



UNIVERSIDAD AUTÓNOMA METROPOLITANA

Unidad Azcapotzalco

División de Ciencias Básicas e Ingeniería

Calibración de Hiperparámetros en Algoritmos
Metaheurísticos y Modelos de Lenguaje para la
Detección de Noticias Falsas

Idónea Comunicación de Resultados

que presenta el:

Ing. Gabriel Hurtado Avilés

para obtener el grado de:

Maestro en Ciencias de la Computación

Directores:

Dr. José Alejandro Reyes Ortiz

Dr. Román Anselmo Mora Gutiérrez

Ciudad de México

Noviembre 2025

Resumen

Este proyecto aborda el desafío de la detección de noticias falsas en español mediante la aplicación y comparación de dos metodologías de inteligencia artificial. Aunque las técnicas desarrolladas podrían aplicarse a otros tipos de fraude digital, el enfoque específico se centra en la identificación de contenido noticioso falso o engañoso. La primera metodología explora el uso de algoritmos metaheurísticos, incluyendo Recocido Multiarranque (MSA), Búsqueda Dispersa (SS), Búsqueda en Vecindades Variables (VNS), Algoritmo Genético (GA) y Optimización por Enjambre de Partículas (PSO), sobre una representación TF-IDF. La segunda, adoptada tras los hallazgos iniciales, se basa en el ajuste fino (fine-tuning) de un modelo de lenguaje Transformer pre-entrenado (DistilBERT). Para el entrenamiento, se construyó un corpus unificando cuatro conjuntos de datos públicos en español y datos extraídos mediante extracción web del portal satírico “El Deforma”, resultando en más de 61,000 noticias. Se implementó un cuidadoso proceso de calibración de hiperparámetros para ambos enfoques, utilizando una división de datos estratificada de 70 % para entrenamiento, 10 % para validación y 20 % para pruebas. El rendimiento fue evaluado con métricas como Exactitud, Precisión, Exhaustividad y F1-Score. Finalmente, el modelo Transformer, que demostró una eficacia superior, fue integrado en una aplicación web funcional desarrollada con Flask y contenerizada con Docker, capaz de analizar URLs en tiempo real. Los resultados validan la metodología de ajuste fino como una solución de vanguardia para combatir la desinformación, superando a los enfoques metaheurísticos en esta tarea.

Palabras clave: Detección de noticias falsas, desinformación, modelos de lenguaje, Transformers, DistilBERT, algoritmos metaheurísticos, procesamiento de lenguaje natural.

Abstract

This project addresses the challenge of fake news detection in Spanish through the application and comparison of two artificial intelligence methodologies. Although the developed techniques could be applied to other types of digital fraud, the specific focus centers on identifying false or misleading news content. The first explores the use of metaheuristic algorithms, including Multi-Start Simulated Annealing (MSA), Scatter Search (SS), Variable Neighborhood Search (VNS), Genetic Algorithm (GA), and Particle Swarm Optimization (PSO), applied to a TF-IDF representation. The second, adopted following initial findings, is based on fine-tuning a pre-trained Transformer language model (DistilBERT). For training, a corpus was constructed by unifying four public Spanish datasets and data extracted through web scraping from the satirical portal “El Deforma”, resulting in over 61,000 news articles. A careful hyperparameter calibration process was implemented for both approaches, using a stratified data split of 70 % for training, 10 % for validation, and 20 % for testing. Performance was evaluated using metrics such as Accuracy, Precision, Recall, and F1-Score. Finally, the Transformer model, which demonstrated superior efficacy, was integrated into a functional web application developed with Flask and containerized with Docker, capable of analyzing URLs in real-time. The results validate the fine-tuning methodology as a state-of-the-art solution for combating misinformation, outperforming metaheuristic approaches in this task.

Keywords: Fake news detection, misinformation, language models, Transformers, DistilBERT, metaheuristic algorithms, natural language processing.

Dedicatoria

A Leslie, el amor de mi vida. Gracias por estar conmigo en todo momento, por hacerme sentir feliz y amado, y por decidir compartir tu vida conmigo.

A mis padres, Abraham y Esther, quienes con su esfuerzo y dedicación han forjado el camino para que sus hijos alcancen sus metas:

A mi papá Abraham, por sus enseñanzas y por siempre preocuparse por sacarnos adelante, así como darnos una formación profesional.

A mi mamá Esther, por su paciencia y por siempre estar para mí en los momentos más difíciles.

A mis hermanas Bere y Dalu, y a mi hermano, Eric, por ser un ejemplo de superación. Gracias por todo su apoyo incondicional, sus consejos, y gracias por ser tan generosos y compartidos conmigo.

A mi familia extendida, cuyo respaldo han sido fuente constante de motivación.

A mis compañeros de estudio, José Manuel, Gabriela, Bryan, Mario y Gabriel de Jesús, y a todos aquellos que, de una u otra forma, contribuyeron a que esta meta se hiciera realidad.

Agradecimientos

En primer lugar, agradezco a Dios por las bendiciones recibidas y por permitirme coincidir en esta vida con personas cuyo amor y apoyo han sido esenciales en este recorrido.

Expreso mi más profundo agradecimiento a mis asesores, el Dr. José Alejandro Reyes Ortiz y el Dr. Román Anselmo Mora Gutiérrez, por su guía, confianza y acompañamiento constante a lo largo de esta etapa. Asimismo, agradezco al Dr.

Josué Padilla Cuevas por su invaluable apoyo y por los puntos de vista que enriquecieron este trabajo.

Extiendo mi gratitud a todos los profesores que formaron parte de mi formación durante la maestría, por su dedicación, enseñanzas y compromiso con la docencia:

Mtro. Rogelio Herrera Aguirre

Dr. César Benavides Álvarez

Dra. Maricela Claudia Bravo Contreras

Dr. Román Anselmo Mora Gutiérrez

Dr. Leonardo Daniel Sánchez Martínez

Dr. Carlos Ernesto Carrillo Arellano

Mtro. Hugo Pablo Leyva

Dr. José Alejandro Reyes Ortiz

Mtro. Jorge Miguel Jaimes Ponce

Mtro. Josué Figueroa González

Agradezco a la Universidad Autónoma Metropolitana por brindarme la oportunidad de cursar este posgrado, por su compromiso con la educación, y por fomentar un ambiente de formación crítica, ética y profesional.

Finalmente, reconozco y agradezco al CONAHCYT (actualmente SECIHTI) por la beca otorgada para el desarrollo de este proyecto de investigación, como estudiante del programa de Maestría en Ciencias de la Computación de la Universidad Autónoma Metropolitana, Unidad Azcapotzalco, con número de CVU 1313870.

Índice general

Abstract	III
Resumen	I
Dedicatoria	V
Agradecimientos	VII
Índice general	IX
Índice de figuras	XIII
Índice de tablas	XV
Glosario	XVII
1. Introducción	1
1.1. Planteamiento del problema	1
1.1.1. El desafío específico del español	2
1.1.2. Complejidad técnica del problema	3
1.2. Motivación	4
1.3. Justificación	5
1.3.1. Brecha tecnológica y novedad metodológica	5
1.3.2. Contribución científica multidimensional	6
1.4. Objetivos	6
1.5. Alcance y limitaciones	7
1.5.1. Alcance del proyecto	7
1.5.2. Limitaciones reconocidas	7
1.6. Contribuciones esperadas	8
1.7. Organización del documento	9
2. Marco Teórico	11
2.1. Detección de noticias falsas: fundamentos y extensibilidad	11
2.1.1. Diferenciación técnica y transferibilidad metodológica	12
2.2. Representación de texto: de TF-IDF a Embeddings Contextuales	13

2.2.1.	Evolución de métodos clásicos: Bag of Words y TF-IDF	13
2.3.	La revolución Transformer y los Modelos de Lenguaje modernos . . .	15
2.3.1.	Arquitectura Transformer y mecanismos de atención	15
2.3.2.	Corpus de pre-entrenamiento y especialización lingüística . . .	15
2.3.3.	Grandes Modelos de Lenguaje y su doble rol en detección . . .	17
2.4.	Optimización metaheurística en la detección de fraude	18
2.4.1.	Fundamentos y arquitectura del sistema metaheurístico	18
2.4.2.	Algoritmos metaheurísticos implementados	19
2.4.3.	Comparación, justificación y aplicaciones	20
2.4.4.	Aplicaciones documentadas en detección de fraude	22
2.5.	Síntesis del marco teórico	22
3.	Estado del arte	23
3.1.	Metodología de búsqueda bibliográfica	23
3.2.	Panorama de la investigación en detección de noticias falsas	24
3.2.1.	Fundamentos metodológicos y construcción de corpus en español	24
3.2.2.	Evolución de los Modelos de Lenguaje en la detección	25
3.2.3.	Técnicas de optimización metaheurística aplicadas	26
3.3.	Algoritmos metaheurísticos: fundamentos y aplicaciones	29
3.4.	Hiperparámetros en modelos de aprendizaje automático	30
3.5.	Análisis temático de la literatura	32
3.6.	Síntesis y perspectivas futuras	35
4.	Metodología	39
4.1.	Visión general del proceso metodológico	39
4.2.	Definición y distinción de conceptos fundamentales	40
4.3.	Construcción del corpus unificado	43
4.4.	Enfoque 1: detección mediante algoritmos metaheurísticos	49
4.5.	Enfoque 2: detección mediante modelo Transformer	52
4.6.	Metodología de evaluación comparativa	54
4.7.	Infraestructura computacional y herramientas	57
5.	Resultados, Evaluación Comparativa e Implementación	59
5.1.	Síntesis de resultados y contribuciones principales	60
5.1.1.	Mapa Conceptual de Contribuciones del Capítulo	60
5.1.2.	Tabla Comparativa entre Paradigmas	62
5.2.	Validación del flujo de procesamiento y representaciones	62
5.2.1.	Implementación y configuración de algoritmos metaheurísticos	63
5.2.2.	Pseudocódigos de los algoritmos implementados	63
5.2.3.	Visualizaciones de resultados por algoritmo	67
5.2.4.	Contextualización con investigación publicada	74
5.2.5.	Análisis comparativo de resultados	75
5.2.6.	Limitaciones fundamentales y justificación para evolución . . .	75
5.3.	Resultados del enfoque Transformer: DistilBERT multilingüe	76

5.3.1. Marco experimental y evolución del desarrollo	76
5.3.2. Configuración del modelo DistilBERT optimizado	77
5.3.3. Proceso de optimización y búsqueda de hiperparámetros . . .	78
5.3.4. Análisis de convergencia y control de sobreajuste	78
5.3.5. Evolución experimental: versiones de desarrollo	79
5.3.6. Pseudocódigo del algoritmo de entrenamiento DistilBERT . .	81
5.3.7. Resultados finales y comparación	81
5.3.8. Análisis de sesgos inherentes en el modelo DistilBERT ajustado	83
5.4. Evaluación comparativa integral: metaheurísticas vs. Transformers . .	88
5.5. Análisis de errores y limitaciones del modelo final	89
5.6. Implementación de prototipos funcionales y demostración práctica . .	90
6. Conclusiones y Trabajo Futuro	97
6.1. Limitaciones del trabajo	98
6.2. Trabajo futuro y líneas de investigación	98
A. Anexo 1	101
Bibliografía	103

Índice de figuras

1.1. Mapa Conceptual 1: Taxonomía del problema de desinformación, con enfoque en noticias falsas y su extensibilidad hacia el fraude digital. .	3
1.2. Mapa Conceptual 2: Estrategias tecnológicas para la detección de fraude digital.	4
2.1. Flujo del proceso de optimización metaheurística para la detección de noticias falsas.	21
3.1. Mapa Conceptual 3: Artículos relacionados que incorporan Modelos de Lenguaje.	26
3.2. Mapa Conceptual 4: Métodos de optimización y metaheurísticas aplicadas.	28
3.3. Mapa Conceptual 5: Clasificación de artículos por enfoque metodológico.	32
3.4. Mapa Conceptual 6: Artículos que son revisiones o están relacionados al análisis de contenido y detección de fraude digital.	35
4.1. Metodología propuesta que aborda la problemática combinando Algoritmos Metaheurísticos y Modelos de Lenguaje.	40
4.2. Arquitectura general del sistema de detección de noticias falsas, mostrando el flujo completo desde la construcción del corpus hasta la implementación de la aplicación web.	41
4.3. Representación gráfica del proceso de balanceo del corpus: comparación entre distribución inicial desbalanceada y distribución final equilibrada. La imagen muestra cómo la extracción web de 9,000 noticias falsas permitió alcanzar un equilibrio óptimo de 49.8 % noticias falsas vs 50.2 % noticias reales.	48
5.1. Mapa conceptual de las contribuciones clave derivadas del análisis de resultados.	61
5.2. Evolución de la convergencia del algoritmo MSA mostrando el progreso gradual a través de los 31 niveles de temperatura desde 1000 hasta 1.24.	68
5.3. Matriz de confusión para MSA en el conjunto de pruebas, evidenciando la baja especificidad (33 %) y el sesgo hacia la clasificación como noticias reales.	68

5.4. Convergencia eficiente del algoritmo SS en solo 10 iteraciones, mostrando mejoras progresivas en las iteraciones 4, 5 y 7 hasta estabilizarse en 0.6630.	69
5.5. Matriz de confusión para SS demostrando mejor balance que MSA con especificidad del 40 % y excelente generalización.	69
5.6. Evolución darwiniana del algoritmo GA a lo largo de 20 generaciones, evidenciando progreso sostenido desde 0.6198 hasta 0.7090 con logros evolutivos significativos.	70
5.7. Matriz de confusión para GA mostrando el mejor balance global con especificidad líder del 48 % y rendimiento sólido en ambas clases. . . .	71
5.8. Progreso sistemático del algoritmo VNS a través de 20 iteraciones con cambios efectivos de vecindario, mostrando saltos significativos en las iteraciones 6 y 14.	72
5.9. Matriz de confusión para VNS destacando la excelente exhaustividad del 89 % para detección de noticias reales con especificidad competitiva del 41 %.	72
5.10. Convergencia problemática del algoritmo PSO evidenciando estancamiento prematuro en la iteración 7-8 y exploración insuficiente del espacio de búsqueda.	73
5.11. Matriz de confusión para PSO revelando el comportamiento extremo problemático con especificidad crítica del 15 % y sesgo severo hacia la clase mayoritaria.	74
5.12. Evolución de la exactitud y pérdida durante el entrenamiento del modelo DistilBERT final. Las líneas azul y roja muestran la convergencia en entrenamiento y validación respectivamente. La estrella dorada marca la mejor época (13), después de la cual se observa el inicio del sobreajuste con una separación creciente entre las curvas.	78
5.13. Evolución de exactitud a través de las versiones experimentales. . . .	79
5.14. Diagrama de componentes del sistema mostrando la arquitectura modular de cuatro capas implementada para ambos prototipos de detección de noticias falsas.	91
5.15. Diagrama de secuencia mostrando el flujo temporal de procesamiento desde la entrada del usuario hasta la respuesta de clasificación del sistema. .	92
5.16. Captura de pantalla de la aplicación analizando una noticia real. . . .	94
5.17. Captura de pantalla de la aplicación detectando una noticia falsa basada en su contenido.	95
5.18. Captura de pantalla de la aplicación detectando una página de fraude digital.	95

Índice de tablas

2.1. Diferencias técnicas entre dominios de desinformación	12
2.2. Comparación de corpus de pre-entrenamiento para modelos de lenguaje considerados en esta investigación.	17
2.3. Comparación de algoritmos metaheurísticos implementados	21
3.1. Contribuciones fundamentales en metodología y construcción de corpus para español.	25
3.2. Evolución de modelos de lenguaje aplicados a la detección de desinformación.	27
3.3. Contribuciones metodológicas en optimización metaheurística para detección.	28
3.4. Algoritmos metaheurísticos: características fundamentales y aplicaciones en detección de noticias falsas.	30
3.5. Aplicación de metaheurísticas por tipo de detección en la literatura revisada.	34
4.1. Corpus académicos utilizados para la construcción del conjunto de datos unificado.	43
4.2. Comparación exhaustiva de características de los corpus utilizados en la construcción del conjunto de datos unificado.	45
4.3. Fases del proceso de extracción web implementado para “El Deforma”.	47
4.4. División estratificada del corpus para entrenamiento y evaluación.	49
4.5. Algoritmos metaheurísticos implementados y sus fundamentos conceptuales.	50
5.1. Comparativa de alto nivel entre los paradigmas de detección implementados.	62
5.2. Corpus académicos utilizados para la construcción del conjunto de datos unificado.	62
5.3. Configuración detallada de parámetros para los cinco algoritmos metaheurísticos implementados.	63
5.4. Función de evaluación común utilizada por todos los algoritmos metaheurísticos.	64

5.5. Pseudocódigo completo del algoritmo Multi-Start Simulated Annealing (MSA).	64
5.6. Pseudocódigo completo del algoritmo Scatter Search (SS).	65
5.7. Pseudocódigo completo del Algoritmo Genético (GA).	66
5.8. Pseudocódigo completo del algoritmo Variable Neighborhood Search (VNS).	66
5.9. Pseudocódigo completo del algoritmo Particle Swarm Optimization (PSO).	67
5.10. Resultados comparativos finales de los cinco algoritmos metaheurísticos implementados usando métricas macro promedio.	75
5.11. Análisis de fortalezas y debilidades de cada algoritmo metaheurístico basado en las métricas obtenidas.	75
5.12. Comparación de rendimiento entre enfoques metaheurísticos y Modelos de Lenguaje usando métricas macro.	76
5.13. Composición del corpus expandido utilizado para el entrenamiento de DistilBERT.	77
5.14. Configuración de la arquitectura del modelo DistilBERT implementado.	77
5.15. Técnicas de regularización implementadas en la configuración final.	77
5.16. Resumen de versiones experimentales de DistilBERT con evolución de estrategias y resultados reales del desarrollo.	79
5.17. Visualización comparativa de convergencia y métricas para las versiones experimentales más significativas con DistilBERT.	80
5.18. Evolución de configuraciones y resultados entre versiones experimentales.	80
5.19. Pseudocódigo simplificado del algoritmo DistilBERT final (V7).	82
5.20. Métricas finales del modelo DistilBERT optimizado.	83
5.21. Desglose detallado de métricas por clase para el modelo DistilBERT optimizado, demostrando rendimiento equilibrado en ambas categorías.	83
5.22. Taxonomía de sesgos identificados en el modelo DistilBERT ajustado para detección de noticias falsas en español.	84
5.23. Análisis preliminar de rendimiento por dominio temático (validación sobre muestra de 500 noticias del conjunto de prueba). La degradación se mide respecto al rendimiento en contenido político.	84
5.24. Comparación DistilBERT vs. mejor algoritmo metaheurístico.	87
5.25. Comparación cuantitativa final entre el mejor algoritmo metaheurístico y el modelo Transformer optimizado.	88
5.26. Estrategias propuestas para abordar limitaciones identificadas.	90

Glosario

ACL Association for Computational Linguistics

API Application Programming Interface

Atención (Attention) Mecanismo que permite a los modelos enfocarse en partes específicas de la entrada al procesar cada elemento. En PLN, permite que el modelo “atienda” a palabras relevantes al procesar una palabra específica.

AUC Area Under the Curve

AUC-ROC Área bajo la curva ROC (Receiver Operating Characteristic). Mide la capacidad del modelo para distinguir entre clases a través de diferentes umbrales de decisión. Un valor de 1.0 indica un clasificador perfecto, mientras que 0.5 indica rendimiento aleatorio.

Balanceo de Clases Proceso de ajustar la distribución de ejemplos entre las diferentes clases para evitar sesgos hacia la clase mayoritaria. En esta investigación se logró un balanceo casi perfecto de 49.8 % noticias falsas y 50.2 % noticias reales mediante extracción web dirigida.

Batch (Lote) Subconjunto de datos procesados simultáneamente en una iteración del algoritmo de entrenamiento. Un tamaño de batch pequeño (como 4, utilizado en esta investigación) proporciona regularización implícita al introducir más ruido en los gradientes.

BDCC Big Data and Cognitive Computing

BERT Bidirectional Encoder Representations from Transformers

BETO Bidirectional Encoder Representations from Transformers for Spanish

Bolsa de Palabras (Bag of Words) Modelo de representación de texto que describe la ocurrencia de palabras en un documento, ignorando el orden y la estructura gramatical. Cada documento se representa como un vector donde cada dimensión corresponde a una palabra del vocabulario y su valor indica la frecuencia de aparición de esa palabra. Es importante para técnicas como TF-IDF y constituye la base para muchos algoritmos de clasificación de texto tradicionales.

BoW Bag of Words

Bulo Información falsa que circula ampliamente, especialmente en redes sociales y medios digitales, con el propósito de engañar a la audiencia. A diferencia de las noticias falsas, los bulos pueden no tener formato periodístico y suelen propagarse de manera viral. Incluye rumores, teorías conspirativas, información médica falsa, y contenido que apela más a las emociones que a los hechos verificables.

Check-Worthiness Propiedad de una afirmación o pieza de contenido que indica si merece ser verificada por un fact-checker. Es una tarea preliminar en sistemas de verificación automática que ayuda a priorizar qué contenido debe ser sometido a verificación exhaustiva.

CLEF Conference and Labs of the Evaluation Forum

CNN Redes Neuronales Convolucionales

Contenerización Técnica de virtualización ligera que empaqueta una aplicación y todas sus dependencias en un contenedor aislado y portable. Docker es la plataforma de contenerización utilizada en esta investigación para garantizar reproducibilidad y facilitar el despliegue.

Convergencia Proceso por el cual un algoritmo de optimización se acerca progresivamente a una solución óptima o cerca del óptimo. Se evalúa observando la estabilización de la función objetivo a lo largo de las iteraciones.

Corpus Colección grande y estructurada de textos utilizados para investigación lingüística o entrenamiento de modelos de PLN. En este contexto, se refiere al conjunto unificado de noticias en español construido integrando cuatro corpus académicos y datos de extracción web.

Corpus Unificado Dataset consolidado de más de 61,000 noticias en español construido mediante la integración y estandarización de cuatro corpus académicos reconocidos (Posadas-Durán, Acosta, Tretiakov, Blanco-Fernández) más 9,000 noticias extraídas de “El Deforma”. Representa una de las contribuciones principales de esta investigación.

CPU Central Processing Unit

CSS Cascading Style Sheets

CSV Comma-Separated Values

Dataset Conjunto estructurado de datos utilizado para entrenar, validar y probar modelos de machine learning. En esta investigación, se refiere al corpus de noticias etiquetadas como verdaderas o falsas, que alcanzó más de 61,000 registros únicos.

Deepfake Contenido multimedia (video, audio, imágenes) generado o manipulado usando inteligencia artificial, especialmente técnicas de aprendizaje profundo, para hacer que parezca que alguien dijo o hizo algo que nunca ocurrió realmente.

Desinformación Difusión intencional de información falsa o engañosa con el propósito específico de manipular la opinión pública, influir en decisiones políticas o sociales, o causar daño. Se caracteriza por ser un proceso activo y deliberado de creación y distribución de contenido falso.

Desinformación (Misinformation) Información incorrecta que se comparte sin intención maliciosa. A diferencia de la desinformación, quienes comparten misinformación no tienen conocimiento de que la información es falsa y actúan de buena fe.

Destilación de Conocimiento Técnica de compresión de modelos en la que un modelo más pequeño (estudiante) aprende a imitar el comportamiento de un modelo más grande (profesor). DistilBERT utiliza destilación triple combinando pérdida de destilación, pérdida de enmascaramiento y pérdida de similitud coseno.

DistilBERT Distilled Bidirectional Encoder Representations from Transformers

División de Datos Proceso de particionar el dataset completo en subconjuntos distintos para diferentes propósitos: entrenamiento (70 %), validación (10 %) y prueba (20 %). La división estratificada garantiza que cada subconjunto mantenga la misma proporción de clases que el dataset original.

DL Deep Learning

Docker Plataforma para contenerización que empaqueta una aplicación y sus dependencias en un entorno aislado y reproducible.

Dropout Una técnica de regularización utilizada en redes neuronales para prevenir el sobreajuste. Consiste en desactivar aleatoriamente una fracción de las neuronas de una capa durante el entrenamiento, obligando al modelo a aprender patrones más robustos y generalizables.

Elitismo Estrategia en algoritmos evolutivos que garantiza que las mejores soluciones de una generación se preserven y pasen a la siguiente generación sin modificación, asegurando que la calidad de la mejor solución no disminuya.

Embedding Representación vectorial densa de palabras, frases o documentos en un espacio multidimensional donde la distancia entre vectores refleja similitud semántica. Ejemplos incluyen Word2Vec, GloVe, FastText y los embeddings contextuales generados por modelos Transformer.

EMNLP Empirical Methods in Natural Language Processing

Espacio de Búsqueda Conjunto de todas las posibles configuraciones de hiperparámetros que pueden ser exploradas durante el proceso de optimización. Define los límites y restricciones para cada hiperparámetro.

Español Neutro Multiregional Enfoque metodológico que busca desarrollar modelos capaces de procesar múltiples variantes geográficas del español sin estar sesgados hacia una región específica. En esta investigación se logró mediante la integración de corpus de España (70 %), México (20 %) y múltiples países latinoamericanos (10 %).

Especificidad (Specificity) Métrica que mide la capacidad del modelo para identificar correctamente los casos negativos. Se calcula como: $\text{Especificidad} = \text{TN} / (\text{TN} + \text{FP})$. En detección de noticias falsas, mide qué tan bien el modelo identifica noticias reales sin confundirlas con falsas.

Exactitud (Accuracy) Proporción de predicciones correctas sobre el total de predicciones. Se calcula como: $\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$. Es una métrica útil cuando las clases están balanceadas.

Exploración Capacidad de un algoritmo de búsqueda para investigar regiones no exploradas del espacio de soluciones, evitando quedar atrapado en óptimos locales.

Explotación Capacidad de un algoritmo para refinar y mejorar soluciones prometedoras encontradas, concentrando la búsqueda en regiones del espacio que han mostrado buenos resultados.

F1-Score Media armónica entre precisión y recall. Se calcula como: $\text{F1} = 2 \times (\text{Precisión} \times \text{Recall}) / (\text{Precisión} + \text{Recall})$. Proporciona una medida equilibrada del rendimiento del clasificador y es la métrica principal utilizada en esta investigación para comparar modelos.

FakeDeS Framework estandarizado para la evaluación de sistemas de detección de noticias falsas en español, establecido por las competencias IberLEF. Define métricas, protocolos de evaluación y datasets de referencia que permiten la comparación directa entre diferentes sistemas.

Fine-tuning Proceso de ajustar un modelo pre-entrenado en una tarea específica utilizando un conjunto de datos más pequeño y especializado. Permite aprovechar el conocimiento general del modelo pre-entrenado para tareas particulares.

Flask Microframework de Python utilizado para construir aplicaciones web y APIs RESTful.

FN False Negative (Falso Negativo)

FP False Positive (Falso Positivo)

Fraude Digital Conjunto amplio de actividades maliciosas realizadas a través de medios digitales con el objetivo primario de obtener beneficios económicos ilícitos, información personal sensible, o acceso no autorizado a recursos. Incluye estafas en línea, phishing, fraude financiero digital, esquemas Ponzi digitales, estafas de inversión, fraude laboral en línea, y otras formas de engaño que explotan plataformas y tecnologías digitales. A diferencia de las noticias falsas, que buscan influencia social, el fraude digital se enfoca en la obtención directa de beneficios materiales o acceso a activos. Su “éxito” se mide por la cantidad de dinero o información obtenida, no por el alcance viral o la influencia en opinión pública.

FSSP Flexible Shop Scheduling Problem

Función Objetivo Función matemática que define el criterio a optimizar en un problema. En el contexto de esta investigación, representa la métrica de rendimiento del modelo (típicamente F1-Score) que se busca maximizar durante la optimización de hiperparámetros.

GA Genetic Algorithm (Algoritmo Genético)

Gap de Generalización (Generalization Gap) La diferencia entre el rendimiento de un modelo en el conjunto de entrenamiento y en un conjunto de validación o prueba. Un gap pequeño (menor a 0.05) indica que el modelo generaliza bien, mientras que un gap grande es un indicador de sobreajuste.

Gemini A Family of Highly Capable Multimodal Models

GPT Generative Pre-trained Transformer

GPU Graphics Processing Unit

Hiperparámetro Parámetro de configuración del modelo que se establece antes del entrenamiento y no se aprende durante el proceso de entrenamiento. Ejemplos incluyen la tasa de aprendizaje, el número de épocas, el tamaño del batch, el dropout rate y la regularización L2.

HTML HyperText Markup Language

HTTP HyperText Transfer Protocol

IA Inteligencia Artificial

IberLEF Iberian Languages Evaluation Forum

ICOKG International Conference on Ontologies and Knowledge Graphs

ICR Idónea Comunicación de Resultados

Información Maliciosa (Malinformation) Información genuina que se comparte con intención de causar daño, como filtraciones de información privada, discursos de odio, o acoso. Aunque la información base puede ser verdadera, su uso es malicioso.

Inyección de Ruido Técnica de regularización que añade ruido aleatorio a las activaciones o pesos del modelo durante el entrenamiento. Actúa como una forma de aumento de datos que mejora la robustez y capacidad de generalización del modelo.

JSON JavaScript Object Notation

KerasTuner Una biblioteca de software para la optimización de hiperparámetros de modelos de aprendizaje automático, especialmente en TensorFlow, que permite explorar eficientemente diferentes combinaciones de parámetros utilizando estrategias como búsqueda aleatoria, Hyperband y optimización Bayesiana.

Lematización Proceso más sofisticado que el stemming que reduce las palabras a su forma canónica o lemma, considerando el contexto morfológico y sintáctico. Por ejemplo, “mejor” se lematiza a “bueno”.

LLaMA Large Language Model Meta AI

LLM Large Language Model (Gran Modelo de Lenguaje)

LSTM Long Short-Term Memory

Matriz de Confusión Tabla que describe el rendimiento de un modelo de clasificación mostrando las predicciones correctas e incorrectas para cada clase. Permite calcular métricas detalladas de rendimiento como precisión, recall, F1-Score y especificidad.

mBERT Multilingual BERT

Metaheurística Estrategia de alto nivel para guiar y modificar otras heurísticas con el objetivo de producir soluciones de alta calidad para problemas de optimización. Incluye técnicas como algoritmos genéticos, optimización por enjambre de partículas, y recocido simulado.

ML Machine Learning

MLM Masked Language Modeling

MSA Multi-Start Simulated Annealing (Recocido Multiarranque)

n-gramas Secuencias contiguas de n elementos (palabras o caracteres) de un texto, que capturan el contexto local y las dependencias secuenciales. En esta tesis, se utilizan n-gramas de palabras como características para la representación TF-IDF.

NER Named Entity Recognition (Reconocimiento de Entidades Nombradas)

NLP Natural Language Processing

Noticias Falsas Información deliberadamente fabricada que se presenta como contenido periodístico legítimo, pero que contiene datos falsos, inexactos o engañosos. Su objetivo principal es manipular la opinión pública, influir en decisiones políticas o sociales, o distorsionar la percepción de eventos actuales. Se caracteriza por imitar el formato y estilo de medios de comunicación establecidos, utilizando técnicas periodísticas aparentemente profesionales para ganar credibilidad. A diferencia del fraude digital, su “éxito” se mide por el alcance social y la influencia en la opinión pública, no por beneficios económicos directos.

NSP Next Sentence Prediction

Operador de Cruce (Crossover) En algoritmos genéticos, operador que combina dos soluciones padres para generar una o más soluciones hijas, heredando características de ambos padres. Implementaciones comunes incluyen cruce de un punto, dos puntos y uniforme.

Operador de Mutación En algoritmos genéticos, operador que introduce variabilidad aleatoria en una solución individual modificando uno o más de sus componentes. Previene la convergencia prematura y mantiene diversidad genética en la población.

Palabras Vacías (Stop Words) Palabras comunes en un idioma que generalmente se filtran durante el preprocesamiento de texto porque no aportan significado semántico significativo. Ejemplos en español: “el”, “la”, “de”, “que”, “y”.

Parada Temprana (Early Stopping) Un mecanismo de regularización que detiene el proceso de entrenamiento cuando el rendimiento del modelo en un conjunto de validación deja de mejorar durante un número específico de épocas (paciencia). Se utiliza para prevenir el sobreajuste y reducir el tiempo de cómputo.

Phishing Técnica de fraude digital que utiliza mensajes electrónicos fraudulentos (correos, SMS, mensajes de redes sociales) que se hacen pasar por comunicaciones legítimas de organizaciones confiables, con el objetivo de obtener información sensible como contraseñas, números de tarjetas de crédito o datos personales.

PLN Procesamiento del Lenguaje Natural

Pre-entrenamiento Fase inicial del entrenamiento de un modelo de lenguaje en la que se aprenden representaciones generales del lenguaje utilizando grandes corpus de texto sin etiquetar. En modelos como BERT, incluye tareas como Masked Language Modeling (MLM) y Next Sentence Prediction (NSP).

Precisión Métrica que mide la proporción de predicciones positivas que fueron correctas. Se calcula como: $\text{Precisión} = \text{TP} / (\text{TP} + \text{FP})$. En detección de noticias falsas, indica qué tan confiable es el modelo cuando predice que una noticia es falsa.

Promedio Macro Método de agregación de métricas que calcula la media aritmética simple de las métricas para cada clase, dando el mismo peso a todas las clases independientemente de su frecuencia. Útil para evaluar el rendimiento equilibrado en datasets balanceados.

Promedio Ponderado Método de agregación de métricas que calcula la media ponderada de las métricas para cada clase, donde los pesos son proporcionales al número de muestras de cada clase. Refleja el rendimiento global considerando el desbalance de clases.

PSO Particle Swarm Optimization

RAM Random Access Memory

Regularización L2 Técnica de regularización que añade una penalización proporcional al cuadrado de la magnitud de los pesos del modelo a la función de pérdida. Ayuda a prevenir el sobreajuste forzando al modelo a utilizar pesos más pequeños y distribuidos, promoviendo soluciones más simples y generalizables.

RESTful Estilo de arquitectura de software para sistemas hipermedia distribuidos, comúnmente utilizado para el diseño de APIs web.

RNN Redes Neuronales Recurrentes

RoBERTa Robustly Optimized BERT Pretraining Approach

ROC Receiver Operating Characteristic

SA Simulated Annealing (Recocido Simulado)

Sensibilidad (Recall) Métrica que mide la proporción de casos positivos reales que fueron correctamente identificados. Se calcula como: $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$. También conocida como exhaustividad o tasa de verdaderos positivos.

Sesgo (Bias) Error sistemático en las predicciones del modelo que puede deberse a suposiciones erróneas en el algoritmo de aprendizaje, datos de entrenamiento no representativos, o prejuicios inherentes en el dataset. En esta investigación se analizan sesgos temáticos, geográficos y temporales.

Sobreajuste (Overfitting) Fenómeno donde un modelo aprende demasiado específicamente los datos de entrenamiento, incluyendo ruido y patrones espurios, perdiendo capacidad de generalización a datos nuevos no vistos durante el entrenamiento. Se manifiesta como un gap grande entre el rendimiento en entrenamiento y validación.

SS Scatter Search

Stemming Técnica de reducción de palabras a su raíz o stem mediante la eliminación de sufijos. Por ejemplo, “corriendo”, “corrió”, “correr” se reducen a “corr”.

Subajuste (Underfitting) Fenómeno donde un modelo es demasiado simple para capturar la complejidad subyacente de los datos, resultando en bajo rendimiento tanto en entrenamiento como en validación. Indica que el modelo no tiene suficiente capacidad para aprender los patrones relevantes.

SVM Support Vector Machine

Tasa de Aprendizaje (Learning Rate) Un hiperparámetro que determina el tamaño de los pasos que un algoritmo de optimización (como el descenso de gradiente) toma para actualizar los parámetros del modelo en cada iteración. Una tasa de aprendizaje ultra-baja (como $2e-06$) se utiliza para una convergencia más controlada y estable.

TF-IDF Term Frequency-Inverse Document Frequency

TinyBERT A Smaller Student for Knowledge Distillation

TN True Negative (Verdadero Negativo)

Tokenización Proceso de dividir texto en unidades más pequeñas llamadas tokens, que pueden ser palabras, subpalabras, caracteres o n-gramas. Es el primer paso en el preprocesamiento de texto para análisis computacional.

TP True Positive (Verdadero Positivo)

Transformer Arquitectura de red neuronal basada en mecanismos de atención que ha revolucionado el PLN. Introdujo el concepto de atención multi-cabeza y eliminó la necesidad de procesamiento secuencial, permitiendo paralelización eficiente.

URL Uniform Resource Locator

Validación Cruzada Técnica de evaluación que divide el dataset en múltiples subconjuntos (folds) para entrenar y validar el modelo repetidamente, proporcionando una estimación más robusta del rendimiento. La validación cruzada estratificada preserva la distribución de clases en cada fold.

Varianza Medida de cuánto varían las predicciones del modelo para diferentes conjuntos de entrenamiento. Alta varianza indica que el modelo es sensible a pequeños cambios en los datos de entrenamiento, lo que puede ser una señal de sobreajuste.

Verificación de Hechos (Fact-Checking) Proceso sistemático de investigación y verificación de afirmaciones factuales en contenido publicado. Incluye la consulta de fuentes primarias, expertos, y evidencia documental para determinar la veracidad de las afirmaciones.

VNS Variable Neighborhood Search

Web Scraping Técnica de extracción automatizada de datos de sitios web mediante programas que navegan y analizan el contenido HTML de las páginas web para recopilar información específica. En esta investigación se utilizó para extraer 9,000 noticias del portal satírico “El Deforma”.

Weight Decay (Decaimiento de Pesos) Técnica de regularización que reduce gradualmente la magnitud de los pesos del modelo en cada iteración del entrenamiento. Es equivalente a la regularización L2 en muchos optimizadores y ayuda a prevenir el sobreajuste controlando la capacidad del modelo.

WordPiece Algoritmo de tokenización basado en subpalabras utilizado por modelos como BERT y DistilBERT. Divide palabras en unidades subléxicas más pequeñas, permitiendo manejar vocabularios grandes de manera eficiente y procesar palabras fuera del vocabulario mediante la composición de subpalabras conocidas.

Época (Epoch) Una iteración completa sobre todo el conjunto de datos de entrenamiento. En el entrenamiento del modelo DistilBERT, se utilizaron hasta 30 épocas máximas, aunque el entrenamiento óptimo se detuvo en la época 13 mediante early stopping.

Capítulo 1

Introducción

1.1. Planteamiento del problema

La era digital y la interconexión global han generado un desafío sin precedentes: la propagación masiva de Desinformación. Este fenómeno, que abarca desde Noticias Falsas hasta diversas formas de Fraude Digital, representa una amenaza significativa para la estabilidad social, económica y democrática a nivel mundial. Las Noticias Falsas se definen como información deliberadamente engañosa que simula ser periodismo auténtico [1], difundiéndose a través de redes sociales y medios digitales para manipular la opinión pública y el comportamiento de los individuos.

La gravedad del problema se ha intensificado exponencialmente debido a tres factores convergentes: la creciente sofisticación de los actores maliciosos, la democratización de herramientas para generar contenido mediante IA [2], y la velocidad sin precedentes con que la información se viraliza. La investigación reciente documenta el impacto multidimensional de la desinformación, desde la distorsión de procesos democráticos [3] hasta la creación de pánico durante crisis sanitarias como la pandemia de COVID-19 [4]. De forma paralela, el fraude digital ha evolucionado hacia formas más sofisticadas que aprovechan tanto vulnerabilidades técnicas como sesgos cognitivos humanos [5].

Distinción fundamental y enfoque de esta investigación: Es importante distinguir entre dos conceptos relacionados pero distintos. Las **Noticias Falsas** son información deliberadamente fabricada que imita el formato periodístico legítimo con el objetivo primario de *manipular la opinión pública*, influir en decisiones políticas o sociales, o distorsionar la percepción de eventos actuales, midiendo su “éxito” por el alcance y la influencia social alcanzados. Por otro lado, el **Fraude Digital** comprende actividades maliciosas digitales cuyo objetivo primario es *obtener beneficios económicos ilícitos* o acceso no autorizado a información o recursos, incluyendo estafas de inversión, phishing, fraude financiero y esquemas de estafas piramidales digitales, donde el “éxito” se mide por el beneficio económico obtenido.

Estas diferencias se manifiestan en objetivos divergentes (influencia social versus beneficio económico), audiencias distintas (consumidores de noticias versus potencia-

les víctimas económicas), métricas de éxito contrastantes (viralidad versus rentabilidad económica), y patrones lingüísticos diferenciados (imitación periodística versus técnicas de persuasión comercial y urgencia). **Este proyecto se centra específicamente en la detección de noticias falsas**, desarrollando una metodología inherentemente transferible al fraude digital debido a que comparten características computacionales fundamentales: naturaleza textual, clasificación binaria (legítimo/malicioso) y optimización de parámetros.

Desde la perspectiva de la detección automatizada, el problema se conceptualiza como una clasificación binaria: determinar si un contenido es **confiable** (verificado y legítimo) o **no confiable** (desinformativo). Aunque esta simplificación reduce la complejidad del espectro de veracidad, resulta práctica y efectiva para aplicaciones reales que requieren respuestas claras y accionables.

La desinformación contemporánea se manifiesta en múltiples modalidades con impacto significativo en individuos, empresas y sociedades, como lo ilustra la Figura 1.1. Si bien este estudio se enfoca en noticias falsas, es relevante comprender el contexto más amplio del fraude digital. Las manifestaciones incluyen noticias falsas generadas por IA mediante Grandes Modelos de Lenguaje (GPTs) que imitan el estilo periodístico legítimo [6] —uno de los objetivos directos de este proyecto—, así como desinformación política dirigida mediante campañas coordinadas para influir en procesos electorales [7], fraude financiero digital que explota plataformas digitales y criptomonedas [8], fraude laboral en línea con ofertas falsas para obtener información personal [9], estafas de ingeniería social que combinan información de redes sociales con narrativas convincentes, desinformación en salud con consecuencias directas en la salud pública [10], Deepfakes mediante contenido multimedia manipulado con técnicas de DL (requiriendo extensión multimodal), y Bulos que se propagan viralmente en redes sociales. La metodología desarrollada en este proyecto es directamente aplicable a la mayoría de estas manifestaciones, con las extensiones apropiadas para casos multimodales.

1.1.1. El desafío específico del español

El español, la cuarta lengua más hablada del mundo con más de 500 millones de hablantes nativos [11], presenta desafíos únicos para la detección automatizada de desinformación. A pesar de su importancia demográfica y económica, existe una notable escasez de recursos computacionales especializados para esta tarea en español, comparado con los abundantes recursos disponibles para el inglés [12]. Esta brecha se manifiesta en la escasez de corpus etiquetados de calidad, la variabilidad dialectal que complica el modelado lingüístico, el contexto cultural específico que modula los patrones de desinformación, y las herramientas de detección limitadas disponibles para hispanohablantes.

Esta investigación adopta un enfoque de español neutro multiregional, fundamentado en la integración estratégica de corpus que representan diferentes variantes geográficas y estilísticas del español. Los corpus de Posadas-Durán et al. [12]



Figura 1.1: Mapa Conceptual 1: Taxonomía del problema de desinformación, con enfoque en noticias falsas y su extensibilidad hacia el fraude digital.

y Blanco-Fernández et al. [13] aportan principalmente contenido peninsular español, mientras que el corpus de Acosta [11] incorpora fuentes internacionales con presencia del español mexicano y latinoamericano. La inclusión específica de contenido de “El Deforma” (portal satírico mexicano) añade características del español mexicano contemporáneo, y la variabilidad temporal de los corpus (2018-2025) captura la evolución del español digital en múltiples regiones.

La distribución geográfica resultante aproxima un 70 % de contenido español (principalmente del corpus político de Blanco-Fernández), 20 % mexicano (contenido de “El Deforma” y fuentes mexicanas), y 10 % multinacional (corpus de Acosta con diversas fuentes internacionales). Esta composición produce un modelo capaz de generalizar eficazmente a través de las principales variantes del español sin estar sesgado hacia una región específica, ofreciendo robustez lingüística para detectar desinformación independientemente de la variante regional, generalización mejorada con menor dependencia de modismos regionales específicos, aplicabilidad universal para toda la comunidad hispanohablante, y representatividad demográfica que refleja la realidad del consumo transnacional de noticias en español.

1.1.2. Complejidad técnica del problema

La detección automatizada de Noticias Falsas es un problema técnico multifacético que integra múltiples disciplinas, como se esquematiza en la Figura 1.2. La literatura reciente [14] documenta desafíos que incluyen el análisis semántico profundo para comprender contexto e implicaciones sutiles mediante PLN, la detección de patrones

estilométricos que identifiquen características lingüísticas indicativas de autoría maliciosa [15], el procesamiento en tiempo real del volumen masivo de contenido diario usando ML, la adaptación a contenido sintético generado por modelos de IA cada vez más sofisticados [16], la robustez ante ataques adversariales diseñados para evadir detección, y la optimización de Hiperparámetros para calibrar modelos y maximizar rendimiento.

Dada la sofisticación de estas amenazas, se requieren soluciones tecnológicas igualmente avanzadas. Este trabajo se centra en el desarrollo de tales soluciones, con un enfoque particular en el idioma español y la comparación sistemática de paradigmas tecnológicos complementarios que abarcan desde técnicas clásicas optimizadas hasta modelos de lenguaje de última generación.



Figura 1.2: Mapa Conceptual 2: Estrategias tecnológicas para la detección de fraude digital.

1.2. Motivación

La motivación de esta investigación se fundamenta en la convergencia de experiencias personales cercanas y la identificación de una brecha crítica en la protección tecnológica de las comunidades hispanohablantes. Durante el desarrollo de este proyecto, se observaron múltiples casos de personas víctimas de fraude digital sofisticado, desde estafas de inversión disfrazadas de noticias financieras legítimas hasta esquemas de *phishing* que aprovechaban eventos noticiosos para parecer creíbles. Las víctimas,

frecuentemente personas mayores o con menor familiaridad con la tecnología digital, sufrieron no solo pérdidas económicas significativas, sino también un profundo impacto psicológico que afectó su confianza en los medios digitales.

La investigación en psicología cognitiva aplicada a la desinformación [5] ha demostrado que ciertos grupos demográficos son particularmente vulnerables. Los adultos mayores muestran mayor susceptibilidad a heurísticas de credibilidad basadas en la autoridad percibida, mientras que las poblaciones con menor alfabetización digital poseen capacidad limitada para evaluar la legitimidad de fuentes en línea. Las comunidades con acceso limitado a información confiable desarrollan mayor dependencia de las redes sociales como fuente principal de noticias, y los hablantes nativos de español enfrentan menor disponibilidad de herramientas de verificación en su idioma comparado con anglófonos.

El rápido avance de los modelos generativos de IA, como GPT-3 [17] y sus sucesores, ha reducido dramáticamente las barreras para la creación de contenido falso convincente. Esta “democratización” de la capacidad de generar desinformación [6] crea una urgencia imperativa para desarrollar defensas tecnológicas igualmente sofisticadas. Impulsado por esta necesidad, el presente trabajo se centra en desarrollar, comparar y validar métodos computacionales avanzados para la detección de noticias falsas, con el objetivo explícito de contribuir a la protección de las poblaciones más vulnerables en el ecosistema digital hispanohablante.

1.3. Justificación

Esta investigación se justifica por tres dimensiones fundamentales: la brecha tecnológica existente en recursos para el español, la novedad de su enfoque metodológico comparativo, y la contribución científica multidimensional que ofrece.

1.3.1. Brecha tecnológica y novedad metodológica

El español, con más de 500 millones de hablantes nativos, representa un vasto ecosistema digital históricamente desatendido en herramientas para la detección de desinformación. Mientras que para el inglés existen múltiples conjuntos de datos a gran escala como LIAR, FakeNewsNet y CREDBANK [18], los recursos equivalentes en español son limitados y fragmentados. El estado del arte actual se basa principalmente en cuatro corpus: el corpus de Acosta con 598 noticias [11], el Spanish Fake News Corpus con 971 noticias [12], el corpus de Tretiakov con 1,958 noticias [19], y el Spanish Political Fake News con más de 57,000 noticias [13]. Esta fragmentación dificulta significativamente el desarrollo de modelos robustos y generalizables, motivando la necesidad de unificación abordada en este proyecto.

La novedad principal de esta investigación radica en su **enfoque evolutivo comparativo** que evalúa sistemáticamente dos paradigmas complementarios de la Inteligencia Artificial. El **paradigma clásico optimizado** utiliza representación textual

TF-IDF, optimización mediante algoritmos metaheurísticos para calibración de hiperparámetros, clasificadores de aprendizaje automático tradicionales, ofreciendo ventajas en eficiencia computacional, interpretabilidad y menor dependencia de hardware especializado. El **paradigma de deep learning** emplea embeddings contextuales dinámicos, modelo base DistilBERT preentrenado [20], técnica de *fine-tuning* con optimización de hiperparámetros, proporcionando ventajas en comprensión semántica profunda y captura de relaciones contextuales complejas que escapan a enfoques tradicionales.

1.3.2. Contribución científica multidimensional

Esta investigación ofrece contribuciones sustanciales en tres dimensiones complementarias. En **recursos lingüísticos**, proporciona un corpus unificado mediante integración y estandarización de los principales corpus en español, desarrolla una metodología de unificación con protocolo replicable para integrar conjuntos de datos heterogéneos, y establece líneas base comparativas (benchmarking) para futuras investigaciones. En el ámbito **metodológico**, realiza una aplicación sistemática de algoritmos bioinspirados para la calibración de hiperparámetros mediante optimización metaheurística, ejecuta un análisis comparativo riguroso con evaluación exhaustiva usando métricas múltiples y validación cruzada, y demuestra transferencia tecnológica mediante implementación práctica en aplicaciones web contenerizadas. Las contribuciones **aplicadas** incluyen herramientas funcionales mediante aplicaciones web desplegables para análisis en tiempo real, disponibilidad pública de implementaciones para garantizar reproducibilidad mediante código abierto, y la generación de impacto social directo al proporcionar herramientas accesibles para comunidades hispanohablantes que históricamente han carecido de tales recursos.

1.4. Objetivos

Objetivo General

Desarrollar un método computacional basado en algoritmos metaheurísticos y modelos de lenguaje para detectar noticias falsas en español, con una metodología transferible a otros tipos de fraude digital.

Objetivos Específicos

- Recopilar y procesar un conjunto de datos diverso a partir de múltiples corpus en español, enriqueciéndolo mediante técnicas de *extracción web*.
- Implementar un sistema de detección inicial que utilice técnicas de Procesamiento del Lenguaje Natural (TF-IDF) y algoritmos metaheurísticos.

- Desarrollar un sistema de detección avanzado mediante el ajuste fino (*fine-tuning*) de un modelo de lenguaje profundo (DistilBERT), optimizando su rendimiento a través de la calibración de hiperparámetros.
- Realizar un análisis comparativo del rendimiento entre ambos enfoques, utilizando un conjunto completo de métricas de evaluación (Exactitud, Precisión, Exhaustividad y F1-Score).
- Desarrollar un prototipo de aplicación web funcional, contenerizada con Docker, para demostrar la aplicabilidad práctica del modelo de mayor rendimiento en el análisis de URLs.

1.5. Alcance y limitaciones

1.5.1. Alcance del proyecto

El alcance de esta investigación se define en múltiples dimensiones complementarias. **Lingüísticamente**, el proyecto se centra exclusivamente en textos en español, abordando la detección de noticias falsas con extensibilidad demostrable a otros tipos de fraude digital, y proporciona cobertura de múltiples países hispanohablantes mediante el enfoque multiregional adoptado. **Técnicamente**, se limita al procesamiento exclusivo de contenido textual (modalidad unimodal), implementa clasificación binaria supervisada (FALSO/REAL) como aproximación práctica al problema, compara sistemáticamente enfoques clásicos optimizados versus modelos Transformer de última generación, y desarrolla aplicaciones web funcionales y contenerizadas que demuestran viabilidad práctica.

La **transferibilidad metodológica** demostrada hace que el enfoque sea adaptable para detectar fraude financiero y laboral mediante ajuste del corpus de entrenamiento, útil para detectar ingeniería social, *phishing* y desinformación temática específica, aunque reconociendo que el contenido multimodal (videos, audios, deep-fakes) requiere arquitecturas adicionales que exceden el alcance actual. **Metodológicamente**, la investigación aplica cinco algoritmos bioinspirados de optimización metaheurística (MSA, SS, VNS, GA, PSO), emplea validación experimental mediante validación cruzada estratificada y métricas múltiples para garantizar robustez estadística, y asegura reproducibilidad mediante documentación completa y disponibilidad de código fuente.

1.5.2. Limitaciones reconocidas

Las limitaciones de esta investigación se organizan en cuatro categorías fundamentales. Las **limitaciones de datos** incluyen dependencia de corpus existentes donde el rendimiento está condicionado por la calidad y representatividad de los datos disponibles, sesgos inherentes potenciales de naturaleza temporal (épocas de recolección), temática (predominio de contenido político) o geográfica (distribución desbalanceada

de regiones), evolución del lenguaje que puede hacer que los modelos no capturen patrones emergentes en la desinformación futura, y dependencia de la calidad del etiquetado manual en los corpus originales que puede introducir ruido en el entrenamiento.

Las **limitaciones técnicas** comprenden requisitos de recursos computacionales donde el entrenamiento de modelos Transformer requiere hardware especializado (GPUs) y tiempo considerable, escalabilidad en tiempo real limitada ya que los prototipos no están optimizados para procesamiento de flujos masivos de datos, y generalización a otros fraudes donde la efectividad en otros tipos de fraude digital es inferencial y requiere validación empírica adicional. Las **limitaciones operacionales** reconocen que los sistemas funcionan como herramientas de apoyo a la decisión humana y no como reemplazo del juicio humano experto, que la verificación absoluta de veracidad puede requerir investigación periodística adicional más allá de la clasificación automatizada, que el contexto dinámico de la desinformación implica que los modelos requieren actualización periódica para mantener efectividad, y que las consideraciones éticas relacionadas con sesgo algorítmico y responsabilidad no se abordan exhaustivamente.

Finalmente, las **limitaciones de evaluación** incluyen el uso de métricas tradicionales que pueden no capturar toda la complejidad multidimensional del problema, validación temporal limitada al no realizarse evaluación con datos posteriores al período de entrenamiento (validación prospectiva), y análisis de errores cualitativo limitado por el volumen masivo de datos que dificulta el análisis caso por caso exhaustivo de fallos del sistema.

1.6. Contribuciones esperadas

Esta investigación aspira a generar contribuciones significativas en tres dimensiones complementarias que abarcan aspectos teóricos, prácticos y sociales. Las **contribuciones teóricas** incluyen el desarrollo de una metodología comparativa que proporciona un marco sistemático y riguroso para comparar paradigmas complementarios en la detección de desinformación, permitiendo a investigadores futuros tomar decisiones informadas sobre enfoques tecnológicos, así como la aplicación innovadora de algoritmos bioinspirados de optimización metaheurística para la calibración de modelos de detección, demostrando su viabilidad y efectividad en este dominio específico.

Las **contribuciones prácticas** abarcan la creación de un corpus unificado que constituye un recurso consolidado y de alta calidad para la investigación futura en español, resolviendo la fragmentación histórica de datasets en este idioma, el desarrollo de herramientas funcionales mediante aplicaciones web desplegables para uso comunitario que democratizan el acceso a tecnología de detección avanzada, y la provisión de código abierto con implementaciones reproducibles y extensibles que facilitan la validación y extensión del trabajo por parte de la comunidad científica.

Las **contribuciones sociales** se orientan hacia la protección comunitaria me-

diente herramientas accesibles específicamente diseñadas para comunidades hispanohablantes que históricamente han carecido de tales recursos, la democratización tecnológica que contribuye a reducir la brecha digital en herramientas de verificación entre hablantes de español e inglés, y la contribución a la concientización y alfabetización digital mediante la disponibilidad de herramientas que ayudan a usuarios finales a desarrollar capacidades críticas para evaluar la credibilidad de contenidos digitales.

1.7. Organización del documento

Este documento se estructura de manera progresiva para guiar al lector a través del desarrollo completo de la investigación. El **Capítulo 2 - Marco Teórico** establece los fundamentos teóricos de las metodologías utilizadas, incluyendo técnicas de procesamiento de lenguaje natural, algoritmos metaheurísticos y arquitecturas de aprendizaje profundo. El **Capítulo 3 - Estado del Arte** revisa exhaustivamente la literatura relevante, identificando las brechas de conocimiento que justifican este trabajo y posicionando las contribuciones en el contexto de investigaciones previas.

El **Capítulo 4 - Metodología** detalla meticulosamente la construcción del corpus unificado y la implementación de ambos paradigmas tecnológicos (clásico optimizado y deep learning), proporcionando información suficiente para la reproducibilidad. El **Capítulo 5 - Resultados, Evaluación Comparativa e Implementación** presenta y compara sistemáticamente los resultados obtenidos por ambas metodologías utilizando múltiples métricas de evaluación, y describe el desarrollo de una aplicación web funcional que demuestra la viabilidad práctica de la solución óptima. Finalmente, el **Capítulo 6 - Conclusiones y Trabajo Futuro** sintetiza los hallazgos principales, discute las implicaciones teóricas y prácticas, reconoce las limitaciones del trabajo, y propone direcciones específicas para investigaciones futuras que puedan extender y mejorar las contribuciones de este proyecto.

Cada capítulo se basa en el anterior para mantener una coherencia narrativa y técnica continua, proporcionando la profundidad analítica necesaria para validar tanto las contribuciones científicas como las prácticas de esta investigación, asegurando que el documento funcione como un recurso para académicos, profesionales y desarrolladores interesados en la detección automatizada de desinformación.

Capítulo 2

Marco Teórico

Esta sección describe las bases teóricas que sustentan las dos metodologías de detección de noticias falsas desarrolladas en este proyecto. Aunque las técnicas son aplicables a otros tipos de fraude digital, el enfoque se centra en la detección de desinformación periodística. Se abordan desde las técnicas clásicas de representación de texto y optimización metaheurística hasta los paradigmas de aprendizaje profundo que definen el estado del arte actual.

2.1. Detección de noticias falsas: fundamentos y extensibilidad

La detección de noticias falsas es un problema multifacético que requiere un enfoque interdisciplinario, con metodologías que pueden extenderse a otros tipos de fraude digital. La desinformación se define como información deliberadamente falsa o engañosa presentada como noticia legítima [1]. Esta problemática ha evolucionado con la aparición de las redes sociales y los medios digitales, donde la velocidad de propagación supera la capacidad de verificación tradicional.

En el contexto de la detección automatizada, se han explorado diversos enfoques. Das et al. [21] propusieron un marco de ensamblaje basado en incertidumbre e impulsado por heurísticas para detectar noticias falsas en tuits y artículos. Este enfoque parte de la premisa de que diferentes modelos poseen distintas fortalezas y que una combinación inteligente de predictores puede superar las limitaciones individuales. El equipo de la Southern Methodist University presentó una solución pionera que utiliza procesamiento de lenguaje natural y aprendizaje profundo para analizar tanto titulares como el contenido completo de las noticias [22]. Su trabajo demostró la viabilidad de combinar la vectorización TF-IDF con redes neuronales densas. Adicionalmente, se ha propuesto un enfoque basado en análisis estilométrico que utiliza Procesamiento del Lenguaje Natural (PLN) y Reconocimiento de Entidades Nombradas (NER) para identificar patrones lingüísticos que sugieran baja veracidad [15]. Este método se basa en la hipótesis de que los autores de contenido falso exhiben patrones de escritura distintivos.

La rápida propagación de noticias falsas en redes sociales puede tener graves consecuencias sociales. Como documentan Ali y Zain-Ul-Abdin [3], la desinformación puede distorsionar la realidad alterando la percepción pública de eventos y hechos, manipular la opinión pública influenciando procesos democráticos y decisiones sociales, incitar a la violencia promoviendo comportamientos agresivos basados en información errónea, difundir propaganda política siendo utilizada como herramienta de influencia partidista, fomentar el odio intensificando divisiones sociales y promoviendo la discriminación, y provocar pánico especialmente en crisis sanitarias como la pandemia de COVID-19 [4]. La investigación de Ali et al. [5] demuestra que las heurísticas cognitivas humanas, como la popularidad social (número de “me gusta” o compartidos), influyen de manera significativa en la percepción de credibilidad. Este fenómeno complica la detección, ya que el contenido falso puede volverse viral precisamente al aprovechar estos sesgos cognitivos.

2.1.1. Diferenciación técnica y transferibilidad metodológica

Es necesario establecer una distinción técnica clara entre los dominios de aplicación. Aunque comparten características computacionales, representan problemas con diferentes objetivos, audiencias y patrones, como expone la Tabla 2.1. El objetivo primario de las noticias falsas es la manipulación de opinión pública e influencia política o social, presentadas en formato de artículos periodísticos que imitan medios legítimos, dirigidas a consumidores de noticias y votantes, midiendo su éxito por viralidad y alcance, y utilizando indicadores lingüísticos como la imitación del estilo periodístico, fuentes falsas y sensacionalismo político asociado a eventos actuales. Por otro lado, el fraude digital busca beneficio económico ilícito y acceso no autorizado a recursos, manifestándose en emails de phishing, anuncios de inversión y ofertas comerciales dirigidas a potenciales víctimas económicas y usuarios con activos digitales, midiendo su éxito por la cantidad de dinero o información obtenida, empleando indicadores lingüísticos de urgencia económica, ofertas “limitadas” y solicitudes de información personal de manera atemporal, aprovechando tendencias económicas.

Aspecto	Noticias Falsas	Fraude Digital
Objetivo primario	Manipulación de opinión pública, influencia política/social	Beneficio económico ilícito, acceso no autorizado a recursos
Formato típico	Artículos periodísticos, imitando medios legítimos	Emails de phishing, anuncios de inversión, ofertas comerciales
Audiencia objetivo	Consumidores de noticias, votantes, opinión pública general	Potenciales víctimas económicas, usuarios con activos digitales
Métrica de éxito	Viralidad, alcance, influencia en opinión	Cantidad de dinero/información obtenida
Indicadores lingüísticos	Imitación de estilo periodístico, fuentes falsas, sensacionalismo político	Urgencia económica, ofertas “limitadas”, solicitudes de información personal
Temporalidad	Eventos actuales, ciclos noticiosos	Atemporales, aprovechan tendencias económicas

Tabla 2.1: Diferencias técnicas entre dominios de desinformación

A pesar de sus diferencias, ambos dominios comparten características computacio-

nales que justifican la transferibilidad de la metodología: ambos se basan en contenido textual como principal vector de engaño, se reducen a problemas de clasificación binaria legítimo/malicioso, pueden exhibir patrones lingüísticos distintivos (características estilométricas), se benefician de técnicas de calibración metaheurística para la optimización de hiperparámetros, y utilizan las mismas métricas estándar de clasificación (precisión, recall, F1-Score) para su evaluación.

Para aplicar la metodología a la detección de fraude digital, se requiere un protocolo sistemático que incluye: (1) construcción de un corpus específico recopilando y etiquetando datos representativos del tipo de fraude objetivo; (2) ajuste del preprocesamiento adaptando las técnicas de limpieza textual al nuevo dominio; (3) re-calibración de hiperparámetros mediante la re-optimización de los algoritmos metaheurísticos para el nuevo corpus; (4) incorporación de características específicas del dominio como URLs sospechosas o patrones de urgencia temporal; y (5) validación cruzada en diferentes dominios evaluando la transferencia con métricas de generalización. Este proyecto valida la metodología en el dominio de noticias falsas en español, sentando las bases para su transferencia a otros fraudes digitales. La elección de este dominio se justifica por la disponibilidad de corpus, su relevancia social y una menor complejidad técnica inicial que permite establecer una línea base sólida.

2.2. Representación de texto: de TF-IDF a Embeddings Contextuales

La evolución de las técnicas de representación textual ha sido clave para el progreso en PLN. Esta sección abarca desde métodos clásicos hasta las representaciones más sofisticadas usadas en esta tesis.

2.2.1. Evolución de métodos clásicos: Bag of Words y TF-IDF

El modelo de Bolsa de Palabras (Bag of Words) (Bag of Words, BoW) es un enfoque muy común en el procesamiento de texto. Aunque no se utilizó en los modelos finales de esta tesis, fue el primer acercamiento explorado en la investigación preliminar [23]. El modelo BoW representa un documento como una colección desordenada de sus palabras, ignorando la gramática y el orden, pero manteniendo la frecuencia de cada término. Matemáticamente, un documento d se representa como un vector de frecuencias $\text{BoW}(d) = [f_1, f_2, \dots, f_V]$, donde f_i es la frecuencia del término i en el documento y V es el tamaño del vocabulario.

El proceso de construcción implica cuatro etapas secuenciales: tokenización para dividir el texto en unidades léxicas, construcción del vocabulario creando un diccionario con todos los términos únicos, vectorización convirtiendo cada documento en un vector dimensional, y conteo de frecuencias asignando la frecuencia del término a cada posición del vector. El modelo BoW ofreció ventajas en las primeras fases de la investigación por su simplicidad conceptual siendo fácil de implementar y compren-

der, eficiencia computacional con bajo costo de procesamiento para corpus pequeños, transparencia mediante interpretabilidad directa de las características, y al proporcionar una línea base sólida como punto de partida para comparaciones.

Sin embargo, la experiencia con BoW reveló limitaciones fundamentales que motivaron la evolución hacia enfoques más sofisticados: pérdida total del orden con imposibilidad de capturar patrones secuenciales, ausencia de ponderación semántica tratando todas las palabras por igual, problemas de escalabilidad debido al crecimiento exponencial de la dimensionalidad, y sensibilidad a palabras vacías con dominancia de términos frecuentes pero poco informativos.

TF-IDF representa una evolución natural de BoW al introducir una ponderación semántica. A pesar de su simplicidad relativa, ha demostrado ser muy eficaz en tareas de clasificación. El proceso implica dos componentes principales: construcción del vocabulario creando un diccionario con todas las palabras únicas del corpus, y cálculo de ponderaciones asignando a cada término un peso basado en su frecuencia en el documento (TF) y su rareza en el corpus (IDF). Aunque este método ignora la gramática y el orden de las palabras, fue muy importante en los primeros trabajos de clasificación de noticias en español [11].

TF-IDF se define matemáticamente como $\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D)$, donde la Frecuencia de Término se calcula como $\text{TF}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$ representando la frecuencia relativa del término t en el documento d , y la Frecuencia Inversa de Documento como $\text{IDF}(t, D) = \log \frac{|D|}{|\{d \in D: t \in d\}|}$ capturando la importancia global del término en la colección. Esta ponderación asigna mayor peso a los términos frecuentes en un documento pero raros en el corpus general, mejorando así la capacidad discriminativa del modelo [22].

Los enfoques basados en TF-IDF presentan limitaciones esenciales: pérdida de información secuencial al no capturar el orden ni la estructura sintáctica, problema de dispersidad generando representaciones muy dispersas en vocabularios grandes, ausencia de semántica al no modelar relaciones semánticas entre palabras, y falta de contexto donde una palabra tiene la misma representación sin importar su contexto de uso. La transición de BoW a TF-IDF representó un primer refinamiento al introducir una ponderación semántica. Esta evolución, documentada en el marco de optimización metaheurística [23], sentó las bases para los enfoques más avanzados de esta tesis. A pesar de sus limitaciones, el modelo BoW fue útil para identificar patrones distintivos en textos en español, sirviendo como punto de partida para las dos metodologías principales de esta investigación.

2.3. La revolución Transformer y los Modelos de Lenguaje modernos

2.3.1. Arquitectura Transformer y mecanismos de atención

La arquitectura Transformer, introducida por Vaswani et al. [24], revolucionó el PLN con su mecanismo de **auto-atención (self-attention)**. Esta innovación permite al modelo calcular representaciones ponderando dinámicamente la importancia de cada elemento de una secuencia en relación con los demás. El mecanismo de atención se define matemáticamente como $\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$, donde Q , K y V son las matrices de consultas, claves y valores. La atención multi-cabeza extiende este concepto mediante $\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$, permitiendo capturar diferentes tipos de relaciones lingüísticas simultáneamente y superando las limitaciones de los modelos secuenciales previos.

BERT (Bidirectional Encoder Representations from Transformers) [25] introdujo el paradigma de preentrenamiento bidireccional. Al entrenar el modelo para predecir palabras enmascaradas considerando el contexto de ambos lados, genera representaciones contextuales más ricas. El éxito de BERT motivó el desarrollo de variantes más eficientes: DistilBERT [20] reduce el tamaño del modelo en un 40 % manteniendo el 97 % de su rendimiento y está disponible en español, mientras que TinyBERT [26] crea modelos aún más compactos, aunque su disponibilidad se limita al inglés.

Para el español se han desarrollado modelos y evaluaciones especializadas. Martínez-Gallego et al. [27] exploraron la aplicación de BERT y BETO (BERT en español) para la detección de desinformación. Blanco-Fernández et al. [13] compararon sistemáticamente BERT y RoBERTa para la detección de desinformación política, proporcionando evidencia empírica sobre su efectividad en este dominio. Shushkevich et al. [28] investigaron el uso de datos aumentados con ChatGPT para mejorar la clasificación multiclase, demostrando que la generación sintética de datos puede mejorar la robustez de los modelos.

2.3.2. Corpus de pre-entrenamiento y especialización lingüística

La efectividad de los modelos de lenguaje preentrenados está intrínsecamente vinculada a la calidad, diversidad y relevancia de los corpus utilizados durante su fase de pre-entrenamiento. Esta subsección detalla las características de los corpus que fundamentan los modelos empleados en esta investigación.

BERT base [25] fue pre-entrenado sobre dos corpus masivos en inglés: **Books-Corpus** conteniendo más de 800 millones de palabras extraídas de 11,038 libros no publicados de diversos géneros, proporcionando exposición a narrativas largas y coherentes con estructuras lingüísticas complejas, y **English Wikipedia** con aproximadamente 2,500 millones de palabras de artículos enciclopédicos, ofreciendo conocimiento factual diverso y lenguaje formal bien estructurado. El pre-entrenamiento utilizó dos

tareas auto-supervisadas: *Masked Language Modeling* (MLM) donde el 15 % de los tokens son enmascarados y el modelo debe predecirlos basándose en el contexto bidireccional, y *Next Sentence Prediction* (NSP) entrenando al modelo para predecir si una oración sigue naturalmente a otra, capturando relaciones entre oraciones.

DistilBERT multilingüe [20], el modelo seleccionado para esta investigación, hereda el conocimiento de BERT mediante destilación de conocimiento pero fue entrenado sobre un corpus multilingüe significativamente más diverso. El corpus de pre-entrenamiento incluyó **Wikipedia multilingüe** con más de 100 idiomas representados incluyendo español con aproximadamente 1.6 millones de artículos, contenido total superior a 2.5 terabytes de texto limpio, y cobertura balanceada que garantiza representación significativa de idiomas no anglosajones. La metodología de pre-entrenamiento preservó la tarea MLM de BERT pero eliminó NSP para simplificación y eficiencia, aplicó destilación de conocimiento triple mediante pérdida de destilación supervisando las salidas del modelo estudiante con las del profesor, pérdida de enmascaramiento de lenguaje manteniendo la tarea MLM original, y pérdida de similitud coseno alineando las representaciones ocultas entre estudiante y profesor.

Las características específicas para español en DistilBERT multilingüe incluyen vocabulario compartido mediante tokenizador WordPiece con 110,000 tokens compartidos entre todos los idiomas, proporcionando transferencia de conocimiento cross-lingual donde el aprendizaje en un idioma beneficia a otros debido a representaciones compartidas, y especialización implícita donde aunque no hay entrenamiento exclusivo en español, la arquitectura Transformer aprende patrones lingüísticos específicos mediante exposición a millones de oraciones en español durante el pre-entrenamiento.

La decisión de utilizar DistilBERT multilingüe en lugar de variantes monolingües se fundamenta en disponibilidad y madurez donde es el modelo destilado multilingüe más estable y ampliamente validado, eficiencia comprobada manteniendo 97 % del rendimiento de BERT con 40 % menos parámetros validado empíricamente en múltiples benchmarks, soporte nativo para español sin necesidad de adaptación adicional o tokenizadores especializados, y integración con ecosistema mediante compatibilidad total con Hugging Face Transformers facilitando implementación.

Modelos alternativos considerados pero no seleccionados incluyen **BETO** (BERT en Español) pre-entrenado exclusivamente sobre 3 mil millones de palabras del corpus OPUS de traducciones y Wikipedia en español, ofreciendo especialización en español pero con limitación de tamaño del corpus comparado con DistilBERT multilingüe y mayor costo computacional al ser modelo completo no destilado; **RoBERTa en español** con arquitectura más robusta pero similar al corpus de BETO ofreciendo rendimiento marginalmente superior pero sin justificar el incremento del 60 % en tiempo de entrenamiento y requerimientos de memoria; y **mBERT** (multilingual BERT) con 104 idiomas soportados pero siendo significativamente más grande (180M parámetros vs 134M de DistilBERT) resultando en menor eficiencia computacional sin mejoras proporcionales en rendimiento para la tarea específica de detección de noticias falsas.

La Tabla 2.2 presenta una comparación sistemática de los corpus de pre-entrenamiento

utilizados por los principales modelos de lenguaje considerados en esta investigación.

Modelo	Corpus Principal	Tamaño Aprox.	Idiomas	Características Relevantes
BERT base	BooksCorpus English Wikipedia	800M palabras 2.5B palabras	Solo inglés	Narrativas largas Conocimiento enciclopédico
DistilBERT multilingüe	Wikipedia multilingüe	>2.5TB texto	104 idiomas	Incluye 1.6M artículos en español Destilación triple Vocabulario compartido 110K tokens
BETO	OPUS corpus Wikipedia español	3B palabras	Solo español	Especialización en español Sin destilación
RoBERTa español	Similar a BETO	3B palabras	Solo español	Arquitectura optimizada Mayor costo computacional
mBERT	Wikipedia multilingüe	>3TB texto	104 idiomas	Modelo completo no destilado 180M parámetros

Tabla 2.2: Comparación de corpus de pre-entrenamiento para modelos de lenguaje considerados en esta investigación.

La validación de la elección de DistilBERT multilingüe se sustenta en evidencia empírica documentada en la literatura. Sanh et al. [20] demostraron mediante evaluaciones extensivas en múltiples benchmarks (GLUE, SQuAD) que DistilBERT mantiene 97% del rendimiento de BERT en tareas de comprensión del lenguaje natural, con reducción del 40% en tamaño del modelo y aceleración del 60% en inferencia. Estudios específicos para español [13] confirmaron que modelos multilingües como DistilBERT alcanzan rendimiento comparable a modelos monolingües especializados en tareas de detección de desinformación, con la ventaja adicional de mayor eficiencia computacional. La transferencia de conocimiento cross-lingual inherente en modelos multilingües ha demostrado beneficiar idiomas con recursos limitados al aprovechar patrones aprendidos de idiomas con corpus más abundantes.

En el contexto específico de esta investigación, la selección de DistilBERT multilingüe optimiza el balance entre rendimiento (capacidad de detectar patrones complejos en español), eficiencia (recursos computacionales accesibles para entrenamiento), y generalización (robustez ante diferentes variantes del español multiregional). El corpus de pre-entrenamiento multilingüe, aunque no exclusivo del español, proporciona exposición suficiente a estructuras lingüísticas del español para capturar dependencias semánticas y sintácticas relevantes para la detección de noticias falsas, mientras mantiene la eficiencia necesaria para experimentos iterativos de optimización de hiperparámetros.

2.3.3. Grandes Modelos de Lenguaje y su doble rol en detección

GPT-3 [17] demostró la capacidad de aprendizaje con pocos ejemplos (*few-shot learning*), mostrando que los modelos a gran escala pueden realizar tareas sin un ajuste fino específico. LLaMA [29] busca democratizar el acceso a modelos de gran escala, ofreciendo alternativas de código abierto con un rendimiento competitivo y menor costo computacional. Gemini [30] introduce capacidades multimodales nativas, procesando texto, imágenes y audio de forma integrada, lo cual es relevante para la detección de desinformación multimedia. El trabajo sobre IA Constitucional [31]

aborda la alineación y seguridad de los LLMs, estableciendo principios para entrenar modelos más seguros y alineados con valores humanos.

La investigación reciente revela el doble rol crítico de los LLMs en el ecosistema de la desinformación. Como “buenos consejeros”, pueden ser ajustados para detectar noticias falsas con alta precisión [2], aprovechando su profunda comprensión del lenguaje y contexto. Sin embargo, como “malos actores”, pueden generar desinformación convincente que complica significativamente su detección [6], creando un escenario de carrera armamentista tecnológica. Esta dualidad implica que los sistemas de detección deben adaptarse continuamente a la era de los LLMs [16], requiriendo estrategias que puedan identificar tanto contenido humano como sintético generado por IA.

El paradigma de **fine-tuning**, introducido por Howard y Ruder [32], ha sido una innovación significativa. Consiste en tomar un modelo preentrenado y continuar su entrenamiento con datos específicos del dominio objetivo. En modelos Transformer como BERT [33], esto implica ajustar las capas superiores para la tarea específica de clasificación. La efectividad de este enfoque radica en que las representaciones contextuales aprendidas durante el preentrenamiento son transferibles a otras tareas [34]. Para la detección de noticias falsas, esto constituye la base del segundo enfoque desarrollado en esta investigación.

2.4. Optimización metaheurística en la detección de fraude

2.4.1. Fundamentos y arquitectura del sistema metaheurístico

Las metaheurísticas son estrategias de optimización de alto nivel que guían la búsqueda de soluciones de alta calidad en espacios complejos. A diferencia de los algoritmos exactos, buscan soluciones “suficientemente buenas” en un tiempo computacional razonable [35]. La aplicación de metaheurísticas en este dominio se justifica por cinco factores fundamentales: los modelos de clasificación tienen múltiples hiperparámetros interdependientes creando un espacio de hiperparámetros complejo, las métricas de rendimiento no son funciones continuas y diferenciables constituyendo una función objetivo no convexa, los hiperparámetros interactúan de manera compleja con interacciones no lineales, el espacio de búsqueda puede atrapar algoritmos determinísticos en múltiples óptimos locales, y exploran el espacio de forma más inteligente que los métodos exhaustivos proporcionando eficiencia computacional.

El marco de trabajo metaheurístico desarrollado sigue una arquitectura modular que puede expresarse como $\text{Sistema} = \{D, P, A, F, E\}$, donde D representa el dataset de noticias preprocesado, P la tubería de preprocesamiento (tokenización, TF-IDF), A el algoritmo metaheurístico (GA, PSO, SA, VNS, SS), F la función objetivo (F1-Score en validación cruzada), y E el evaluador final en el conjunto de prueba. El sistema recibe como entrada un corpus textual de noticias en español con etiquetas binarias (REAL/FALSO), una división de datos estratificada de 70 % entrenamiento,

10 % validación y 20 % prueba, y una representación TF-IDF que genera una matriz dispersa de dimensión $n \times v$. Los algoritmos metaheurísticos optimizan conjuntos de hiperparámetros, incluyendo para TF-IDF: $\text{max_features} \in [1000, 50000]$ controlando el tamaño del vocabulario, $\text{min_df} \in [1, 10]$ estableciendo la frecuencia mínima de documento, $\text{max_df} \in [0.7, 1.0]$ definiendo la frecuencia máxima de documento, y $\text{ngram_range} \in \{(1, 1), (1, 2), (1, 3)\}$ determinando el rango de n-gramas.

El preprocesamiento sigue un flujo de tres etapas secuenciales. La Etapa 1 de limpieza textual incluye normalización de caracteres mediante conversión a minúsculas y eliminación de acentos, filtrado de contenido eliminando URLs, menciones y hash-tags, tokenización para dividir en tokens, eliminación de stopwords filtrando palabras vacías, y validación de longitud excluyendo textos demasiado cortos. La Etapa 2 implementa la vectorización TF-IDF mediante $\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log\left(\frac{N}{|\{d': t \in d'\}|}\right)$. La Etapa 3 aplica normalización L2 para estabilizar el entrenamiento mediante $\mathbf{x}_{\text{norm}} = \frac{\mathbf{x}}{\|\mathbf{x}\|_2}$.

2.4.2. Algoritmos metaheurísticos implementados

Se implementaron cinco algoritmos metaheurísticos representativos de diferentes paradigmas. El **Algoritmo Genético (GA)**, inspirado en la evolución natural, representa cada individuo como un vector de hiperparámetros.

$$\text{Individuo} = [C, \gamma, \text{max_features}, \text{min_df}, \text{max_df}, \text{ngram}]$$

Utiliza operadores genéticos de selección por torneo, cruce uniforme, mutación gaussiana y elitismo, con parámetros de tamaño de población 30, 50 generaciones, tasa de cruce 0.8 y tasa de mutación 0.1.

La **Optimización por Enjambre de Partículas (PSO)**, inspirada en el comportamiento de bandadas, emplea ecuaciones de movimiento $v_i^{t+1} = w \cdot v_i^t + c_1 \cdot r_1 \cdot (p_i - x_i^t) + c_2 \cdot r_2 \cdot (g - x_i^t)$ y $x_i^{t+1} = x_i^t + v_i^{t+1}$, con parámetros de 30 partículas, 50 iteraciones, factor de inercia 0.9 y factores de aceleración 2.0.

El **Recocido Simulado Multi-arranque (MSA)**, inspirado en el proceso de enfriamiento en metalurgia, utiliza un criterio de aceptación $P(\text{aceptar}) = \begin{cases} 1 & \text{si } \Delta f \geq 0 \\ e^{\frac{\Delta f}{T}} & \text{si } \Delta f < 0 \end{cases}$

y un esquema de enfriamiento $T_{k+1} = \alpha \cdot T_k$ con $\alpha = 0.95$, configurado con temperatura inicial 100.0, temperatura final 0.01, factor de enfriamiento 0.95, 10 iteraciones por temperatura y 5 arranques múltiples.

La **Búsqueda en Vecindades Variables (VNS)** emplea el principio de cambio sistemático de estructuras de vecindad mediante perturbación de uno, dos o todos los hiperparámetros, explorando sistemáticamente cada vecindad y reiniciando la búsqueda al encontrar una mejora. La **Búsqueda Dispersa (SS)** combina soluciones de calidad para generar nuevas mediante un conjunto de referencia, generación de subconjuntos, método de combinación y mejora local.

El proceso de optimización se ejecuta en cuatro etapas. La Etapa 1 de inicialización carga y divide el dataset, define los espacios de búsqueda, inicializa la población o enjambre, y configura los parámetros del algoritmo. La Etapa 2 de evaluación de aptitud construye el pipeline TF-IDF + Clasificador para cada configuración, entrena en el conjunto de entrenamiento, evalúa con validación cruzada y calcula el F1-Score promedio como fitness. La Etapa 3 de evolución/optimización aplica los operadores del algoritmo, genera nuevas configuraciones, evalúa su fitness, actualiza la población o enjambre y verifica criterios de convergencia. La Etapa 4 de selección final identifica la mejor configuración, re-entrena el modelo con ella, evalúa en el conjunto de prueba y reporta las métricas finales.

La función objetivo principal se define como $f(\theta) = \text{F1-Score}_{CV}(\theta)$, donde θ es el vector de hiperparámetros y F1-Score_{CV} es el F1-Score promedio en validación cruzada. Las métricas de evaluación secundarias incluyen Precisión = $\frac{TP}{TP+FP}$, Recall = $\frac{TP}{TP+FN}$, F1-Score = $\frac{2 \times \text{Precisión} \times \text{Recall}}{\text{Precisión} + \text{Recall}}$, y Exactitud = $\frac{TP+TN}{TP+TN+FP+FN}$.

El sistema genera cuatro tipos de salidas: configuración óptima de hiperparámetros con valores óptimos, historia de convergencia, número de evaluaciones y tiempo de optimización; modelo entrenado optimizado incluyendo vectorizador TF-IDF configurado, clasificador entrenado y pipeline completo listo para predicción; métricas de rendimiento con F1-Score, Precisión, Recall, Exactitud en el conjunto de prueba, matriz de confusión, curvas de convergencia y análisis de la importancia de los hiperparámetros; y análisis comparativo entre los algoritmos metaheurísticos, análisis de eficiencia computacional y estudio de robustez y estabilidad.

2.4.3. Comparación, justificación y aplicaciones

La Tabla 2.3 presenta una comparación sistemática de los cinco algoritmos implementados, destacando sus inspiraciones, fortalezas, limitaciones y parámetros clave. La selección de estos algoritmos se basó en cinco criterios: diversidad de paradigmas incluyendo representantes de las principales familias de metaheurísticas, eficiencia computacional con algoritmos que balancean calidad y tiempo de cómputo, robustez empírica mediante métodos con efectividad documentada en problemas de optimización de ML, implementación práctica usando algoritmos con parámetros bien establecidos, y complementariedad mediante enfoques que exploran el espacio de búsqueda de maneras diferentes. Esta selección permite comparar diferentes estrategias y determinar cuáles son más efectivas para la calibración de detectores de noticias falsas.

Las metaheurísticas implementadas superan métodos alternativos en varios aspectos. Frente a la búsqueda en cuadrícula (Grid search), las metaheurísticas ofrecen eficiencia ya que Grid search es computacionalmente inviable para espacios de alta dimensión, y manejan parámetros continuos de forma natural permitiendo optimización continua. Comparadas con la búsqueda aleatoria (Random Search), proporcionan inteligencia dirigida al aprender de las evaluaciones previas para guiar la búsqueda de manera adaptativa. Frente a la optimización Bayesiana, las metaheurísticas ofrecen

Algoritmo	Inspiración	Fortalezas	Limitaciones	Parámetros Clave
GA	Evolución biológica	Exploración global robusta Paralelización natural Buena diversidad poblacional	Convergencia lenta Muchos parámetros a ajustar Puede estancarse prematuramente	Población: 30 Generaciones: 50 Cruce: 0.8 Mutación: 0.1
PSO	Comportamiento de enjambre	Convergencia rápida Pocos parámetros Fácil implementación	Puede convergir prematuramente Sensible a parámetros Exploración limitada	Partículas: 30 Iteraciones: 50 Inercia: 0.9 Aceleración: 2.0
SA/MSA	Recocido de metales	Escape de óptimos locales Base teórica sólida Múltiples arranques	Esquema de enfriamiento crítico Búsqueda individual Muchas evaluaciones	T inicial: 100 T final: 0.01 Enfriamiento: 0.95 Arranques: 5
VNS	Cambio sistemático de vecindades	Escape sistemático de óptimos Combinación exploración/explotación Flexibilidad en vecindades	Dependiente de definición de vecindades Puede ser costoso computacionalmente Diseño específico del problema	Vecindades: 3 Iteraciones: 100 Búsqueda local: Hill climbing
SS	Combinación de soluciones de calidad	Balance calidad-diversidad Intensificación y diversificación Memoria adaptativa	Complejo de implementar Muchos componentes Sensible a tamaño de referencia	Ref. Set: 10 Combinaciones: todas Mejora: local search Actualizaciones: dinámicas

Tabla 2.3: Comparación de algoritmos metaheurísticos implementados

mayor flexibilidad para restricciones complejas y espacios de búsqueda no convencionales. Comparadas con métodos basados en gradiente, no requieren diferenciabilidad de las métricas de clasificación ni restricciones sobre la naturaleza discreta de algunos hiperparámetros.

La implementación práctica consideró tres aspectos críticos. Para el manejo de memoria se utilizaron matrices dispersas y procesamiento por lotes para manejar el corpus de gran escala. La paralelización se implementó mediante evaluación paralela de individuos y vectorización de operaciones para aprovechar recursos computacionales. La validación y robustez se garantizó usando validación cruzada estratificada y múltiples ejecuciones para el análisis estadístico, asegurando resultados confiables y reproducibles.

La Figura 2.1 ilustra el flujo completo del proceso de optimización, garantizando reproducibilidad mediante protocolos estandarizados y documentación completa, escalabilidad para corpus de diferentes tamaños y dominios, transferibilidad adaptando el protocolo a otros tipos de fraude digital, y transparencia con trazabilidad completa de decisiones y evaluaciones.




Figura 2.1: Flujo del proceso de optimización metaheurística para la detección de noticias falsas.

2.4.4. Aplicaciones documentadas en detección de fraude

Las metaheurísticas han demostrado efectividad en diversas aplicaciones de detección de fraude. Aqil y Lahby [36] modelaron la detección de noticias falsas como un problema de FSSP (Flexible Shop Scheduling Problem), comparando tres metaheurísticas y encontrando que el algoritmo Voraz Iterativo (IG) lograba el mejor rendimiento, demostrando la viabilidad de enfoques no convencionales. Bacanin et al. [37] demostraron los beneficios de usar metaheurísticas para la calibración de hiperparámetros en modelos de *deep learning*, mostrando mejoras significativas sobre métodos tradicionales como Grid Search y Random Search. La investigación publicada en [23] aborda específicamente la calibración de hiperparámetros para la detección de fraude digital, proporcionando un marco conceptual y experimental relevante para esta tesis. Das et al. [21] desarrollaron un marco de ensamble que combina modelos preentrenados, características estadísticas y heurísticas de incertidumbre, logrando F1-scores superiores al 95 % en múltiples datasets de referencia.

En el ámbito del fraude financiero, Hidayattullah et al. [38] aplicaron metaheurísticas para optimizar la detección de fraude en estados financieros considerando múltiples objetivos (precisión, eficiencia y robustez), mostrando que un SVM optimizado con Algoritmo Genético alcanzó una precisión del 96.15 %. Horak y Sabek [39] exploraron la optimización de hiperparámetros en *Gaussian Process Regression* para la predicción de dificultades financieras, destacando la importancia de la calibración metaheurística en contextos de alta incertidumbre. Los algoritmos híbridos modernos también han mostrado promesa: Yildirim [40] propuso un enfoque metaheurístico híbrido *multi-thread* que optimiza simultáneamente la selección de características, los parámetros del clasificador y la arquitectura del ensamble, mientras que Deshai y Bhaskara Rao [41] desarrollaron un enfoque de CNN con PSO adaptativo para detectar reseñas falsas, ajustando dinámicamente los parámetros del algoritmo según el progreso de la búsqueda.

2.5. Síntesis del marco teórico

La tendencia actual en la detección de noticias falsas favorece los sistemas híbridos que combinan múltiples paradigmas. Este marco teórico establece los fundamentos para las dos metodologías desarrolladas en esta tesis: el enfoque clásico optimizado que utiliza representaciones TF-IDF con optimización metaheurística de hiperparámetros, y el enfoque de *deep learning* que emplea modelos Transformer preentrenados con *fine-tuning*. La integración de ambos enfoques, sustentada en la literatura revisada, establece la base teórica para la contribución metodológica de esta tesis: la aplicación sistemática de la optimización de hiperparámetros en ambos paradigmas, en el contexto específico de textos en español, proporcionando una comparación rigurosa que permite identificar las fortalezas y limitaciones de cada enfoque en un dominio históricamente desatendido por la investigación en PLN.

Capítulo 3

Estado del arte

La detección de noticias falsas constituye un campo activo de investigación dentro del procesamiento de lenguaje natural (PLN). Este campo multidisciplinario abarca desde la ciencia de la computación hasta la psicología cognitiva. En años recientes, los investigadores han desarrollado enfoques innovadores que van desde técnicas tradicionales de procesamiento de lenguaje natural hasta modelos de lenguaje preentrenados de última generación. Estos avances responden a la creciente sofisticación de las campañas de desinformación y la velocidad sin precedentes con la que se propagan en las redes sociales.

En el contexto hispanohablante, esta problemática adquiere características particulares debido a las especificidades lingüísticas y culturales del español. La complejidad del idioma, con sus múltiples variantes geográficas y ricas estructuras sintácticas, presenta desafíos únicos para los sistemas automatizados de detección, que tradicionalmente han sido desarrollados y entrenados principalmente para el inglés. Este capítulo examina las principales contribuciones científicas en el campo de la detección de desinformación, con especial énfasis en las aproximaciones que combinan técnicas de optimización metaheurística con modelos de aprendizaje automático. Se analiza también la evolución de los enfoques metodológicos, desde los primeros sistemas basados en características superficiales hasta los desarrollos más recientes que incorporan arquitecturas Transformer y algoritmos de optimización bioinspirados.

3.1. Metodología de búsqueda bibliográfica

Para garantizar una revisión completa y actualizada de la literatura científica, se diseñó una estrategia de búsqueda en múltiples bases de datos académicas reconocidas internacionalmente. El proceso se llevó a cabo entre agosto de 2023 y agosto de 2025, utilizando una combinación de términos clave y operadores booleanos para maximizar la relevancia de los resultados. Las bases de datos consultadas incluyeron Google Scholar, Semantic Scholar, Nature Digital Libraries, IOPscience, MDPI, Web of Science (WoS) y repositorios especializados como arXiv. La selección de estas fuentes se basó en su cobertura disciplinaria, calidad editorial y relevancia para el campo.

Adicionalmente, se incluyeron conferencias especializadas como ACL, EMNLP y talleres como CheckThat! para capturar los desarrollos más recientes.

La búsqueda se estructuró en torno a combinaciones de términos que reflejan las dimensiones de esta investigación: *Spanish fake news detection* y “detección de noticias falsas en español” para trabajos específicos del idioma; *Fake news detection language models* cubriendo términos como BERT, RoBERTa y Transformer para arquitecturas modernas; *Metaheuristic hyperparameter optimization* para identificar aplicaciones en aprendizaje automático; *Employment fraud detection* para abarcar el dominio del fraude laboral; *Simulated annealing fake news* y *Genetic algorithm text classification* para enfoques de optimización específicos; *Social media misinformation detection* para trabajos enfocados en plataformas sociales; y *Cross-lingual fake news* y *multilingual misinformation* para incluir enfoques multilingües.

Se priorizaron publicaciones de los últimos cinco años (2020-2025), sin excluir trabajos relevantes anteriores. Los criterios de inclusión fueron: contribuciones metodológicas originales, validación empírica robusta, relevancia directa para la detección de desinformación y calidad de la revisión por pares. Como resultado, se identificaron 86 trabajos que constituyen el núcleo de esta revisión, representando una cobertura comprehensiva del estado actual del conocimiento en el campo.

3.2. Panorama de la investigación en detección de noticias falsas

El campo de la detección automatizada de desinformación ha evolucionado rápidamente, transitando desde enfoques basados en características estadísticas simples hacia sistemas sofisticados que integran múltiples modalidades y conocimiento contextual profundo. Esta evolución refleja tanto los avances en inteligencia artificial como la creciente complejidad de las técnicas de desinformación. La progresión del campo puede dividirse en tres fases: **la era pionera (2010-2016)** con enfoques basados en características lingüísticas superficiales y aprendizaje automático tradicional; **la era de los modelos profundos (2017-2020)** marcada por la adopción de redes neuronales y arquitecturas Transformer; y **la era contemporánea (2021-presente)** dominada por modelos de lenguaje a gran escala y enfoques híbridos [42].

3.2.1. Fundamentos metodológicos y construcción de corpus en español

La disponibilidad de conjuntos de datos de alta calidad es fundamental para cualquier sistema de detección eficaz. En el contexto hispanohablante, esta necesidad es crítica debido a la escasez de recursos en comparación con el inglés. Los trabajos pioneros en esta área han establecido las bases para la construcción y evaluación de corpus especializados, influyendo significativamente en el desarrollo del campo. Acosta [11] desarrolló uno de los primeros marcos sistemáticos para construir conjuntos

de datos de noticias en español, con criterios rigurosos de calidad y protocolos de etiquetado manual. Su metodología demostró la viabilidad de crear recursos lingüísticos a gran escala para el español. Por su parte, el trabajo de Posadas-Durán et al. [12] propuso un nuevo corpus con características estilométricas innovadoras, abriendo nuevas líneas de investigación sobre el estilo de escritura como indicador de veracidad.

La comunidad científica internacional ha impulsado iniciativas como los talleres CheckThat! en CLEF [43, 44], que proporcionan marcos estandarizados para la evaluación comparativa de sistemas. Un desafío clave es que los corpus disponibles no son homogéneos, ya que abordan diferentes aspectos del problema: detección binaria verdadero/falso, clasificación multiclase de tipos de desinformación, verificación de afirmaciones específicas y análisis de credibilidad de fuentes. En el ámbito iberoamericano, las competiciones IberLEF han sido fundamentales. Aragón et al. [45] documentaron los primeros esfuerzos para abordar la detección de noticias falsas en el español de México, estableciendo el **F1-Score como la métrica principal de comparación**. La estandarización de métricas ha sido crucial para el progreso del campo. Los marcos como CheckThat! [44] han establecido que las métricas fundamentales deben incluir Precisión, Recall (exhaustividad), F1-Score y Exactitud, permitiendo una comparación directa y reproducible entre diferentes sistemas.

Contribución Principal	Autores	Publicación	Año	Ref.
Marco metodológico para construcción de conjuntos de datos de noticias en español	Acosta, F. A. Z.	U. Politécnica de Madrid	2019	[11]
Evaluación multimodal y multigenre para verificación de contenido	Alam, F., et al.	CEUR Workshop Proc.	2023	[43]
Análisis de agresividad y desinformación en español mexicano	Aragón, M. E., et al.	IberLEF Workshop	2020	[45]
Marco estandarizado CheckThat! para evaluación de sistemas	Barrón-Cedeño, A., et al.	ECIR 2023	2023	[44]
Consolidación de métricas FakeDeS para detección en español	Gómez-Adorno, H., et al.	Procesamiento del Lenguaje Natural	2021	[46]
Corpus pionero con características estilométricas para español	Posadas-Durán, J. P., et al.	J. of Intelligent and Fuzzy Systems	2019	[12]
Corpus enriquecido con anotaciones multinivel versión 2.0	Ramírez Cruz, J. M., et al.	GitHub Repository	2021	[47]
Técnicas de aprendizaje automático aplicadas al español	Tretiakov, A., et al.	Springer	2022	[19]

Tabla 3.1: Contribuciones fundamentales en metodología y construcción de corpus para español.

3.2.2. Evolución de los Modelos de Lenguaje en la detección

La irrupción de los modelos de lenguaje preentrenados ha revolucionado la detección de noticias falsas. Esta transformación ha progresado desde arquitecturas básicas hacia sistemas sofisticados con una profunda comprensión contextual. El punto de inflexión fue la introducción de **BERT** [25], cuya arquitectura bidireccional permitió capturar dependencias contextuales de manera más efectiva que los modelos secuenciales anteriores. La capacidad de BERT para entender el contexto completo de una oración simultáneamente representó un avance que estableció el paradigma dominante

para los años siguientes.



Figura 3.1: Mapa Conceptual 3: Artículos relacionados que incorporan Modelos de Lenguaje.

La necesidad de modelos más eficientes llevó al desarrollo de variantes como **DistilBERT** [20], que mantiene el 97 % del rendimiento de BERT con solo el 60 % de sus parámetros mediante técnicas de destilación de conocimiento. Esta reducción de tamaño ha sido crucial para aplicaciones en tiempo real y dispositivos con recursos limitados. En el contexto del español, trabajos como el de Padilla Cuevas et al. [48] con **MédicoBERT** han demostrado el valor de adaptar modelos de lenguaje a dominios específicos, logrando una mejor comprensión del vocabulario técnico y patrones discursivos especializados.

El surgimiento de modelos generativos a gran escala como **GPT-3** [17] ha introducido nuevas complejidades en el panorama de la detección. Como señalan Papa-georgiou et al. [49], estos modelos presentan una dualidad fundamental: pueden tanto generar contenido falso indistinguible del humano como ser herramientas poderosas para su detección. Esta dualidad crea un escenario de carrera armamentista tecnológica donde los avances en generación impulsan simultáneamente mejoras en detección. Investigaciones recientes revelan que los detectores actuales muestran sesgos contra el texto generado por LLMs [6], lo que plantea cuestiones críticas sobre la generalización y equidad de estos sistemas en escenarios del mundo real.

3.2.3. Técnicas de optimización metaheurística aplicadas

La aplicación de algoritmos metaheurísticos a la detección de noticias falsas representa un área innovadora que aborda la complejidad inherente de la calibración

Innovación Principal	Autores	Publicación	Año	Ref.
Arquitectura bidireccional para comprensión contextual profunda	Devlin, J., et al.	arXiv	2018	[25]
Destilación de conocimiento para modelos eficientes	Sanh, V., et al.	arXiv	2019	[20]
Aplicación de transformers en español (MédicoBERT)	Padilla Cuevas, J., et al.	Applied Sciences	2024	[48]
Revisión sobre el uso de LLMs en noticias falsas	Papageorgiou, E., et al.	Future Internet	2024	[49]
Comparación BERT vs RoBERTa para español	Blanco-Fernández, Y., et al.	Applied Sciences	2024	[13]
Capacidades emergentes en modelos de gran escala	Brown, T. B., et al.	arXiv	2020	[17]
Modelos multimodales de próxima generación	Gemini Team, Google	arXiv	2023	[30]
El auge de los grandes Modelos de Lenguaje	Nature Comp. Science	Nature	2025	[42]

Tabla 3.2: Evolución de modelos de lenguaje aplicados a la detección de desinformación.

de hiperparámetros. Estos algoritmos son particularmente eficaces para resolver problemas de optimización donde el espacio de búsqueda es vasto, no convexo y contiene múltiples óptimos locales. Aqil y Lahby [36] fueron pioneros al modelar la tarea de detección como un problema de planificación de tareas flexible (FSSP), evaluando metaheurísticas como Algoritmos Genéticos, Colonia de Abejas y Búsqueda Iterativa para optimizar el procesamiento de documentos en sistemas de detección.

En el ámbito de las reseñas falsas, Deshai y Rao [41] combinaron redes neuronales convolucionales (CNN) con Optimización por Enjambre de Partículas adaptativo (PSO), demostrando que PSO puede optimizar eficazmente los hiperparámetros de las CNN mientras reduce significativamente el tiempo de búsqueda comparado con métodos exhaustivos. Su trabajo mostró mejoras consistentes en F1-Score del 3-5 % sobre configuraciones por defecto. Otros trabajos han explorado el uso de metaheurísticas para optimizar modelos de aprendizaje profundo en contextos de predicción energética [37] y para manejar la incertidumbre en la clasificación mediante marcos de ensamble [21], mostrando que la integración inteligente de múltiples predictores guiada por heurísticas puede superar significativamente el rendimiento de modelos individuales.

La diversificación hacia enfoques híbridos ha sido una tendencia creciente. La combinación de K-Means y SVM con metaheurísticas para la selección de características [50] ha demostrado que la integración de técnicas de clustering con optimización puede mejorar tanto la eficacia como la eficiencia de los detectores. En el contexto específico del español y el fraude digital, el trabajo de Hurtado Avilés et al. [23] proporciona un marco conceptual y experimental directamente relevante para esta tesis, validando la aplicabilidad de cinco algoritmos metaheurísticos diferentes en la calibración de detectores para corpus hispanohablantes.

Contribución Metodológica	Autores	Publicación	Año	Ref.
Formulación como problema de planificación de tareas	Aqil, S., & Lahby, M.	Studies in Comp. Intelligence	2021	[36]
PSO adaptativo para optimización de CNN en detección de reseñas	Deshai, N., & Rao, B. B.	Soft Computing	2023	[41]
Evidencia sistemática de beneficios en modelos de aprendizaje profundo	Bacanin, N., et al.	Energies	2023	[37]
Marco ensemble para manejo de incertidumbre	Das, S. D., et al.	Neurocomputing	2022	[21]
Aplicación específica para español y fraude digital	Hurtado Avilés, G., et al.	BUAP	2024	[23]
Enfoque multi-hilo para detección multimodal	Yildirim, G.	Applied Intelligence	2023	[40]
Combinación K-Means y SVM para selección de características	Yazdi, K. M., et al.	WASET	2020	[50]
Optimización de ensemble con metaheurísticas	Yasmin, A., et al.	PLOS ONE	2024	[51]

Tabla 3.3: Contribuciones metodológicas en optimización metaheurística para detección.



Figura 3.2: Mapa Conceptual 4: Métodos de optimización y metaheurísticas aplicadas.

3.3. Algoritmos metaheurísticos: fundamentos y aplicaciones

Los algoritmos metaheurísticos son técnicas de optimización versátiles y efectivas para resolver problemas complejos donde los métodos exactos son computacionalmente intratables. En el contexto de la calibración de hiperparámetros en modelos de aprendizaje automático, estos algoritmos ofrecen un equilibrio óptimo entre exploración del espacio de búsqueda y explotación de regiones prometedoras. Los **Algoritmos Genéticos** [52], inspirados en la evolución darwiniana, mantienen una población de soluciones que evoluciona a través de operadores como la selección, el cruzamiento y la mutación. Este proceso permite una exploración eficiente de espacios de búsqueda complejos y altamente dimensionales, siendo particularmente efectivos para la optimización de hiperparámetros en clasificadores tradicionales, la selección de características relevantes y la evolución de arquitecturas de redes neuronales.

La **Optimización por Enjambre de Partículas** [53, 54] se inspira en el comportamiento social de bandadas de pájaros y enjambres de insectos. Cada partícula representa una solución candidata que se mueve a través del espacio de búsqueda influenciada tanto por su propia experiencia (mejor posición personal) como por la experiencia colectiva del enjambre (mejor posición global). Este mecanismo de inteligencia colectiva crea un equilibrio dinámico entre exploración y explotación, siendo particularmente efectiva para la calibración de hiperparámetros en redes neuronales profundas donde las evaluaciones son computacionalmente costosas. El **Recocido Simulado** [55] se basa en el proceso físico de enfriamiento controlado de metales en metalurgia. El algoritmo permite escapar de óptimos locales al aceptar soluciones temporalmente peores con una probabilidad que disminuye gradualmente según un esquema de enfriamiento. La combinación con estrategias de **Multi-arranque** [56] aprovecha múltiples ejecuciones independientes para explorar diferentes regiones del espacio de búsqueda, proporcionando robustez estadística y mayor probabilidad de encontrar el óptimo global.

La **Búsqueda Dispersa** [57] utiliza estrategias determinísticas para combinar un conjunto de soluciones de referencia de alta calidad, generando así nuevas soluciones prometedoras a través de métodos de combinación estructurada. A diferencia de los enfoques estocásticos, se basa en una diversificación controlada que mantiene un balance explícito entre calidad y diversidad de las soluciones, siendo efectiva en problemas donde la estructura del espacio de búsqueda puede ser explotada mediante combinaciones inteligentes. La **Búsqueda en Vecindades Variables** [58] se basa en el principio de cambio sistemático de estructuras de vecindad durante la búsqueda. Esta técnica alterna entre diferentes definiciones de vecindad que capturan diversos aspectos de la estructura del problema, permitiendo escapar de óptimos locales de manera sistemática y explorar el espacio de soluciones desde múltiples perspectivas complementarias.

Algoritmo	Inspiración	Características Principales	Aplicaciones en Detección	Ref.
Algoritmos Genéticos (GA)	Evolución biológica y genética molecular	Población de soluciones, operadores genéticos, selección natural, teoría de esquemas	Optimización de hiperparámetros, selección de características, evolución de arquitecturas de redes neuronales	[52]
Optimización por Enjambre de Partículas (PSO)	Comportamiento social de bandadas y enjambres	Partículas con velocidad y posición, memoria personal y social, inteligencia colectiva	Calibración de pesos en redes, optimización de parámetros de modelos de lenguaje, ajuste de transformers	[53]
Recocido Simulado (SA)	Proceso físico de enfriamiento de metales y mecánica estadística	Aceptación probabilística, esquema de enfriamiento, escape de óptimos locales, distribución de Boltzmann	Optimización de arquitecturas profundas, ajuste fino de modelos complejos, calibración no convexa	[55]
Multi-arranque (Multi-start)	Diversificación de puntos de inicio y exploración global	Múltiples ejecuciones independientes, exploración global del espacio, robustez estadística	Inicialización robusta de modelos, validación cruzada optimizada, ensemble de optimizadores	[56]
Búsqueda Dispersa (SS)	Combinación sistemática de soluciones diversas y métodos determinísticos	Conjunto de referencia, combinaciones determinísticas, diversificación controlada, memoria adaptativa	Ensemble de modelos, combinación de características, optimización de flujo de datos, fusión de arquitecturas	[57]
Búsqueda en Vecindades Variables (VNS)	Cambio sistemático de estructuras de vecindad y perspectivas múltiples	Múltiples definiciones de vecindad, alternancia entre diversificación e intensificación	Exploración de espacios de hiperparámetros, optimización de topologías de red, búsqueda adaptativa	[58]

Tabla 3.4: Algoritmos metaheurísticos: características fundamentales y aplicaciones en detección de noticias falsas.

3.4. Hiperparámetros en modelos de aprendizaje automático

Para comprender la naturaleza de los hiperparámetros, es útil usar una analogía culinaria. Si entrenar un modelo de aprendizaje automático es como hornear un pastel, los **parámetros** son los procesos que ocurren dentro del horno durante la cocción, como las reacciones químicas entre los ingredientes que transforman la masa en un producto final, procesos que el horno (modelo) ajusta automáticamente según las condiciones internas. En una red neuronal, estos son los pesos y sesgos que se optimizan iterativamente durante el entrenamiento mediante algoritmos de descenso de gradiente.

Los **hiperparámetros**, en cambio, son las decisiones críticas que el científico de datos debe tomar antes de comenzar el proceso de entrenamiento, análogo a configurar la temperatura del horno, el tiempo de cocción y la posición de la rejilla antes de hornear. En un modelo de aprendizaje automático, estos incluyen la tasa de aprendizaje que controla la velocidad de actualización de los pesos, el número de épocas que determina cuántas veces el modelo ve el conjunto completo de datos de entrenamiento, la arquitectura de la red como el número de capas y neuronas por capa, los métodos de regularización como dropout o L2 que previenen el sobreajuste, y el tamaño del lote que afecta tanto la velocidad de convergencia como la calidad de la solución. Una elección inadecuada de estos hiperparámetros puede llevar a un rendimiento subóptimo, sobreajuste donde el modelo memoriza en lugar de generalizar, o subajuste donde el modelo no captura la complejidad subyacente de los datos.

En la detección de noticias falsas en español, la optimización de hiperparámetros adquiere una importancia crítica debido a la complejidad multifacética de la tarea. Las especificidades lingüísticas del español requieren configuraciones adaptadas a sus variaciones regionales, múltiples registros formales e informales, y patrones discursivos culturalmente específicos. La sutileza de los patrones de desinformación moderna, que puede incluir medias verdades, tergiversación de contexto y manipulación semántica sofisticada, requiere modelos finamente calibrados capaces de detectar señales débiles. El desbalance de clases, donde las noticias falsas son generalmente menos frecuentes que las verdaderas en corpus reales, exige ajustes específicos en los pesos de clase, umbrales de decisión y métricas de evaluación. La complejidad contextual donde fenómenos como el sarcasmo, la ironía y la sátira deben distinguirse de la falsedad genuina, hace que una configuración inadecuada pueda llevar a altas tasas de falsos positivos.

Tradicionalmente, la optimización de hiperparámetros se ha abordado con métodos como la búsqueda en grilla (Grid Search) que explora sistemáticamente todas las combinaciones posibles en una cuadrícula predefinida, pero es computacionalmente impracticable en espacios de alta dimensión; la búsqueda aleatoria (Random Search) que muestrea combinaciones de hiperparámetros al azar, siendo más eficiente que Grid Search pero sin aprovechar información de evaluaciones previas; y la optimización Bayesiana que utiliza un modelo probabilístico (típicamente un Proceso Gaussiano) para guiar la búsqueda hacia regiones prometedoras, pero puede atascarse en óptimos locales en espacios complejos. Los algoritmos metaheurísticos emergen como una solución más inteligente para este problema, ya que aprenden de cada evaluación para guiar la búsqueda de manera más efectiva, balancean automáticamente exploración de nuevas regiones y explotación de áreas prometedoras, pueden manejar espacios de búsqueda mixtos con hiperparámetros continuos, discretos y categóricos, y son naturalmente paralelizables permitiendo evaluaciones simultáneas en múltiples procesadores.

Keras Tuner [59] es una herramienta moderna de TensorFlow que automatiza y simplifica la búsqueda de hiperparámetros para modelos de deep learning. Facilita la definición declarativa de espacios de búsqueda con rangos y distribuciones, la paralelización automática de evaluaciones en múltiples GPUs o núcleos, la implementación transparente de estrategias avanzadas como Hyperband que combina selección aleatoria con early stopping adaptativo, y la integración nativa con TensorBoard para visualización en tiempo real del progreso de la búsqueda. La combinación de modelos de lenguaje modernos como DistilBERT con herramientas de optimización como Keras Tuner o algoritmos metaheurísticos personalizados crea sistemas potentes donde la representación semántica profunda del modelo se complementa con una búsqueda inteligente de la configuración óptima. Esta sinergia entre arquitecturas Transformer y optimización metaheurística constituye el núcleo metodológico de esta investigación.




Figura 3.3: Mapa Conceptual 5: Clasificación de artículos por enfoque metodológico.

3.5. Análisis temático de la literatura

La escasez de conjuntos de datos etiquetados a gran escala en español continúa siendo un desafío persistente que limita el desarrollo de sistemas de detección robustos. El trabajo pionero de Zules Acosta [11] sentó las bases metodológicas al centrarse en la ingeniería de características léxicas, sintácticas y pragmáticas para la clasificación de noticias en español. Por su parte, Posadas-Durán et al. [12] introdujeron el influyente *Spanish Fake News Corpus*, un recurso relevante que incorpora características estilométricas innovadoras como patrones de puntuación, longitud de oraciones y complejidad sintáctica, abriendo nuevas líneas de investigación sobre el estilo de escritura como indicador de veracidad.

Más recientemente, se han publicado corpus a mayor escala que han sido cruciales para el avance del campo. Tretiakov et al. [19] aportaron un conjunto de datos con metadatos enriquecidos que incluyen información sobre fuentes, fechas de publicación y categorías temáticas, mientras que Blanco-Fernández et al. [13] introdujeron el *Spanish Political Fake News Dataset* con más de 6,000 artículos etiquetados, uno de los recursos más completos disponibles y la principal fuente de datos para esta tesis. La arquitectura Transformer [24] transformó radicalmente el PLN al reemplazar las arquitecturas recurrentes con mecanismos de atención paralelos que procesan secuencias completas simultáneamente. Esto sentó las bases para el paradigma de preentrenamiento-ajuste fino que domina el campo actual, materializado en modelos como BERT [25] que introdujo el preentrenamiento bidireccional mediante tareas de modelado de lenguaje enmascarado, y sus variantes optimizadas como DistilBERT [20] que democratizó el acceso a estos modelos mediante técnicas de compresión que mantienen el rendimiento con recursos computacionales reducidos.

El paradigma de los Grandes Modelos de Lenguaje (LLMs) se consolidó con GPT-3 [17], que demostró capacidades emergentes sorprendentes de aprendizaje con pocos ejemplos (few-shot learning) y razonamiento en contexto sin necesidad de ajuste fino. Investigaciones posteriores han revelado el doble rol crítico de los LLMs en el ecosistema de la desinformación: como “buenos consejeros” pueden ser ajustados para detectar noticias falsas con alta precisión [2], aprovechando su profunda comprensión del lenguaje y contexto; pero como “malos actores” pueden generar desinformación convincente que complica significativamente su detección [16], creando un escenario de carrera armamentista tecnológica donde cada avance en generación impulsa la necesidad de mejoras en detección.

Los algoritmos metaheurísticos han demostrado ser herramientas valiosas para abordar problemas de optimización compleja en la detección de noticias falsas. Aqil y Lahby [36] fueron pioneros al modelar la detección como un problema de planificación de tareas flexible (FSSP), comparando Algoritmos Genéticos, Colonia de Abejas y Búsqueda Iterativa, y encontrando que el enfoque Voraz Iterativo lograba el mejor compromiso entre calidad de solución y eficiencia computacional. Otros trabajos se han centrado específicamente en la calibración de hiperparámetros, donde Bacanin et al. [37] demostraron empíricamente los beneficios de usar metaheurísticas para optimizar modelos de deep learning, mostrando mejoras significativas sobre métodos tradicionales como Grid Search y Random Search en términos de F1-Score y tiempo de convergencia. El trabajo de Hurtado Avilés et al. [23] aborda específicamente la calibración de hiperparámetros para la detección de fraude digital en español, proporcionando un marco conceptual y experimental directamente relevante para esta tesis.

Enfoques de ensamble con marcos heurísticos [21] han mostrado resultados prometedores al combinar múltiples modelos base con estrategias de votación ponderada optimizadas mediante heurísticas de incertidumbre, logrando F1-scores superiores al 95 % en múltiples datasets de referencia. La Tabla 3.5 proporciona una taxonomía detallada de las aplicaciones de metaheurísticas según el tipo de detección, mostrando que la elección del algoritmo está fuertemente influenciada por el tipo de modelo base, las características de los datos y los requisitos específicos del sistema en términos de precisión versus eficiencia computacional.

La comprensión del fenómeno de las noticias falsas requiere necesariamente un enfoque interdisciplinario que trascienda lo puramente computacional. Investigaciones como las de Ali et al. [5, 3] han explorado desde la psicología cognitiva cómo las heurísticas mentales humanas, particularmente la heurística de disponibilidad y el sesgo de confirmación, influyen en la percepción de credibilidad y la propagación viral de contenido falso. El análisis sociológico del rol de los medios de comunicación tradicionales en la era digital [7] ha revelado tensiones entre velocidad de publicación y verificación rigurosa, mientras que estudios sobre el impacto de la desinformación en la salud pública durante la pandemia de COVID-19 [10] han demostrado consecuencias tangibles y medibles de la desinformación en comportamientos de riesgo y tasas de vacunación.

Tipo de Detección	Metaheurística Empleada	Aplicación Específica	Autores	Ref.
Detección de Noticias Falsas	Algoritmo Genético (GA), Colonia de Abejas (ABC), Búsqueda Iterativa (IG)	Planificación de tareas para procesamiento de documentos	Aqil, S. & Lahby, M.	[36]
Detección de Reseñas Falsas	Optimización por Enjambre de Partículas Adaptativo (PSO)	Optimización de hiperparámetros en redes CNN	Deshai, N. & Rao, B. B.	[41]
Fraude Financiero y de Estados Financieros	Algoritmos Genéticos, Optimización por Enjambre de Partículas, Recocido Simulado	Selección de características y optimización de clasificadores SVM	Hidayattullah, S. et al.	[38]
Predicción de Dificultades Financieras	Optimización Bayesiana con Procesos Gaussianos	Calibración de hiperparámetros en modelos GPR	Horak, J. & Sabek, A.	[39]
Detección de Fraude Laboral	Redes Neuronales Artificiales (ANN)	Clasificación de ofertas de empleo fraudulentas	Nasser, I. M. et al.	[9]
Optimización de Modelos de Energía	Algoritmo Genético Binario, PSO, Recocido Simulado, Búsqueda Armónica	Ajuste de hiperparámetros en modelos LSTM para predicción energética	Bacanin, N. et al.	[37]
Detección Multimodal de Noticias Falsas	Enfoque Híbrido Multi-hilo con Metaheurísticas	Optimización paralela de características textuales y visuales	Yildirim, G.	[40]
Selección de Características para Fake News	K-Means combinado con Support Vector Machine (SVM)	Reducción de dimensionalidad y mejora de precisión	Yazdi, K. M. et al.	[50]
Framework de Incertidumbre para Fake News	Enfoque Heurístico basado en Ensemble	Manejo de incertidumbre en clasificación de tweets y artículos	Das, S. D. et al.	[21]
Optimización de Dominación Total en Redes Sociales	Búsqueda en Vecindades Variables (VNS)	Propagación de información en redes sociales	Kapunac, S. et al.	[60]
Estimación de Esfuerzo en Proyectos	Ensemble con Metaheurísticas para Pesos	Optimización de hiperparámetros y pesos de ensemble	Yasmin, A. et al.	[51]

Tabla 3.5: Aplicación de metaheurísticas por tipo de detección en la literatura revisada.

La investigación en detección de fraude se ha extendido exitosamente a otros dominios más allá de las noticias, demostrando la transferibilidad de las técnicas desarrolladas. En el fraude laboral, Nasser et al. [9] aplicaron redes neuronales artificiales para clasificar ofertas de empleo fraudulentas, identificando patrones característicos como ofertas de salarios excesivamente altos y descripciones vagas de responsabilidades. En el fraude financiero, Hidayattullah et al. [38] utilizaron algoritmos metaheurísticos para optimizar la detección de fraude en estados financieros, mostrando que un SVM optimizado con Algoritmo Genético alcanzó una precisión del 96.15 % superando significativamente a configuraciones estándar.



Figura 3.4: Mapa Conceptual 6: Artículos que son revisiones o están relacionados al análisis de contenido y detección de fraude digital.

3.6. Síntesis y perspectivas futuras

La revisión exhaustiva de la literatura revela una rápida evolución en las técnicas para la detección de noticias falsas, caracterizada por tres tendencias convergentes: la adopción generalizada de modelos de lenguaje preentrenados basados en arquitecturas Transformer, la integración creciente de técnicas de optimización metaheurística

para la calibración de hiperparámetros, y el reconocimiento de la necesidad de enfoques multimodales que combinen texto, imágenes y metadatos contextuales. Los desafíos principales que persisten incluyen la necesidad crítica de más datos etiquetados de alta calidad en español que capturen la diversidad dialectal y temática del idioma, la adaptación cultural de los modelos a contextos hispanohablantes considerando factores pragmáticos y sociolingüísticos específicos, la optimización eficiente de hiperparámetros en espacios de alta dimensión con recursos computacionales limitados, y la robustez frente a técnicas adversariales cada vez más sofisticadas incluido el contenido generado por LLMs modernos.

La organización temática de este capítulo proporciona un marco conceptual integral que justifica el enfoque híbrido de esta investigación. La combinación de modelos de lenguaje Transformer con algoritmos metaheurísticos para la optimización de hiperparámetros representa una síntesis natural de las fortalezas de ambos paradigmas: la capacidad de los Transformers para capturar dependencias semánticas profundas y contextuales, con la eficiencia de las metaheurísticas para explorar espacios de configuración complejos y no convexos. Esta aproximación dual, validada en el contexto específico del español mediante corpus especializados, constituye la contribución metodológica central de esta tesis al campo de la detección de desinformación.

El presente trabajo de investigación se posiciona de manera distintiva frente a los estudios analizados mediante varias contribuciones particulares. Mientras que trabajos previos como los de Acosta [11] y Posadas-Durán et al. [12] establecieron corpus pioneros para español con cientos o miles de muestras, esta investigación construye un corpus unificado a gran escala de más de 61,000 registros balanceados, integrando cuatro fuentes académicas reconocidas y enriqueciéndolo mediante extracción web verificada, constituyendo uno de los recursos más extensos disponibles para español. A diferencia de aproximaciones que se centran exclusivamente en modelos de lenguaje como Blanco-Fernández et al. [13] o únicamente en optimización metaheurística como Aqil y Lahby [36], este trabajo implementa una metodología evolutiva dual que establece primero una línea base robusta mediante cinco algoritmos metaheurísticos diferentes (MSA, SS, GA, VNS, PSO) optimizando modelos clásicos con representación TF-IDF, y posteriormente desarrolla un sistema avanzado mediante ajuste fino de DistilBERT con técnicas anti-sobreajuste, permitiendo una comparación empírica directa entre paradigmas bajo condiciones experimentales idénticas. Mientras que estudios internacionales alcanzan exactitudes del 90-98 % en inglés, esta investigación logra 95.2 % de exactitud específicamente para español con un modelo DistilBERT optimizado que supera por más de 24 puntos porcentuales al mejor enfoque metaheurístico, demostrando la superioridad de Transformers para esta tarea en el contexto hispanohablante. Más allá de la validación experimental, este trabajo materializa sus resultados en prototipos funcionales contenerizados con Docker listos para despliegue real, cerrando la brecha entre investigación académica y aplicabilidad práctica. Finalmente, a diferencia de trabajos que se limitan a un dominio específico, la metodología desarrollada demuestra transferibilidad a otros tipos de fraude digital como ofertas de empleo fraudulentas y phishing, estableciendo un marco generalizable más allá de

la detección de noticias falsas. Estas particularidades posicionan esta investigación como una contribución integral que no solo alcanza resultados de estado del arte, sino que proporciona recursos, metodologías y herramientas concretas para el ecosistema hispanohablante de lucha contra la desinformación.

Capítulo 4

Metodología

En este capítulo se presenta una metodología unificada e integrada para abordar el problema de la detección de noticias falsas en español. La estrategia metodológica se fundamenta en un proceso evolutivo de desarrollo y evaluación que avanza desde técnicas clásicas hasta modelos de lenguaje de última generación, permitiendo una comparación sistemática y objetiva de diferentes paradigmas de inteligencia artificial sobre una base de datos común.

El diseño metodológico adopta un enfoque experimental escalonado que incluye: adquisición y procesamiento unificado de datos, implementación de un flujo común de preprocesamiento, desarrollo paralelo de modelos de clasificación utilizando algoritmos metaheurísticos y modelos Transformer, y evaluación comparativa integral bajo un marco de métricas unificado. Este proceso culmina con la implementación de la solución más efectiva en una aplicación web funcional.

4.1. Visión general del proceso metodológico

La metodología se estructura como un flujo de datos experimental unificado que evalúa sistemáticamente dos paradigmas de inteligencia artificial complementarios. Como se ilustra en la Figura 4.1, ambos enfoques parten de una base metodológica común pero implementan estrategias de modelado diferenciadas, convergiendo finalmente en una evaluación comparativa que determina la solución óptima.

Esta investigación adopta una filosofía de desarrollo evolutivo donde se exploran técnicas de complejidad creciente. El proceso comienza estableciendo una línea base sólida con métodos clásicos de PLN optimizados mediante metaheurísticas, para luego progresar hacia modelos Transformer de última generación. Esta progresión permite validación incremental donde cada fase valida y mejora los resultados de la anterior, comparación objetiva bajo las mismas condiciones experimentales, justificación empírica de si la complejidad adicional se traduce en mejoras de rendimiento, y transferibilidad metodológica aplicable a otros tipos de fraude digital.

Una vez completada la evaluación comparativa, el modelo de mejor rendimiento se implementa en una aplicación web que demuestra la viabilidad práctica de la solución

desarrollada.




Figura 4.1: Metodología propuesta que aborda la problemática combinando Algoritmos Metaheurísticos y Modelos de Lenguaje.

Para facilitar la comprensión integral de la arquitectura y el flujo de procesamiento implementado, se presenta un esquema visual completo del sistema desarrollado. La Figura 4.2 ilustra la arquitectura general del sistema, mostrando la interacción entre los componentes principales y el flujo de datos desde la adquisición del corpus hasta la implementación final.

Este esquema arquitectónico unificado permite visualizar: la capa de datos con el proceso de unificación del corpus desde múltiples fuentes académicas y extracción web; la capa de preprocesamiento con el flujo común para limpieza, tokenización y representación textual; la capa de modelado dual con implementación paralela de enfoques metaheurísticos y Transformer; la capa de evaluación mediante un marco unificado de métricas y validación cruzada; y la capa de aplicación integrando el modelo óptimo en sistema productivo.

4.2. Definición y distinción de conceptos fundamentales

Antes de proceder con la descripción metodológica, es fundamental establecer con precisión la terminología utilizada en esta investigación, particularmente la distinción entre conceptos relacionados pero diferenciados que a menudo se utilizan de manera intercambiable en la literatura.




Figura 4.2: Arquitectura general del sistema de detección de noticias falsas, mostrando el flujo completo desde la construcción del corpus hasta la implementación de la aplicación web.

En el contexto de esta investigación, es esencial distinguir entre dos conceptos fundamentales que, aunque relacionados, poseen características distintivas importantes para el desarrollo de sistemas de detección automática. Para proporcionar un marco conceptual completo, esta investigación adopta la taxonomía establecida por la literatura internacional [1, 18], que clasifica el contenido engañoso en tres categorías principales: **Desinformación** como información falsa creada y compartida deliberadamente con intención maliciosa, **Desinformación (Misinformation)** como información incorrecta compartida sin intención maliciosa, y **Información Maliciosa (Malinformation)** como información genuina compartida con intención de causar daño.

El alcance de esta investigación se centra específicamente en la detección automática de **desinformación**, abarcando tanto noticias falsas como bulos, reconociendo que ambos tipos requieren estrategias de procesamiento de lenguaje natural diferenciadas pero complementarias.

En el contexto del desarrollo de sistemas automáticos de detección, la distinción entre noticia falsa y bulo, aunque conceptualmente importante, se aborda mediante un enfoque unificado de **detección de contenido desinformativo**. Esta decisión metodológica se fundamenta en características textuales compartidas donde ambos tipos utilizan patrones lingüísticos identificables mediante técnicas de PLN, objetivo común de engañar o desinformar a la audiencia, impacto social similar con efectos

negativos en la percepción pública y toma de decisiones, y necesidad práctica de que los sistemas de detección automática sean capaces de identificar ambos tipos.

Por tanto, en el resto de este documento, el término “**noticias falsas**” se utilizará de manera inclusiva para referirse a cualquier tipo de contenido desinformativo, reconociendo la diversidad de formatos y estrategias de propagación que abarca esta categorización.

Esta investigación adopta un esquema de clasificación binaria, donde cada noticia se etiqueta en una de dos clases mutuamente excluyentes: **Clase 0 (FALSO)** que incluye todo contenido desinformativo, abarcando tanto noticias falsas formales como bulos informales, contenido satírico deliberadamente engañoso y cualquier tipo de información con intención de desinformar; y **Clase 1 (REAL)** que incluye contenido periodístico legítimo, noticias verificadas de fuentes confiables e información factualmente correcta.

La decisión de utilizar clasificación binaria, en lugar de esquemas multiclase más granulares, se fundamenta en: practicidad para usuarios finales donde en aplicaciones reales los usuarios necesitan una respuesta clara y directa sobre la confiabilidad del contenido; consistencia con la literatura donde la mayoría de trabajos en detección de noticias falsas utilizan esquemas binarios, facilitando la comparación de resultados; robustez del modelo donde los esquemas binarios tienden a ser más robustos y menos propensos al sobreajuste que las clasificaciones multiclase complejas; y disponibilidad de datos donde los corpus disponibles están mayoritariamente etiquetados de forma binaria.

Aunque este trabajo adopta clasificación binaria, es importante reconocer que existen esquemas alternativos más granulares como clasificación ternaria (FALSO, REAL, PARCIALMENTE_CIERTO), clasificación por niveles de confianza con escalas de 5 o 7 puntos de credibilidad, o clasificación por tipo de desinformación distinguiendo entre sátira, propaganda, clickbait, etc. Sin embargo, estos enfoques requieren corpus más especializados y presentan desafíos adicionales en términos de consistencia de etiquetado y acuerdo entre anotadores.

Es importante reconocer que la clasificación binaria de contenido informativo presenta inherentemente zonas grises y fronteras difusas, donde la distinción entre “verdadero” y “falso” no es absoluta. Esta complejidad conceptual representa uno de los desafíos fundamentales en la detección automatizada de desinformación.

En la práctica, existen varios tipos de contenido que desafían la clasificación binaria estricta: información parcialmente correcta con noticias que contienen algunos hechos verificables mezclados con información falsa o tergiversada; contenido satírico ambiguo como material humorístico que puede ser malinterpretado como información factual; opiniones presentadas como hechos con contenido subjetivo que se presenta con apariencia de objetividad periodística; información desactualizada con noticias que fueron ciertas en el pasado pero ya no son válidas; interpretaciones sesgadas mediante presentación de hechos reales con marcos interpretativos tendenciosos; e información especulativa con predicciones o análisis presentados como hechos consumados.

Esta ambigüedad inherente se aborda en esta investigación mediante: criterios de etiquetado conservadores donde en casos ambiguos se prioriza la asignación a la clase “REAL” para evitar censura inadecuada de contenido legítimo; umbral de confianza con el modelo generando probabilidades que pueden interpretarse como niveles de certeza, permitiendo identificar casos limítrofes; validación humana en casos dudosos donde los corpus utilizados fueron validados manualmente para resolver ambigüedades; y reconocimiento de limitaciones asumiendo que un porcentaje mínimo de casos será inherentemente ambiguo y difícil de clasificar con certeza absoluta.

A pesar de estas complejidades, el enfoque binario se justifica porque proporciona utilidad práctica donde los usuarios finales requieren decisiones claras sobre la credibilidad del contenido, viabilidad técnica con modelos binarios más robustos y fáciles de entrenar que los esquemas multiclase complejos, consistencia metodológica permitiendo comparación directa con la literatura existente, y escalabilidad facilitando la anotación y validación de grandes volúmenes de datos.

Es fundamental entender que **la frontera difusa no es una limitación del modelo, sino una característica inherente del problema mismo**, que debe ser gestionada mediante diseño metodológico cuidadoso y reconocimiento explícito de las limitaciones del enfoque adoptado.

4.3. Construcción del corpus unificado

El primer y más fundamental paso de la metodología fue la construcción de un corpus de alta calidad y de tamaño significativo en español, dada la escasez documentada de recursos centralizados para esta tarea [18]. Se llevó a cabo un proceso exhaustivo de investigación y unificación de cuatro corpus académicos reconocidos, los cuales constituyen pilares en la investigación de noticias falsas en español. Es importante señalar que aunque todos los corpus convergen hacia el objetivo común de detección de desinformación, cada uno fue desarrollado con enfoques metodológicos y propósitos específicos diferentes, lo que enriquece la diversidad y robustez del conjunto de datos unificado. La Tabla 4.1 presenta un resumen detallado de estos recursos y sus características distintivas.

ID	Nombre del Corpus	Autores Principales	Año	Noticias	Características	Ref.
1	Spanish Fake News Corpus (IberLEF)	Posadas-Durán, J.P. Gómez-Adorno, H.	2019-2021	971	Análisis estilométrico Múltiples versiones	[12]
2	Conjunto de datos Zules Acosta (UPM)	Acosta, F.A.Z.	2019	598	Trabajo fin de maestría Extracción web verificada	[11]
3	Conjunto de datos Tretiakov (Kaggle)	Tretiakov, A. Martín García, A.	2022	1,958	Aprendizaje automático Disponible públicamente	[19]
4	Spanish Political Fake News Conjunto de datos	Blanco-Fernández, Y. Otero-Vizoso, J.	2024	57,231	Temática política Modelos BERT/RoBERTa	[13]

Tabla 4.1: Corpus académicos utilizados para la construcción del conjunto de datos unificado.

El corpus de IberLEF, asociado a las competencias de IberLEF y desarrollado por Posadas-Durán, Gómez-Adorno, et al., ha tenido varias versiones. La versión original

y más citada del corpus contiene un total de 971 noticias [12]. Su propósito específico fue el desarrollo de técnicas de análisis estilométrico para identificar patrones lingüísticos distintivos en texto desinformativo. Este corpus se caracteriza por su enfoque metodológico riguroso en análisis estilométrico y ha sido utilizado en múltiples evaluaciones comparativas dentro del marco de las competencias IberLEF [46, 45]. Las fuentes de este corpus provienen principalmente de sitios web verificados como desinformativos por organismos de verificación de datos españoles y latinoamericanos. Las versiones posteriores del corpus han sido mantenidas y actualizadas en repositorios públicos [47].

Desarrollado como parte de un Trabajo Fin de Maestría Universitaria en Ciberseguridad en la Universidad Politécnica de Madrid, el corpus de Acosta contiene 598 noticias verificadas [11]. Su propósito original fue establecer una metodología de construcción de corpus para noticias falsas en español, con énfasis en la verificación manual exhaustiva. El conjunto de datos fue construido mediante técnicas de extracción web y se encuentra disponible públicamente en la plataforma Kaggle [61, 62]. Las fuentes incluyen tanto medios legítimos (para noticias reales) como sitios identificados como propagadores de desinformación, con verificación cruzada mediante múltiples verificadores de hechos. Su contribución principal radica en la aplicación de metodologías rigurosas de verificación para la construcción de conjuntos de datos de noticias falsas.

El corpus de Tretiakov, desarrollado por Tretiakov, Martín García y Camacho, contiene 1,958 noticias en español con distribución balanceada (50 % de noticias falsas y 50 % de noticias verdaderas) [19]. Su propósito específico fue la evaluación de técnicas de aprendizaje automático tradicionales para clasificación binaria de contenido desinformativo. El conjunto de datos fue creado en el contexto de técnicas de aprendizaje automático para la detección de información falsa y se encuentra disponible públicamente en Kaggle [63]. Las fuentes de este corpus se concentran en redes sociales y plataformas digitales donde se propaga desinformación, incluyendo Twitter, Facebook y sitios web no verificados. Su enfoque se centra en la aplicación de técnicas de aprendizaje automático para la clasificación automatizada de contenido desinformativo.

El corpus más extenso utilizado, desarrollado por Blanco-Fernández et al., contiene 57,231 noticias de temática política [13]. Su propósito específico fue evaluar modelos transformer (BERT/RoBERTa) en el dominio político, donde la desinformación tiene particular relevancia social. Este conjunto de datos fue específicamente diseñado para evaluar modelos BERT y RoBERTa en la detección de desinformación política en español y se encuentra disponible en Kaggle [64]. Las fuentes incluyen tanto medios de comunicación tradicionales como plataformas digitales especializadas en contenido político, con particular énfasis en el contexto español e iberoamericano. Su gran tamaño y enfoque en contenido político lo convierte en un recurso valioso para el entrenamiento de modelos de gran escala.

Para garantizar una comprensión completa de las características y diferencias entre los corpus utilizados, se presenta un análisis comparativo exhaustivo que permite entender las fortalezas y limitaciones de cada fuente de datos, así como las decisiones

metodológicas tomadas en el proceso de unificación, como se detalla en la Tabla 4.2.

Aspecto Comparativo	Posadas-Durán	Acosta (UPM)	Tretiakov	Blanco-Fernández	El Deforma
Tamaño del corpus	971 noticias	598 noticias	1,958 noticias	57,231 noticias	9,000 noticias
Año de creación	2019-2021	2019	2022	2024	2025 (extracción)
Enfoque metodológico	Análisis estilométrico Competencias IberLEF	Metodología de construcción de corpus	Aprendizaje automático tradicional	Modelos Transformer BERT/RoBERTa	Contenido satírico Web scraping
Dominio temático	General	General	General	Político específico	Satírico/General
Distribución de clases	Balanceado	Balanceado	Solo falsas	Balanceado	Solo falsas
Variabilidad regional	España/Latinoamérica	Internacional	Múltiple	España	México
Periodo temporal	2018-2021	2018-2019	2020-2022	2020-2024	2019-2025
Contribución al corpus final	1.6 %	1.0 %	3.2 %	92.8 %	14.6 %

Tabla 4.2: Comparación exhaustiva de características de los corpus utilizados en la construcción del conjunto de datos unificado.

Una consideración metodológica fundamental en esta investigación es el reconocimiento y aprovechamiento de la diversidad regional del español presente en los corpus utilizados. El corpus unificado representa un enfoque de español neutro multiregional, lo que constituye una fortaleza metodológica significativa. La distribución geográfica incluye español peninsular (España) representado principalmente en los corpus de Posadas-Durán [12] y Blanco-Fernández [13] que utilizan fuentes de medios españoles verificados; español mexicano incorporado a través del contenido de “El Deforma” y fuentes mexicanas presentes en el corpus de Acosta [11]; español latinoamericano diverso donde el corpus de Acosta incluye fuentes internacionales que abarcan múltiples países de habla hispana; y español digital contemporáneo donde los corpus más recientes (2020-2025) capturan la evolución del español en medios digitales.

Las ventajas metodológicas del enfoque multiregional incluyen robustez del modelo con capacidad de detectar desinformación independientemente de la variante regional, generalización lingüística con menor sesgo hacia construcciones específicas de una región, aplicabilidad universal donde el modelo resultante es funcional para toda la comunidad hispanohablante, y representatividad real que refleja el consumo actual de noticias en español, que frecuentemente cruza fronteras nacionales. Esta diversidad regional no constituye una limitación, sino una fortaleza que permite desarrollar modelos más robustos y ampliamente aplicables.

El análisis detallado de los corpus permite identificar patrones complementarios que justifican la estrategia de unificación adoptada. La diversidad metodológica se evidencia en que el corpus de Posadas-Durán aporta rigor en análisis estilométrico y experiencia en competencias académicas; el corpus de Acosta contribuye con metodología de construcción verificada manualmente; el corpus de Tretiakov añade perspectiva de ML tradicional y fuentes de redes sociales; el corpus de Blanco-Fernández proporciona escala masiva y especialización en dominio político; y el contenido de El Deforma introduce diversidad estilística y contemporaneidad.

La cobertura temporal y geográfica abarca un span temporal de 2018-2025 (7 años de evolución en patrones de desinformación), cobertura geográfica de España, México y Latinoamérica (diversidad regional del español), y evolución temática desde temas generales hasta especialización política y satírica. La complementariedad en tipos de desinformación incluye desinformación tradicional con corpus académicos con verificación formal, desinformación política con especialización del corpus de Blanco-Fernández, contenido satírico mediante ampliación con El Deforma para diversidad

estilística, y múltiples fuentes desde medios tradicionales hasta redes sociales.

La diversidad en metodologías de construcción permite validar la robustez de los modelos desarrollados, donde modelos entrenados deben generalizar entre diferentes tipos de anotación, tener capacidad de detectar patrones consistentes a pesar de diferencias metodológicas, y permitir evaluación de transferencia entre dominios (general $\rightarrow$ político $\rightarrow$ satírico).

La decisión de unificar corpus heterogéneos se basa en varios principios metodológicos sólidos: el principio de máxima diversidad con mayor variabilidad en patrones lingüísticos, reducción de sesgos específicos de corpus individuales y mejora en generalización de modelos entrenados; el principio de escala efectiva mediante aprovechamiento del corpus grande (Blanco-Fernández) como base, enriquecimiento con corpus especializados más pequeños y balanceo mediante extracción web controlada; y el principio de validación cruzada donde cada corpus actúa como validación independiente de los otros, patrones consistentes entre corpus indican robustez y diferencias señalan áreas que requieren atención especial.

La integración de corpus heterogéneos requirió un proceso sistemático de estandarización que incluyó: normalización de formato mediante unificación de esquemas de etiquetado en un sistema binario consistente (FALSO=0, REAL=1) y estandarización de estructuras de datos CSV con separador de punto y coma; eliminación de duplicados con implementación de algoritmos de detección de contenido similar basados en hash de texto y comparación de títulos; validación de calidad mediante verificación manual de una muestra estadísticamente significativa para confirmar la calidad del etiquetado y consistencia temática; balanceo de clases con análisis detallado de la distribución de clases para identificar necesidades de ampliación y garantizar equilibrio (el balanceo se refiere a mantener una proporción similar entre noticias “FALSAS” y “REALES”, idealmente cercana al 50 %-50 %, para evitar sesgos algorítmicos y garantizar que los modelos aprendan a detectar ambas clases con igual efectividad); y limpieza de datos mediante eliminación de registros con valores nulos o inconsistentes usando `dropna()` y validación de tipos de datos.

Para mejorar el balance del conjunto de datos y aumentar la diversidad de las noticias etiquetadas como “FALSAS”, se aplicaron técnicas de extracción web automatizada. Se desarrolló un script especializado en Python utilizando las librerías BeautifulSoup y Requests para extraer de forma sistemática los titulares y cuerpos de noticia del portal de contenido satírico “El Deforma”.

El proceso de extracción automatizada se ejecutó en múltiples fases para alcanzar el objetivo de 9,000 noticias adicionales. La Tabla 4.3 detalla las diferentes etapas implementadas.

El proceso de extracción automatizada incluyó: identificación de patrones mediante análisis de la estructura HTML del sitio web objetivo para identificar selectores CSS consistentes (`h1.tdb-title-text`, `div.tdb-block-inner`); extracción automatizada con implementación de rutinas de extracción con manejo de errores y delays aleatorios (1.5-4.5 segundos) para evitar sobrecarga del servidor; validación de contenido mediante verificación automática de la calidad del contenido extraído con filtros

Fase	Estrategia	Técnica Utilizada	Objetivo	Resultado	Observaciones
1	Scraping Inicial	Navegación por enlaces Extracción de contenido	1,000	1,000	Proceso exitoso Base establecida
2	Búsqueda Expandida Masiva	URLs desde existentes Crawling híbrido	9,000	2,495	Expansión limitada Nuevas estrategias
3	Crawler Híbrido Persistente	URLs semilla Trafilatura	9,000	2,495	Estabilización Mismo resultado
4	Paginación Sistemática	Escaneo por páginas Indexación completa	9,000	9,000	Éxito completo Objetivo alcanzado

Tabla 4.3: Fases del proceso de extracción web implementado para “El Deforma”.

de longitud mínima (500 caracteres); limpieza de texto eliminando disclaimers específicos del sitio, caracteres especiales y normalización de espacios mediante expresiones regulares; etiquetado automático asignando etiqueta “FALSO” (0) a todo el contenido extraído del portal satírico; persistencia progresiva mediante guardado en lotes de 50 registros con formato CSV y separador de punto y coma para evitar pérdida de datos; y gestión de estado con implementación de archivos de progreso para permitir la reanudación del proceso en caso de interrupción.

La estrategia final exitosa utilizó paginación sistemática, escaneando secuencialmente desde <https://eldeforma.com/page/1/> hasta alcanzar las 9,000 noticias objetivo, garantizando cobertura completa del contenido disponible. Esta estrategia de ampliación se justifica por varios factores: diversidad estilística mediante incorporación de diferentes estilos de contenido falso o satírico; volumen de datos con incremento significativo del conjunto de entrenamiento; actualidad temporal incluyendo contenido contemporáneo que refleja tendencias actuales; y variabilidad temática ampliando el espectro de temas cubiertos en el corpus.

El proceso completo de unificación, limpieza de duplicados y ampliación mediante extracción web resultó en un **corpus final con 61,674 noticias únicas**, constituyendo uno de los recursos más extensos disponibles para la detección de noticias falsas en español. El análisis de balance del corpus final mostró una distribución equilibrada: **Noticias FALSAS (0)**: 30,734 registros (49.8 %) y **Noticias REALES (1)**: 30,940 registros (50.2 %).

El **balanceo de clases** es un concepto fundamental en el aprendizaje automático que se refiere a la distribución equitativa de ejemplos entre las diferentes categorías o clases del conjunto de datos. En el contexto de la detección de noticias falsas, esto significa mantener una proporción similar entre noticias etiquetadas como “FALSAS” y “REALES”. La importancia crítica del balanceo radica en prevenir sesgo algorítmico donde un conjunto de datos desbalanceado puede llevar a que el modelo aprenda a predecir sistemáticamente la clase mayoritaria, ignorando la minoritaria; en métricas de evaluación confiables donde las métricas como exactitud pueden ser engañosas en datasets desbalanceados (ejemplo: 95 % de exactitud puede significar que el modelo siempre predice la clase mayoritaria); en generalización robusta donde los modelos entrenados con datos balanceados tienden a generalizar mejor en escenarios reales donde la distribución puede ser diferente; y en detección efectiva de ambas clases

siendo igualmente importante detectar noticias falsas como preservar noticias verdaderas.

Las estrategias implementadas para lograr el balanceo incluyeron: análisis cuantitativo inicial evaluando la distribución de clases en cada corpus individual; identificación de déficits detectando desbalances significativos que requerían corrección; extracción web dirigida mediante adición estratégica de 9,000 noticias falsas mediante web scraping para compensar el déficit; y validación final confirmando que la distribución resultante es prácticamente equilibrada (49.8 % vs 50.2 %). El balanceo adecuado del corpus tiene impactos directos en múltiples aspectos del proyecto: entrenamiento más estable donde los algoritmos convergen de manera más consistente; métricas más interpretables con F1-Score, precisión y recall reflejando el rendimiento real; transferibilidad mejorada donde los modelos se adaptan mejor a nuevos dominios; y validación confiable con resultados de validación cruzada más representativos.

La Figura 4.3 ilustra gráficamente el concepto de balanceo implementado, mostrando la transformación desde una distribución inicial potencialmente sesgada hacia la distribución final equilibrada que optimiza el rendimiento de los modelos de clasificación.




Figura 4.3: Representación gráfica del proceso de balanceo del corpus: comparación entre distribución inicial desbalanceada y distribución final equilibrada. La imagen muestra cómo la extracción web de 9,000 noticias falsas permitió alcanzar un equilibrio óptimo de 49.8 % noticias falsas vs 50.2 % noticias reales.

Para garantizar una evaluación robusta y evitar el sobreajuste, este corpus se dividió de manera estratificada, manteniendo la proporción original de noticias falsas y reales en cada subconjunto. La configuración utilizada fue **70 % para entrenamiento, 10 % para validación y 20 % para evaluación final**. Esta división garantiza: conjunto de entrenamiento suficiente donde 70 % proporciona datos abundantes para el aprendizaje de patrones complejos; validación efectiva con 10 % permitiendo calibración de hiperparámetros sin comprometer datos de prueba; y evaluación objetiva mediante 20 % reservado exclusivamente para pruebas finales sin contaminar el

proceso de desarrollo.

La Tabla 4.4 muestra la distribución implementada en todos los experimentos.

Conjunto de Datos	Porcentaje	Noticias	Propósito
Entrenamiento	70 %	43,171	Entrenar modelos
Validación	10 %	6,167	Calibrar hiperparámetros
Pruebas	20 %	12,336	Evaluación final

Tabla 4.4: División estratificada del corpus para entrenamiento y evaluación.

Esta estrategia sigue las mejores prácticas establecidas en la literatura de aprendizaje automático y permite una evaluación imparcial de ambas metodologías. La estratificación garantiza que cada subconjunto mantenga la misma proporción de noticias falsas y reales que el corpus completo, evitando sesgos en el entrenamiento y evaluación de los modelos.

Para minimizar posibles sesgos en el conjunto de datos, se implementaron las siguientes medidas: estratificación rigurosa usando `train_test_split` con parámetro `stratify` para mantener distribución de clases en cada partición; aleatorización controlada mediante semilla fija (`random_state=42`) para reproducibilidad sin pérdida de aleatoriedad; análisis de distribución con verificación estadística de la distribución de clases en cada subconjunto mediante tests chi-cuadrado; y validación cruzada estratificada usando k-fold estratificado ($k=5$) durante la optimización de hiperparámetros para garantizar robustez.

El proceso de limpieza final implementó las siguientes operaciones: eliminación de valores nulos mediante remoción de registros con campos vacíos en texto o etiquetas usando `dropna()`; detección de duplicados con identificación y eliminación de 15 registros duplicados basada en contenido textual idéntico; normalización de caracteres eliminando punto y coma y caracteres especiales para evitar conflictos con el formato CSV; compactación de espacios reduciendo espacios múltiples y normalizando saltos de línea mediante expresiones regulares; mezclado aleatorio con randomización del orden usando semilla fija (`random_state=42`) para garantizar reproducibilidad; y validación de tipos mediante conversión de etiquetas a enteros usando `astype(int)` para consistencia de datos.

El resultado final fue un corpus robusto, balanceado y limpio, optimizado para el entrenamiento de modelos de detección de noticias falsas en español, que constituye una de las contribuciones principales de este trabajo de investigación al proporcionar un recurso de gran escala para la comunidad hispanohablante.

4.4. Enfoque 1: detección mediante algoritmos metaheurísticos

El primer enfoque metodológico se basó en técnicas clásicas de PLN combinadas con algoritmos de optimización metaheurística, sirviendo como línea base robusta para el proyecto y permitiendo la comparación con enfoques más modernos. El flujo

de datos de preprocesamiento implementó una serie de transformaciones estándar para convertir el texto crudo en representaciones numéricas adecuadas para algoritmos de aprendizaje automático.

Se implementó una función optimizada de limpieza que incluye los siguientes pasos: validación de entrada verificando que el input sea de tipo string válido; normalización a minúsculas con conversión completa del texto usando `lower()`; eliminación de URLs mediante remoción de enlaces web con expresiones regulares; limpieza de caracteres especiales preservando únicamente caracteres alfabéticos en español; tokenización con NLTK dividiendo el texto usando `word_tokenize()`; eliminación de stopwords excluyendo palabras funcionales sin valor semántico; y filtrado por longitud removiendo tokens menores a 3 caracteres.

Tras el preprocesamiento, se aplicó la técnica TF-IDF utilizando `TfidfVectorizer` de scikit-learn. La configuración específica incluyó: máximo de características con 5,000 palabras más frecuentes; matriz resultante con representación densa convertida usando `toarray()`; y almacenamiento guardando en formato CSV para reutilización.

La ponderación TF-IDF se calculó utilizando las siguientes fórmulas:

$$\text{TF}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (4.1)$$

$$\text{IDF}(t, D) = \log \frac{|D|}{|\{d \in D : t \in d\}|} \quad (4.2)$$

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D) \quad (4.3)$$

Donde t representa un término, d un documento, D la colección completa de documentos y $f_{t,d}$ la frecuencia del término t en el documento d .

Para la optimización de hiperparámetros de clasificadores, se implementaron y evaluaron cinco algoritmos metaheurísticos específicos [23, 37]. La Tabla 4.5 presenta una visión general de los algoritmos seleccionados y sus características principales.

Algoritmo	Inspiración	Principio Base	Estrategia Principal	Ref.
MSA	Metalurgia	Recocido de metales Enfriamiento controlado	Múltiples puntos de inicio Aceptación probabilística	[55, 56]
SS	Metodología científica	Búsqueda sistemática Combinación estructurada	Conjunto de referencia Generación de subconjuntos	[57]
VNS	Exploración geográfica	Cambio sistemático de vecindarios	Exploración local Diversificación estructural	[58]
GA	Evolución natural	Selección natural Supervivencia del más apto	Operadores genéticos Evolución poblacional	[52]
PSO	Comportamiento social	Inteligencia de enjambre Comunicación colectiva	Movimiento de partículas Intercambio de información	[53, 54]

Tabla 4.5: Algoritmos metaheurísticos implementados y sus fundamentos conceptuales.

El algoritmo MSA combina los principios del Recocido Simulado [55] con estrategias de métodos Multi-arranque [56]. Se inspira en el proceso metalúrgico de recocido,

donde los metales se calientan y luego se enfrían lentamente para alcanzar estados de menor energía y mayor estabilidad estructural. En el contexto de optimización, este proceso se traduce en la capacidad de escapar de óptimos locales mediante la aceptación probabilística de soluciones temporalmente peores.

La Búsqueda Dispersa, desarrollada por Glover [57], se basa en principios de metodología científica, combinando elementos de diversas soluciones de alta calidad para generar nuevas candidatas. Su filosofía se centra en la combinación sistemática y la mejora estructurada, similar a como los investigadores combinan diferentes enfoques para obtener mejores resultados.

El Algoritmo Genético, fundamentado en el trabajo original de Holland [52], emula los procesos de evolución natural descritos por Darwin, donde las especies más aptas tienen mayor probabilidad de sobrevivir y reproducirse. En optimización, este principio se traduce en la evolución de poblaciones de soluciones mediante operadores inspirados en la genética: selección, cruce y mutación.

VNS, introducida por Mladenović y Hansen [58], se inspira en la exploración geográfica sistemática, donde se cambian las estrategias de búsqueda (vecindarios) de manera estructurada para evitar quedar atrapado en regiones subóptimas. Su principio fundamental es que diferentes estructuras de vecindario pueden revelar diferentes aspectos del paisaje de optimización.

PSO, desarrollado por Kennedy y Eberhart [53], se fundamenta en el comportamiento social observado en enjambres naturales como bandadas de aves o cardúmenes de peces. Las partículas (soluciones) se mueven en el espacio de búsqueda influenciadas por su propia experiencia y la información colectiva del enjambre, creando un mecanismo de inteligencia emergente.

Todos los algoritmos metaheurísticos utilizan una función de evaluación común que implementa un clasificador logístico binario:

$$P(y = 1|x) = \frac{1}{1 + \exp(-w^T \cdot x_{binario})} \quad (4.4)$$

Donde w representa el vector de pesos optimizado, $x_{binario}$ es la versión binarizada de las características usando umbrales, y la decisión final se toma con umbral de 0.5.

Para hacer computacionalmente factible la optimización, se aplicó reducción de dimensionalidad usando `SelectPercentile` con selección del 10 % de las características más relevantes según el test chi-cuadrado (que mide qué tan relacionada está cada palabra con el hecho de que una noticia sea falsa o real). Esta estrategia de reducción permite que los algoritmos metaheurísticos operen eficientemente sobre un espacio de características optimizado, manteniendo la información más discriminativa para la tarea de clasificación.

4.5. Enfoque 2: detección mediante modelo Transformer

El segundo enfoque se fundamentó en el paradigma de aprendizaje profundo, específicamente en la arquitectura Transformer [24], utilizando un modelo de lenguaje preentrenado para capturar representaciones contextuales sofisticadas del texto.

Para la selección del modelo óptimo se realizó un análisis comparativo entre los principales modelos BERT optimizados disponibles. Se seleccionó el modelo `distilbert-base-multilingual-cased`

por las siguientes razones técnicas y prácticas: capacidad multilingüe con soporte nativo para español y más de 100 idiomas; eficiencia computacional reduciendo 40 % de parámetros respecto a BERT base manteniendo el 97 % del rendimiento [20]; arquitectura probada basada en destilación de conocimiento de BERT [25]; balance óptimo con mejor relación rendimiento-eficiencia que TinyBERT [26]; especialización en español donde a diferencia de TinyBERT diseñado principalmente para inglés, DistilBERT tiene una versión multilingüe específica que incluye entrenamiento extensivo en español, crítico para esta investigación que maneja un corpus de español neutro multiregional; y disponibilidad accesible a través de la librería Transformers de Hugging Face.

El corpus de pre-entrenamiento de DistilBERT multilingüe incluye Wikipedia multilingüe con más de 100 idiomas representados, incluyendo español con aproximadamente 1.6 millones de artículos que representan más de 800 millones de palabras de texto enciclopédico de alta calidad. Este volumen de exposición permite al modelo aprender la morfología del español con patrones de conjugación verbal y concordancia de género y número, la sintaxis característica con orden flexible de palabras y construcciones con subjuntivo, la semántica contextual incluyendo polisemia y modismos específicos del español, y variación dialectal natural introducida por contribuidores de Wikipedia de diversos países hispanohablantes. El contenido total del corpus supera los 2.5 terabytes de texto limpio con cobertura balanceada que garantiza representación significativa de idiomas no anglosajones.

La metodología de pre-entrenamiento preservó la tarea de Masked Language Modeling (MLM) de BERT, donde el 15 % de los tokens son enmascarados y el modelo debe predecirlos basándose en el contexto bidireccional, pero eliminó Next Sentence Prediction (NSP) para simplificación y eficiencia. El proceso aplicó destilación de conocimiento triple mediante pérdida de destilación supervisando las salidas del modelo estudiante con las del profesor, pérdida de enmascaramiento de lenguaje manteniendo la tarea MLM original, y pérdida de similitud coseno alineando las representaciones ocultas entre estudiante y profesor. Esta triple destilación permite que DistilBERT con solo 6 capas Transformer (versus 12 en BERT) mantenga 97 % del rendimiento con 40 % menos parámetros, logrando un balance óptimo entre capacidad y eficiencia crucial para la fase intensiva de experimentación requerida en esta investigación.

Las características específicas para español en DistilBERT multilingüe incluyen vocabulario compartido mediante tokenizador WordPiece con 110,000 tokens com-

partidos entre todos los idiomas, proporcionando transferencia de conocimiento cross-lingual donde el aprendizaje en un idioma beneficia a otros debido a representaciones compartidas, y especialización implícita donde aunque no hay entrenamiento exclusivo en español, la arquitectura Transformer aprende patrones lingüísticos específicos mediante exposición a millones de oraciones en español durante el pre-entrenamiento. Contrario a la intuición inicial de que un modelo monolingüe especializado en español debería superar a uno multilingüe, la investigación reciente en PLN ha demostrado que los modelos multilingües ofrecen ventajas específicas mediante transferencia de conocimiento cross-lingual donde el modelo aprende representaciones universales que capturan patrones sintácticos y semánticos compartidos entre idiomas, robustez ante code-switching común en contenido digital hispanohablante donde se mezcla español e inglés, y generalización mejorada donde la exposición a múltiples idiomas durante el pre-entrenamiento actúa como regularización implícita.

Modelos alternativos considerados pero no seleccionados incluyen BETO (BERT en Español) pre-entrenado exclusivamente sobre 3 mil millones de palabras del corpus OPUS de traducciones y Wikipedia en español, ofreciendo especialización en español pero con limitación de tamaño del corpus comparado con DistilBERT multilingüe y mayor costo computacional al ser modelo completo no destilado; RoBERTa en español con arquitectura más robusta pero similar corpus ofreciendo rendimiento marginalmente superior pero sin justificar el incremento del 60 % en tiempo de entrenamiento y requerimientos de memoria; y mBERT (multilingual BERT) con 104 idiomas soportados pero siendo significativamente más grande (180M parámetros versus 134M de DistilBERT) resultando en menor eficiencia computacional sin mejoras proporcionales en rendimiento para la tarea específica de detección de noticias falsas. Experimentos preliminares con tres arquitecturas confirmaron empíricamente la selección: pruebas con TinyBERT en inglés (3 experimentos, 30-45 minutos cada uno) fueron descartadas por falta de soporte nativo para español requiriendo traducción que introduciría ruido adicional; pruebas con BERT completo (3 experimentos, 24-48 horas cada uno) alcanzaron exactitud de 94.8 % pero con tiempos de entrenamiento inviables para iteración experimental; y validación con DistilBERT (8+ experimentos, 12-24 horas cada uno) alcanzó exactitud final de 95.2 % con tiempos de experimentación 50 % menores que BERT completo.

La decisión final de utilizar DistilBERT multilingüe en lugar de variantes monolingües se fundamenta en disponibilidad y madurez siendo el modelo destilado multilingüe más estable y ampliamente validado, eficiencia comprobada manteniendo 97 % del rendimiento de BERT con 40 % menos parámetros validado empíricamente en múltiples benchmarks, soporte nativo para español sin necesidad de adaptación adicional o tokenizadores especializados, e integración con ecosistema mediante compatibilidad total con Hugging Face Transformers facilitando implementación. Esta selección optimiza el balance entre rendimiento (capacidad de detectar patrones complejos en español), eficiencia (recursos computacionales accesibles para entrenamiento), y generalización (robustez ante diferentes variantes del español multiregional), proporcionando la plataforma ideal para la investigación comparativa desarrollada en

este proyecto.

El entrenamiento del modelo DistilBERT se realizó en un entorno de hardware dedicado con procesador AMD Ryzen 7 7735H (8 núcleos, 16 hilos, 4.75 GHz boost, arquitectura Zen 3+ 6nm); GPU NVIDIA GeForce RTX 4060 (8GB GDDR6 VRAM, 3072 núcleos CUDA, 140W TGP, soporte mixed precision); memoria RAM de 16GB DDR5 con capacidad para datasets grandes y procesamiento de batches; y almacenamiento con x2 500GB SSD NVMe para acceso rápido a datos y checkpointing eficiente.

El proceso de fine-tuning se implementó utilizando TensorFlow con precisión mixta (mixed_float16) para optimizar el uso de memoria GPU y acelerar el entrenamiento. La configuración experimental se estructuró en múltiples fases de optimización. La configuración base del modelo se estableció considerando las limitaciones computacionales y las mejores prácticas para modelos Transformer: longitud máxima de secuencia de 128 tokens reducida desde 512 para minimizar overfitting; épocas máximas de 30 suficientes para convergencia; paciencia early stopping de 8 épocas para evitar sobreentrenamiento; factor de reducción LR de 0.15 más agresivo que estándar para convergencia controlada; y precisión numérica mixed_float16 para optimización de memoria GPU.

Para controlar el overfitting identificado en experimentos preliminares, se implementó una estrategia de regularización intensiva que incluye múltiples técnicas complementarias: Learning Rate Ultra-bajo explorando rango [8e-7, 5e-6] con valor óptimo 2e-06 para convergencia controlada; Dropout Agresivo en rango [0.4, 0.7] con valor óptimo 0.7 para prevención de co-adaptación; Regularización L2 en rango [0.05, 0.5] con valor óptimo 0.05 para control de pesos; Weight Decay Manual fijo en 0.02 aplicado por batch; Noise Injection en rango [0.01, 0.03] con valor óptimo 0.03 como alternativa a label smoothing; y Batch Size Variable en conjunto 4, 6, 8 con valor óptimo 4 para mayor regularización.

La optimización de hiperparámetros se realizó mediante una búsqueda sistemática que combinó exploración manual y búsqueda en cuadrícula (grid search) en los rangos especificados. El proceso se estructuró en las siguientes etapas: búsqueda inicial con exploración amplia de rangos para identificar regiones prometedoras; refinamiento mediante búsqueda focalizada en torno a los mejores candidatos iniciales; validación cruzada confirmando estabilidad con múltiples semillas aleatorias (k=5); y selección final evaluando en conjunto de validación para determinar configuración óptima.

4.6. Metodología de evaluación comparativa

Para garantizar una comparación justa y rigurosa entre ambos paradigmas, se estableció un protocolo de evaluación común que eliminara sesgos metodológicos y permitiera una comparación objetiva del rendimiento. Ambos enfoques fueron sometidos al mismo esquema de evaluación estructurado que garantiza la imparcialidad y reproducibilidad de los resultados.

Para la evaluación de modelos de clasificación binaria en detección de noticias

falsas, todas las métricas se derivan de la matriz de confusión, que categoriza las predicciones según su correspondencia con la realidad. Los cuatro casos posibles son: Verdaderos Positivos (TP) cuando la predicción es REAL y la realidad es REAL, correspondiendo a contenido real correctamente identificado como real con impacto positivo preservando información legítima; Verdaderos Negativos (TN) cuando la predicción es FALSO y la realidad es FALSO, correspondiendo a contenido falso correctamente identificado como falso con impacto positivo detectando desinformación; Falsos Positivos (FP) cuando la predicción es REAL pero la realidad es FALSO, correspondiendo a contenido falso incorrectamente clasificado como real con impacto negativo permitiendo propagación de falsedad; y Falsos Negativos (FN) cuando la predicción es FALSO pero la realidad es REAL, correspondiendo a contenido real incorrectamente clasificado como falso con impacto negativo censurando información legítima.

La selección de métricas de evaluación en este trabajo se fundamenta en los estándares establecidos por la literatura especializada y los marcos de evaluación reconocidos internacionalmente. Como establece Gómez-Adorno et al. [46] en su consolidación de métricas FakeDeS para detección en español, la evaluación rigurosa requiere un conjunto comprehensivo de medidas que capturen diferentes aspectos del rendimiento del modelo. Los talleres CheckThat! organizados en el marco de CLEF [43, 44] han estandarizado el uso de métricas específicas que permiten la comparación directa entre sistemas, estableciendo que las métricas necesarias para clasificación binaria deben incluir: exactitud, precisión, exhaustividad (recall), F1-Score y especificidad. Esta estandarización garantiza la reproducibilidad y comparabilidad de los resultados con el estado del arte internacional.

Para que una función pueda considerarse una métrica válida en el contexto matemático, debe cumplir con propiedades formales específicas. Las métricas implementadas en este trabajo satisfacen los siguientes axiomas fundamentales: axioma de normalización donde todas las métricas están normalizadas en el rango $[0,1]$ con valor 0 indicando rendimiento mínimo posible, valor 1 indicando rendimiento máximo posible, y esta propiedad permitiendo comparabilidad directa entre métricas diferentes; axioma de monotonía donde las métricas son monotónicamente crecientes respecto a las predicciones correctas con incremento en TP implicando incremento en Precisión, Recall, F1-Score y Exactitud, e incremento en TN implicando incremento en Especificidad y Exactitud, garantizando que mejores predicciones resulten en mejores valores de métrica; axioma de sensibilidad donde las métricas reaccionan apropiadamente a cambios en los componentes de la matriz de confusión con cambios en FP afectando negativamente a Precisión y Especificidad, y cambios en FN afectando negativamente a Recall y Exactitud, permitiendo detectar diferentes tipos de errores del modelo; axioma de complementariedad donde las métricas capturan aspectos complementarios del rendimiento con Precisión midiendo calidad de predicciones positivas, Recall midiendo cobertura de casos positivos reales, F1-Score equilibrando ambos aspectos mediante media armónica, y Especificidad midiendo calidad en clase negativa; y propiedad de consistencia con literatura donde las definiciones implementadas son

consistentes con marcos de evaluación IberLEF [45], estándares CheckThat! CLEF [44], métricas utilizadas en trabajos de referencia [12, 13], y protocolos de evaluación en competencias internacionales.

Utilizando las definiciones anteriores, el rendimiento se evaluó con un conjunto comprehensivo de métricas estándar: Exactitud calculada como $\frac{TP+TN}{TP+TN+FP+FN}$ interpretándose como proporción total de predicciones correctas, con relevancia en detección como rendimiento general en datos balanceados; Precisión calculada como $\frac{TP}{TP+FP}$ interpretándose como confiabilidad de predicciones positivas, con relevancia en detección para minimizar falsas alarmas de contenido falso; Exhaustividad calculada como $\frac{TP}{TP+FN}$ interpretándose como capacidad de detectar casos positivos reales, con relevancia en detección para detectar todo contenido verdaderamente falso; F1-Score calculado como $2 \times \frac{Precision \times Recall}{Precision + Recall}$ interpretándose como balance entre precisión y exhaustividad, con relevancia en detección como métrica principal para comparación de modelos; y Especificidad calculada como $\frac{TN}{TN+FP}$ interpretándose como capacidad de identificar casos negativos correctos, con relevancia en detección para evitar clasificar contenido real como falso.

En el contexto de detección de noticias falsas, cada tipo de error tiene implicaciones específicas: Falsos Positivos (FP) con contenido real clasificado como falso pueden generar censura indebida y limitar la libertad de información; Falsos Negativos (FN) con contenido falso no detectado permiten propagación de desinformación y daño social; el equilibrio requiere un balance cuidadoso entre la identificación efectiva de contenido falso y la preservación de la libertad de información legítima; y en consideraciones prácticas, en implementaciones reales los falsos positivos pueden ser más aceptables cuando existe un proceso de revisión humana que puede corregir estas decisiones automáticas.

La selección del modelo óptimo se basará en una evaluación multi-criterio que considera diferentes aspectos del rendimiento: Rendimiento Predictivo con peso del 40 %, métrica principal F1-Score y métricas secundarias Precision, Recall, Accuracy y Specificity, justificándose como capacidad relevante de clasificación; Estabilidad del Modelo con peso del 25 %, métrica principal Desviación estándar F1 y métricas secundarias varianza en múltiples ejecuciones, justificándose como consistencia y confiabilidad; Eficiencia Computacional con peso del 20 %, métrica principal Tiempo de inferencia y métricas secundarias Memoria utilizada y Recursos GPU/CPU, justificándose como viabilidad práctica de implementación; y Capacidad de Generalización con peso del 15 %, métrica principal Gap Training-Test y métricas secundarias diferencia entre rendimiento interno y externo, justificándose como robustez ante datos no vistos.

Se realizará un análisis detallado de las matrices de confusión para comprender el comportamiento específico de cada modelo mediante: análisis por clase identificando sesgos hacia noticias reales o falsas; análisis de errores con caracterización cualitativa de casos mal clasificados; visualización mediante mapas de calor normalizados para comparación visual; e interpretabilidad con análisis de características más influyentes en decisiones.

Los resultados se presentarán siguiendo un formato estandarizado que incluye:

tabla de métricas principales con Accuracy, Precision, Recall, F1-Score y Specificity; análisis de variabilidad mediante Media $\pm$ desviación estándar por métrica; benchmarking de eficiencia con tiempos de inferencia y uso de recursos; matrices de confusión con visualización normalizada y análisis de errores; y recomendación final con modelo seleccionado y justificación integral.

Esta metodología de evaluación comprensiva garantiza una comparación objetiva, estadísticamente robusta y prácticamente relevante entre los paradigmas de algoritmos metaheurísticos y modelos Transformer para la detección de noticias falsas en español.

4.7. Infraestructura computacional y herramientas

El desarrollo de los algoritmos metaheurísticos se realizó en un entorno cloud optimizado para experimentación iterativa y flexibilidad de recursos utilizando Google Colab Pro con acceso a recursos escalables, procesamiento mediante CPU Intel/AMD variable suficiente para algoritmos iterativos, memoria RAM de 12-16 GB para carga completa de datasets, almacenamiento con Google Drive integrado y sin requerimiento de GPU dado que los algoritmos son CPU-intensivos.

La implementación utilizó un ecosistema de software cuidadosamente seleccionado para garantizar compatibilidad y rendimiento óptimo. Python 3.9.x como lenguaje principal proporcionando compatibilidad con ecosistema ML; TensorFlow 2.15.0 como framework principal para DistilBERT con soporte GPU optimizado; transformers de Hugging Face 4.35.0 proporcionando modelos preentrenados y tokenización avanzada; scikit-learn 1.3.2 para algoritmos metaheurísticos y métricas de evaluación; pandas 2.1.3 para manipulación de datasets; numpy 1.25.2 para operaciones matriciales y algoritmos de optimización; NLTK 3.8.1 para preprocesamiento de texto; matplotlib 3.8.1 y seaborn 0.12.2 para visualización; joblib 1.3.2 para persistencia de modelos; Flask 2.3.3 como API REST para aplicación final; y Docker 24.0.x para deployment reproducible.

El desarrollo de herramientas de detección de desinformación conlleva importantes consideraciones éticas que deben ser abordadas de manera integral y transparente. Se estableció un marco ético comprehensivo que guía todas las decisiones de diseño e implementación. El principio de Transparencia se implementó mediante código fuente abierto y metodología pública, con mecanismo de control a través de repositorio GitHub público y documentación completa, generando impacto esperado de auditoría independiente y reproducibilidad científica. El principio de Responsabilidad se implementó posicionando la herramienta como apoyo sin ser decisión final, con mecanismo de control mediante interfaz con disclaimers y scores de confianza, generando impacto esperado de uso responsable y juicio humano preservado. El principio de Privacidad se implementó mediante procesamiento local y sin almacenamiento personal, con mecanismo de control de anonimización automática y logs temporales únicamente, generando impacto esperado de protección de datos y cumplimiento GDPR. El principio de Equidad se implementó mediante datasets balanceados y evaluación

multi-métrica, con mecanismo de control de análisis de sesgos y validación cruzada, generando impacto esperado de tratamiento imparcial y reducción de discriminación.

Se establecieron limitaciones claras y recomendaciones de uso responsable considerando el alcance geográfico optimizado para español que puede tener limitaciones en variantes regionales específicas; contexto temporal con entrenamiento usando datos hasta 2025 pudiendo requerir actualización para tendencias futuras; dominios específicos enfocados en noticias generales pudiendo tener menor precisión en contenido altamente técnico; y posicionándose como herramienta de apoyo diseñada para asistir sin reemplazar el criterio editorial humano.

La reproducibilidad científica constituye un pilar relevante de esta investigación, implementándose protocolos para garantizar que los resultados puedan ser verificados independientemente por la comunidad científica. Para facilitar la reproducción completa del estudio y su extensión por parte de la comunidad científica, se desarrollará un ecosistema integral de artefactos que abarca desde el código fuente hasta modelos completamente entrenados listos para producción. El código fuente completo en formato GitHub repository incluye scripts de entrenamiento, algoritmos implementados y flujo de datos completo disponible públicamente con licencia MIT. Los datasets procesados en formato CSV con metadata incluyen corpus unificado, división train/val/test y estadísticas descriptivas disponibles públicamente respetando licencias originales. Los modelos entrenados en formato joblib para metaheurísticos y SavedModel para DistilBERT incluyen pesos optimizados, configuraciones y métricas de evaluación disponibles públicamente en Hugging Face Hub. El entorno de ejecución mediante Docker containers incluye imagen completa, dependencias exactas y scripts de ejecución disponibles en Docker Hub público. Los resultados experimentales en formato JSON con visualizaciones incluyen métricas detalladas, matrices de confusión y logs de entrenamiento disponibles en repositorio principal como supplementary material.

Como parte del compromiso con la transferencia tecnológica y la aplicabilidad práctica de los resultados, se entregará un repositorio completo con el mejor modelo identificado durante la evaluación comparativa, completamente optimizado y listo para ser desplegado en entornos de producción. Esta solución incluirá: modelo pre-entrenado optimizado siendo el modelo con mejor rendimiento según las métricas de evaluación con pesos finales y configuración optimizada; interfaz web completa desarrollada con Flask incluyendo opciones para análisis de URLs y texto directo; contenerización Docker mediante imagen completa con todas las dependencias, configuraciones y el modelo integrado; y despliegue con un comando mediante script automatizado que permite poner en funcionamiento toda la aplicación ejecutando únicamente un comando.

La estrategia de contenerización garantiza que la solución sea completamente portable y reproducible en cualquier entorno que soporte Docker, eliminando problemas de compatibilidad y dependencias.

Capítulo 5

Resultados, Evaluación Comparativa e Implementación

Este capítulo presenta el análisis integral de los resultados obtenidos mediante la metodología unificada desarrollada para la detección de noticias falsas en español. Los resultados se organizan siguiendo la estructura evolutiva de la metodología: comenzando con la validación del flujo de procesamiento de datos común, continuando con la evaluación de los modelos clásicos optimizados con algoritmos metaheurísticos que establecen la línea base, progresando hacia los resultados del modelo Transformer DistilBERT, culminando con una evaluación comparativa integral que justifica la selección del modelo final y demostrando su viabilidad práctica mediante la implementación de prototipos funcionales.

El análisis estadístico se fundamenta en un marco de evaluación unificado que emplea las métricas definidas en la metodología: exactitud (accuracy), precisión (precision), exhaustividad (recall), F1-Score y especificidad. Todos los experimentos se ejecutaron bajo condiciones experimentales idénticas para garantizar comparabilidad objetiva: mismo corpus, misma división de datos (70 % entrenamiento, 10 % validación, 20 % prueba) y mismo protocolo de validación.

5.1. Síntesis de resultados y contribuciones principales

Este capítulo presenta la validación experimental de la metodología evolutiva desarrollada, demostrando la superioridad de los modelos de lenguaje modernos sobre los enfoques clásicos optimizados para la detección de noticias falsas en español [13, 23]. A continuación, se presenta una síntesis de los logros y contribuciones clave derivados de este análisis.

El proceso de investigación culminó con la consolidación de un corpus a gran escala de **61,674 noticias únicas**, logrando un balance de clases casi perfecto (49.8 % FALSO / 50.2 % REAL) para la división de datos [11, 12, 19, 13]. Sobre esta base, se estableció primero un "techo de rendimiento" para los enfoques clásicos (TF-IDF), donde el mejor modelo optimizado con un **Algoritmo Genético (GA)** alcanzó una **exactitud máxima de 71.06 %** [23]. Para superar esta línea base, se desarrolló un modelo **DistilBERT** optimizado [20] mediante un riguroso proceso de 7 versiones experimentales y regularización múltiple, logrando alcanzar una **exactitud final de 95.2 %**. El resultado final demostró la superioridad categórica del enfoque de aprendizaje profundo, con una **mejora absoluta de +24.14 puntos porcentuales** en exactitud sobre la mejor línea base metaheurística.

5.1.1. Mapa Conceptual de Contribuciones del Capítulo

La Figura 5.1 ilustra la relación entre las contribuciones clave de este capítulo, mostrando cómo la validación de la línea base (metaheurísticas) [23, 40] justifica la transición al modelo Transformer [24, 20], y cómo la evaluación comparativa da lugar a la selección del modelo final para la implementación del prototipo.

Mapa Conceptual de Contribuciones




Figura 5.1: Mapa conceptual de las contribuciones clave derivadas del análisis de resultados.

5.1.2. Tabla Comparativa entre Paradigmas

La Tabla 5.1 resume las diferencias principales entre los dos paradigmas evaluados, destacando las ventajas y desventajas en rendimiento, complejidad y recursos.

Dimensión de Análisis	Enfoque 1: Metaheurístico (GA)	Enfoque 2: Transformer (DistilBERT)
Modelo Base	Clasificador Logístico	DistilBERT pre-entrenado [20]
Representación Textual	TF-IDF (Estática, 500 caract.) [35, 36]	Embeddings Contextuales (Dinámicos)
Rendimiento (Exactitud)	71.06 % [23]	95.2 %
Detección "FALSOS"	Baja (Especificidad 48 %) [23]	Excelente (Especificidad 94.96 %)
Equilibrio de Clases	Desbalanceado (Sesgo a clase REAL)	Perfectamente Balanceado
Recursos de Entrenamiento	CPU (Tiempos razonables) [40]	GPU (NVIDIA RTX 4060, >500 horas) [65]
Interpretabilidad	Alta (Pesos de características)	Baja (Modelo caja negra)
Modelo de Aplicación	modelo_metaheuristico.joblib	modelo_final_distilbert_es

Tabla 5.1: Comparativa de alto nivel entre los paradigmas de detección implementados.

5.2. Validación del flujo de procesamiento y representaciones

Antes de proceder con la evaluación de modelos, se validó la robustez del flujo de procesamiento desarrollado, que constituye la base común para ambos enfoques de modelado. El corpus utilizado para todos los experimentos presentaba las siguientes características tras el proceso de unificación y limpieza:

ID	Nombre del Corpus	Autores Principales	Año	Noticias	Características	Ref.
1	Spanish Fake News Corpus (IberLEF)	Posadas-Durán, J.P. Gómez-Adorno, H.	2019-2021	971	Análisis estilométrico Múltiples versiones	[12]
2	Conjunto de datos Zules Acosta (UPM)	Acosta, F.A.Z.	2019	598	Trabajo fin de maestría Extracción web verificada	[11]
3	Conjunto de datos Tretiakov (Kaggle)	Tretiakov, A. Martín García, A.	2022	1,958	Aprendizaje automático Disponible públicamente	[19]
4	Spanish Political Fake News Conjunto de datos	Blanco-Fernández, Y. Otero-Vizoso, J.	2024	57,231	Temática política Modelos BERT/RoBERTa	[13]

Tabla 5.2: Corpus académicos utilizados para la construcción del conjunto de datos unificado.

La representación textual se basó en TF-IDF con una configuración específica que equilibra capacidad discriminativa y eficiencia computacional. Se estableció un vocabulario inicial de 5,000 términos más frecuentes del corpus, sobre el cual se aplicó una reducción de dimensionalidad mediante selección del 10 % más discriminativo (500 características) utilizando el test chi-cuadrado. Esta selección representa un balance óptimo ya que experimentos preliminares con más de 1,000 características mostraron mejoras marginales en exactitud (<2 %) a costa de incrementos importantes en tiempo de convergencia (>300 %), haciendo inviable la optimización metaheurística en tiempos razonables. La representación final genera una matriz dispersa de 500 dimensiones por documento que alimenta a un clasificador logístico binario con función

de activación sigmoide, cuyos parámetros optimizados incluyen la selección de características, pesos del modelo y umbrales de decisión, maximizando la exactitud en el conjunto de entrenamiento.

5.2.1. Implementación y configuración de algoritmos metaheurísticos

La Tabla 5.3 presenta la configuración detallada de parámetros para cada algoritmo metaheurístico implementado. Estos valores fueron establecidos siguiendo las mejores prácticas reportadas en la literatura y ajustados experimentalmente para el dominio específico de detección de noticias falsas.

Parámetro	MSA	SS	GA	VNS	PSO
Iteraciones/Generaciones	31 temperaturas	10 iteraciones	20 generaciones	20 iteraciones	20 iteraciones
Población/Agentes	5 multiarranques	50 soluciones	50 individuos	1 solución	30 partículas
Parámetro Principal 1	Temp. inicial: 1000	RefSet: 5 soluciones	Tasa mutación: 0.1	k_max: 5 vecindarios	Factor inercia: 0.5
Parámetro Principal 2	Temp. final: 1.24	Combinaciones: 10 por iteración	Torneo: 3 competidores	Estrategia: k elementos	Coef. cognitivo: 1.5
Parámetro Principal 3	Factor enfriamiento: 0.8	Mejora: Mutación aleatoria	Cruce: Un punto	Aceptación: Solo mejora	Coef. social: 1.5
Característica Especial	100 pasos por temperatura	Combinación sistemática	Selección determinística	Reinicio a k=1 tras mejora	Velocidad gaussiana inicial
Filosofía de Búsqueda	Aceptación probabilística	Combinación estructurada	Evolución darwiniana	Cambio de vecindarios	Inteligencia de enjambre

Tabla 5.3: Configuración detallada de parámetros para los cinco algoritmos metaheurísticos implementados.

Los parámetros establecidos se fundamentan en valores base extraídos de trabajos originales para cada algoritmo, configurados para mantener un balance exploración-explotación que evite convergencia prematura, con límites de iteraciones que garanticen tiempos de ejecución razonables y parámetros que aseguren reproducibilidad de resultados.

5.2.2. Pseudocódigos de los algoritmos implementados

Todos los algoritmos metaheurísticos utilizan una función de evaluación unificada que implementa un clasificador logístico binario para garantizar comparabilidad directa entre enfoques. La Tabla 5.4 presenta el pseudocódigo detallado de esta función común.

El algoritmo MSA implementa una estrategia de multiarranque que ejecuta múltiples instancias de recocido simulado desde diferentes puntos de inicio, aprovechando la aceptación probabilística para escapar de óptimos locales. La Tabla 5.5 presenta el pseudocódigo detallado del algoritmo implementado.

El algoritmo SS utiliza una estrategia de combinación sistemática que mantiene un conjunto de referencia con las mejores soluciones y genera nuevas soluciones mediante cruces estructurados. La Tabla 5.6 presenta el pseudocódigo detallado del algoritmo implementado.

Función: evaluar_solucion (<i>solucion, pesos, umbrales, X, y</i>)	
Entrada:	Índices de características, pesos, umbrales, datos X , etiquetas y
Salida:	Tupla (exactitud, predicciones)
Proceso de clasificación logística:	
Para cada instancia i en X :	
$caracteristicas_activas \leftarrow X[i, solucion]$	
$x_binario \leftarrow (caracteristicas_activas \geq umbrales).astype(int)$	
$logit \leftarrow np.dot(pesos, x_binario)$	
$probabilidad \leftarrow \frac{1}{1+\exp(-logit)}$	
$clase_predicha \leftarrow 1$ si $probabilidad \geq 0.5$, 0 en otro caso	
$exactitud \leftarrow accuracy_score(y, predicciones)$	
Retornar ($exactitud, np.array(predicciones)$)	

Tabla 5.4: Función de evaluación común utilizada por todos los algoritmos metaheurísticos.

Algoritmo MSA - Multi-Start Simulated Annealing	
Entrada:	$TI = 1000, TF = 1, \alpha = 0.8, pasos = 100, puntos = 5$
Salida:	Mejor solución ($sol^*, pesos^*, umbrales^*$)
0. Carga y preprocesamiento de datos:	
Cargar corpus TF-IDF desde archivo CSV	
Dividir datos: 80 % entrenamiento, 10 % validación, 10 % pruebas	
Aplicar SelectPercentile(percentile=10) para reducir características	
1. Inicialización multiarranque:	
Para $k = 1$ hasta $puntos = 5$:	
$soluciones[k] \leftarrow np.random.randint(0, num_caracteristicas, size=num_caracteristicas)$	
$pesos[k] \leftarrow np.random.uniform(-10, 10, size=num_caracteristicas)$	
$umbrales[k] \leftarrow np.random.uniform(0, 1, size=num_caracteristicas)$	
$evaluaciones[k] \leftarrow evaluar_solucion(soluciones[k], pesos[k], umbrales[k])$	
2. Proceso de enfriamiento gradual:	
$TA \leftarrow TI = 1000$	
Mientras $TA > TF = 1$:	
Para $k = 1$ hasta $puntos$:	
Para $paso = 1$ hasta $pasos = 100$:	
Generar solución vecina modificando elemento aleatorio	
$\Delta E \leftarrow eval_vecina - evaluaciones[k]$	
Si $\Delta E > 0$ o $random() < \exp(\Delta E/TA)$:	
Aceptar solución vecina	
$TA \leftarrow TA \times \alpha = TA \times 0.8$	
3. Evaluación final:	
$idx_mejor \leftarrow \arg \max(evaluaciones)$	
Evaluar mejor solución en conjunto de pruebas	
Generar reporte de clasificación y matriz de confusión	
Guardar gráficas de convergencia y resultados	

Tabla 5.5: Pseudocódigo completo del algoritmo Multi-Start Simulated Annealing (MSA).

Algoritmo SS - Scatter Search	
Entrada:	$P = 50, b = 5, max_iteraciones = 10, num_combinaciones = 10$
Salida:	Mejor solución del RefSet final
0. Carga y preprocesamiento de datos:	
Cargar corpus TF-IDF desde archivo CSV	
Dividir datos: 80 % entrenamiento, 10 % validación, 10 % pruebas	
Aplicar SelectPercentile(percentile=10) para reducir características	
1. Generación de población inicial diversa:	
Para $i = 1$ hasta $P = 50$: generar solución aleatoria y evaluar	
Ordenar población por score descendente	
$ref_set \leftarrow poblacion[: b]$ (mejores $b = 5$ soluciones)	
2. Proceso iterativo de mejora:	
Para $iteracion = 1$ hasta $max_iteraciones = 10$:	
Para $c = 1$ hasta $num_combinaciones = 10$:	
Seleccionar aleatoriamente $s1, s2 \in ref_set$	
Aplicar cruce en punto aleatorio + mutación	
Evaluar nueva solución	
Actualizar ref_set con mejores b soluciones	
3. Evaluación final:	
Evaluar mejor solución del RefSet en conjunto de pruebas	
Generar reporte de clasificación y matriz de confusión	
Guardar gráficas de convergencia y resultados	

Tabla 5.6: Pseudocódigo completo del algoritmo Scatter Search (SS).

El algoritmo GA emplea una estrategia evolutiva basada en principios darwinianos, utilizando selección por torneo, cruce de un punto y mutación para evolucionar una población hacia mejores soluciones. La Tabla 5.7 presenta el pseudocódigo detallado del algoritmo implementado.

El algoritmo VNS implementa una búsqueda sistemática que cambia de estructura de vecindario cuando no encuentra mejoras, reiniciando a la primera vecindad tras cada mejora encontrada. La Tabla 5.8 presenta el pseudocódigo detallado del algoritmo implementado.

El algoritmo PSO simula el comportamiento de enjambres mediante partículas que ajustan su velocidad basándose en su mejor posición personal y la mejor posición global del enjambre. La Tabla 5.9 presenta el pseudocódigo detallado del algoritmo implementado.

Los pseudocódigos presentados reflejan la implementación real utilizada en los experimentos, capturando tanto la lógica algorítmica como las etapas de carga de datos y evaluación final. Cada algoritmo optimiza simultáneamente la selección de características, los pesos del clasificador logístico y los umbrales de binarización.

Algoritmo GA - Genetic Algorithm	
Entrada:	$num_generaciones = 20$, $tam_poblacion = 50$, $tasa_mutacion = 0.1$, $tam_torneo = 3$
Salida:	Mejor individuo global encontrado
0. Carga y preprocesamiento de datos:	
Cargar corpus TF-IDF desde archivo CSV	
Dividir datos: 80 % entrenamiento, 10 % validación, 10 % pruebas	
Aplicar SelectPercentile(percentile=10) para reducir características	
1. Inicialización y proceso evolutivo:	
Generar población inicial de $tam_poblacion = 50$ individuos	
Para $gen = 1$ hasta $num_generaciones = 20$:	
Evaluar toda la población	
Actualizar mejor global si es necesario	
Para $i = 1$ hasta $tam_poblacion/2$:	
Seleccionar padres por torneo ($k=3$)	
Aplicar cruce de un punto	
Aplicar mutación con probabilidad 0.1	
2. Evaluación final:	
Evaluar mejor individuo global en conjunto de pruebas	
Generar reporte de clasificación y matriz de confusión	
Guardar gráficas de convergencia y resultados	

Tabla 5.7: Pseudocódigo completo del Algoritmo Genético (GA).

Algoritmo VNS - Variable Neighborhood Search	
Entrada:	$max_iteraciones = 20$, $k_max = 5$
Salida:	Mejor solución global encontrada
0. Carga y preprocesamiento de datos:	
Cargar corpus TF-IDF desde archivo CSV	
Dividir datos: 80 % entrenamiento, 10 % validación, 10 % pruebas	
Aplicar SelectPercentile(percentile=10) para reducir características	
1. Inicialización y búsqueda en vecindades:	
Generar solución inicial aleatoria	
Para $i = 1$ hasta $max_iteraciones = 20$:	
$k \leftarrow 1$	
Mientras $k \leq k_max = 5$:	
Generar vecino modificando k elementos aleatorios	
Si mejora: aceptar y $k \leftarrow 1$	
Sino: $k \leftarrow k + 1$	
2. Evaluación final:	
Evaluar mejor solución global en conjunto de pruebas	
Generar reporte de clasificación y matriz de confusión	
Guardar gráficas de convergencia y resultados	

Tabla 5.8: Pseudocódigo completo del algoritmo Variable Neighborhood Search (VNS).

Algoritmo PSO - Particle Swarm Optimization	
Entrada:	$num_particulas = 30$, $max_iteraciones = 20$, $w = 0.5$, $c1 = 1.5$, $c2 = 1.5$
Salida:	Mejor posición global del enjambre
0. Carga y preprocesamiento de datos:	
Cargar corpus TF-IDF desde archivo CSV	
Dividir datos: 80 % entrenamiento, 10 % validación, 10 % pruebas	
Aplicar SelectPercentile(percentile=10) para reducir características	
1. Inicialización del enjambre:	
$solucion_fija \leftarrow np.arange(num_caracteristicas)$	
Inicializar 30 partículas con posiciones y velocidades aleatorias	
Evaluar partículas e inicializar mejores personal y global	
2. Optimización del enjambre:	
Para $i = 1$ hasta $max_iteraciones = 20$:	
Para cada partícula:	
Actualizar velocidad: componente cognitiva + social	
Actualizar posición: $posicion + velocidad$	
Evaluar y actualizar mejores personal y global	
3. Evaluación final:	
Evaluar mejor posición global en conjunto de pruebas	
Generar reporte de clasificación y matriz de confusión	
Guardar gráficas de convergencia y resultados	

Tabla 5.9: Pseudocódigo completo del algoritmo Particle Swarm Optimization (PSO).

5.2.3. Visualizaciones de resultados por algoritmo

Esta sección presenta las visualizaciones generadas por cada algoritmo metaheurístico durante la ejecución experimental. Para cada algoritmo se incluyen dos gráficas: la evolución de la convergencia durante el entrenamiento y la matriz de confusión resultante en el conjunto de pruebas.

El algoritmo MSA presenta un comportamiento de convergencia caracterizado por múltiples puntos de inicio y aceptación probabilística de soluciones. Su estrategia de multiarranque permite explorar diferentes regiones del espacio de búsqueda, mientras que el esquema de enfriamiento gradual facilita la transición entre exploración y explotación.




Figura 5.2: Evolución de la convergencia del algoritmo MSA mostrando el progreso gradual a través de los 31 niveles de temperatura desde 1000 hasta 1.24.




Figura 5.3: Matriz de confusión para MSA en el conjunto de pruebas, evidenciando la baja especificidad (33 %) y el sesgo hacia la clasificación como noticias reales.

El algoritmo SS implementa una estrategia de combinación sistemática que mantiene un conjunto de referencia élite y genera nuevas soluciones mediante cruces es-

tructurados. Su enfoque de búsqueda dispersa permite mantener diversidad mientras intensifica la búsqueda en regiones prometedoras, resultando en una convergencia eficiente y estable.




Figura 5.4: Convergencia eficiente del algoritmo SS en solo 10 iteraciones, mostrando mejoras progresivas en las iteraciones 4, 5 y 7 hasta estabilizarse en 0.6630.




Figura 5.5: Matriz de confusión para SS demostrando mejor balance que MSA con especificidad del 40 % y excelente generalización.

El algoritmo GA exhibe un proceso evolutivo robusto basado en principios darwinianos, donde la selección por torneo, el cruce de un punto y la mutación controlada trabajan en conjunto para evolucionar la población hacia mejores soluciones. Su capacidad para mantener diversidad genética mientras converge gradualmente hacia óptimos se refleja en las siguientes visualizaciones.




Figura 5.6: Evolución darwiniana del algoritmo GA a lo largo de 20 generaciones, evidenciando progreso sostenido desde 0.6198 hasta 0.7090 con logros evolutivos significativos.




Figura 5.7: Matriz de confusión para GA mostrando el mejor balance global con especificidad líder del 48 % y rendimiento sólido en ambas clases.

El algoritmo VNS demuestra una estrategia de búsqueda sistemática que cambia dinámicamente entre diferentes estructuras de vecindario. Su mecanismo de reinicio tras cada mejora y la exploración progresiva de vecindarios más amplios permite escapar efectivamente de óptimos locales, generando un patrón de convergencia característico con saltos significativos.




Figura 5.8: Progreso sistemático del algoritmo VNS a través de 20 iteraciones con cambios efectivos de vecindario, mostrando saltos significativos en las iteraciones 6 y 14.




Figura 5.9: Matriz de confusión para VNS destacando la excelente exhaustividad del 89 % para detección de noticias reales con especificidad competitiva del 41 %.

El algoritmo PSO simula el comportamiento colectivo de enjambres mediante partículas que ajustan su trayectoria basándose en información cognitiva y social. Sin

embargo, en este experimento específico, el algoritmo exhibe convergencia prematura y pérdida de diversidad del enjambre, lo que resulta en un estancamiento que limita significativamente su capacidad de exploración.




Figura 5.10: Convergencia problemática del algoritmo PSO evidenciando estancamiento prematuro en la iteración 7-8 y exploración insuficiente del espacio de búsqueda.




Figura 5.11: Matriz de confusión para PSO revelando el comportamiento extremo problemático con especificidad crítica del 15 % y sesgo severo hacia la clase mayoritaria.

Las matrices de confusión confirman los patrones de rendimiento identificados. GA muestra el mejor balance global entre especificidad y exhaustividad, mientras que VNS destaca en la detección de noticias reales manteniendo competitividad en noticias falsas. SS ofrece rendimiento equilibrado con buena estabilidad, MSA evidencia limitaciones en detección de noticias falsas, y PSO exhibe comportamiento inaceptable para aplicaciones prácticas. Estas visualizaciones proporcionan evidencia gráfica que facilita la comprensión del comportamiento específico de cada algoritmo metaheurístico en la tarea de detección de noticias falsas.

5.2.4. Contextualización con investigación publicada

Los hallazgos de esta investigación fueron formalizados y publicados en el capítulo de libro “Calibración de hiperparámetros en algoritmos metaheurísticos para la detección de fraude digital” [23]. Es importante destacar que en la versión publicada, la Búsqueda Dispersa (SS) obtuvo resultados iguales o ligeramente superiores al Algoritmo Genético, confirmando la competitividad de ambos enfoques. En los experimentos actuales, el Algoritmo Genético (GA) emergió como el mejor algoritmo con un F1-Score macro de 0.68 y exactitud del 71.06 %. Esta ligera variación en el ranking se atribuye a diferencias en la configuración específica de hiperparámetros y semillas aleatorias utilizadas en diferentes experimentos. Los resultados obtenidos son consistentes con investigación internacional reciente. Yildirim [40] realizó prue-

bas exhaustivas con múltiples algoritmos metaheurísticos, alcanzando exactitud del 78.8 % con SVM optimizado. Esta consistencia valida que los algoritmos metaheurísticos tienen un techo de rendimiento relativo cuando se aplican a representaciones tradicionales de texto.

5.2.5. Análisis comparativo de resultados

Algoritmo	Exactitud (%)	F1-Score (macro)	Precisión (macro)	Exhaustividad (macro)	F1-Score (weighted)	Ranking
GA	71.06	0.68	0.72	0.68	0.70	1 ^o
VNS	69.22	0.65	0.70	0.65	0.67	2 ^o
SS	66.12	0.62	0.66	0.62	0.64	3 ^o
MSA	58.36	0.54	0.56	0.55	0.56	4 ^o
PSO	63.98	0.51	0.74	0.57	0.55	5 ^o

Tabla 5.10: Resultados comparativos finales de los cinco algoritmos metaheurísticos implementados usando métricas macro promedio.

Algoritmo	Fortalezas Principales	Debilidades Críticas
GA	• Mejor F1-Score macro (0.68) • Mejor exactitud global (71.06 %) • Convergencia evolutiva estable	• Especificidad aún limitada (48 %) • Dependencia de operadores genéticos
VNS	• Segundo mejor F1-Score macro (0.65) • Cambios efectivos de vecindario • Buena precisión macro (0.70)	• Especificidad moderada (41 %) • Sensible a configuración de k
SS	• Convergencia eficiente • F1-Score macro competitivo (0.62) • Balance razonable	• Rendimiento intermedio • RefSet de tamaño fijo limitante
MSA	• Exploración exhaustiva • Múltiples puntos de inicio	• F1-Score macro bajo (0.54) • Convergencia lenta • Rendimiento general limitado
PSO	• Simplicidad conceptual • Alta precisión macro (0.74)	• F1-Score macro más bajo (0.51) • Convergencia prematura crítica • Especificidad extremadamente baja (15 %)

Tabla 5.11: Análisis de fortalezas y debilidades de cada algoritmo metaheurístico basado en las métricas obtenidas.

5.2.6. Limitaciones fundamentales y justificación para evolución

El análisis exhaustivo reveló limitaciones críticas que justifican la transición hacia Modelos de Lenguaje. En el ámbito de representación, la codificación TF-IDF provoca pérdida de información contextual y semántica, mientras que la reducción dimensional agresiva de 5,000 a 500 características elimina información relevante aunque incrementar dimensiones mejora métricas a costa de viabilidad computacional. Las representaciones estáticas resultan incapaces de modelar significados contextuales. En cuanto al rendimiento, se identifica un techo de rendimiento con F1-Score macro máximo de 0.68 (GA) como límite superior, especificidad crítica con mejor valor apenas

del 48 % para detectar noticias falsas, y variabilidad excesiva con F1-Score macro del 0.51 (PSO) al 0.68 (GA) indicando inestabilidad.

La investigación de Blanco-Fernández et al. [13] demuestra que modelos BERT y RoBERTa para detección de noticias falsas en español alcanzan exactitudes de más del 90 %, llegando hasta 98 %. Esta brecha de rendimiento de aproximadamente 20-27 puntos porcentuales justifica plenamente la transición hacia enfoques basados en Transformers.

Enfoque	Exactitud Máxima	F1-Score Macro Máximo	Diferencia vs. BERT
Metaheurísticos (GA)	71.06 %	0.68	-20 a -27 p.p.
Modelos de Lenguaje	90-98 %	0.90-0.98	Referencia

Tabla 5.12: Comparación de rendimiento entre enfoques metaheurísticos y Modelos de Lenguaje usando métricas macro.

Las contribuciones del enfoque metaheurístico incluyen la línea base establecida con F1-Score macro de 0.68 (GA) como referencia confiable, metodología validada mediante publicación exitosa del capítulo de libro [23], caracterización algorítmica clara de fortalezas y debilidades, eficiencia computacional con tiempos de entrenamiento razonables, e interpretabilidad con modelos explicables. Las limitaciones identificadas establecen la necesidad de evolucionar hacia enfoques más sofisticados debido a la brecha de rendimiento significativa de 22-30 puntos porcentuales respecto a Modelos de Lenguaje, representación textual limitada con TF-IDF como cuello de botella, comprensión semántica insuficiente con incapacidad para modelar relaciones contextuales complejas, y F1-Score macro limitado donde ningún algoritmo superó el 0.68. La experiencia obtenida durante la investigación del enfoque metaheurístico proporcionó resultados valiosos que orientaron el desarrollo del segundo enfoque basado en modelos Transformer, que será analizado en la siguiente sección de este capítulo.

5.3. Resultados del enfoque Transformer: DistilBERT multilingüe

La segunda fase de esta investigación se centró en el desarrollo y optimización de un modelo basado en la arquitectura Transformer, específicamente DistilBERT multilingüe, para superar las limitaciones identificadas en el enfoque metaheurístico. Este desarrollo representó un esfuerzo computacional considerable, involucrando más de 30 experimentos iterativos con tiempos de entrenamiento que oscilaron desde 30 minutos para pruebas con TinyBERT en inglés hasta más de 72 horas para entrenamientos completos con el corpus en español.

5.3.1. Marco experimental y evolución del desarrollo

El desarrollo del modelo DistilBERT requirió un proceso de experimentación que incluyó 3 pruebas iniciales con TinyBERT en inglés (30-45 minutos cada uno), 3 pruebas con BERT en inglés y español (24-48 horas cada uno), 8 pruebas con DistilBERT

multilingüe (12-24 horas cada uno), 7 pruebas especializadas anti-sobreajuste (48-72 horas cada uno), acumulando aproximadamente 500 horas totales de GPU hasta alcanzar la configuración final óptima con regularización máxima.

Para el entrenamiento del modelo DistilBERT se utilizó una versión expandida del corpus, que incorpora tanto fuentes académicas como datos obtenidos mediante extracción web:

Componente del Corpus	Noticias	Distribución	Fuente	Calidad
Corpus Académicos	60,758	98.5 %	Investigación verificada	Alta
Extracción web	916	1.5 %	Sitios de noticias	Verificada

Tabla 5.13: Composición del corpus expandido utilizado para el entrenamiento de DistilBERT.

La configuración final implementó una división específica para maximizar el rendimiento del modelo con 43,171 registros (70 %) para entrenamiento, 6,167 registros (10 %) para validación y 12,336 registros (20 %) para pruebas, manteniendo un balance de clases con 49.8 % noticias falsas y 50.2 % noticias reales.

5.3.2. Configuración del modelo DistilBERT optimizado

Componente	Configuración	Justificación
Modelo Base	distilbert-base-multilingual-cased	Soporte nativo para español
Secuencia Máxima	128 tokens	Balance rendimiento/sobreajuste
Formato de Entrada	título + [SEP] + texto	Información estructurada
Precisión	Mixed Float16	Optimización de memoria GPU
Núm. Etiquetas	2 (binario)	Clasificación falso/real

Tabla 5.14: Configuración de la arquitectura del modelo DistilBERT implementado.

El principal desafío durante el desarrollo fue el sobreajuste prematuro, que se manifestó consistentemente en los primeros experimentos. La configuración final implementó múltiples técnicas de regularización:

Técnica de Regularización	Valor/Configuración	Objetivo	Impacto
Tasa de Aprendizaje Ultra-Baja	2e-06	Convergencia gradual	Reducción sobreajuste
Dropout Agresivo	0.7	Prevenir co-adaptación	Generalización
Regularización L2	0.05	Penalización de pesos	Suavizado del modelo
Tamaño de Lote Pequeño	4	Mayor ruido en gradientes	Regularización implícita
Inyección de Ruido	0.03	Perturbación controlada	Robustez del modelo
Decaimiento de Pesos Manual	0.02	Decaimiento de pesos	Control de capacidad
Parada Temprana	Paciencia: 8 épocas	Detención automática	Prevención sobreajuste

Tabla 5.15: Técnicas de regularización implementadas en la configuración final.

5.3.3. Proceso de optimización y búsqueda de hiperparámetros

La optimización se realizó mediante Keras Tuner con búsqueda aleatoria sobre un espacio de hiperparámetros cuidadosamente diseñado. Se exploraron tasas de aprendizaje $[5e-6, 2e-6, 1e-6, 8e-7]$, dropout evaluados $[0.4, 0.5, 0.6, 0.7]$, regularización L2 $[0.05, 0.1, 0.2, 0.5]$ y tamaños de lote probados $[4, 6, 8]$, generando 192 combinaciones posibles de las cuales se ejecutaron 4 intentos limitados por recursos computacionales. La búsqueda automatizada identificó como configuración óptima una tasa de aprendizaje de $2e-06$ extremadamente conservadora, dropout rate de 0.7 con regularización agresiva, regularización L2 de 0.05 moderada-fuerte, factor de ruido de 0.03 con perturbación controlada, y tamaño de lote de 4 para máxima regularización implícita.

5.3.4. Análisis de convergencia y control de sobreajuste

El modelo final se entrenó durante 21 épocas antes de que el mecanismo de detención temprana detuviera el proceso. La época 13 fue identificada como el punto óptimo, marcando el momento antes del inicio del sobreajuste:




Figura 5.12: Evolución de la exactitud y pérdida durante el entrenamiento del modelo DistilBERT final. Las líneas azul y roja muestran la convergencia en entrenamiento y validación respectivamente. La estrella dorada marca la mejor época (13), después de la cual se observa el inicio del sobreajuste con una separación creciente entre las curvas.

La métrica clave para evaluar el sobreajuste fue el gap de pérdida (diferencia entre pérdida de validación y entrenamiento). En las épocas 1-9 el gap fue menor a 0.02 indicando convergencia excelente, en la época 10-13 el gap osciló entre 0.02-0.05 alcanzando parcialmente el objetivo, en épocas 14-21 el gap superó 0.05 marcando el inicio del sobreajuste, con un gap final en época 13 de 0.0492 cerca del objetivo de menor a 0.04.

La detención del entrenamiento en la época 13 se justifica por múltiples indicadores: pérdida de validación mínima registrada en 0.2214, gap de generalización controlado de 0.0492 cercano al objetivo de menor a 0.04, exactitud estabilizada de 95.04 % en validación sin mejoras posteriores, prevención de sobreajuste con épocas posteriores mostrando degradación clara, y eficiencia computacional evitando 9 épocas adicionales innecesarias.

5.3.5. Evolución experimental: versiones de desarrollo

El desarrollo del modelo DistilBERT final (V7) fue el resultado de un proceso iterativo exhaustivo que incluyó múltiples versiones experimentales, cada una diseñada para abordar limitaciones específicas identificadas en iteraciones anteriores. El proceso experimental siguió una metodología sistemática de refinamiento progresivo mediante identificación de problema mediante análisis de limitaciones en versión anterior, hipótesis de mejora formulando estrategias específicas, implementación controlada con modificación incremental de parámetros, evaluación rigurosa mediante métricas de convergencia y generalización, documentación sistemática registrando configuraciones y resultados, e iteración dirigida aplicando lecciones aprendidas.

Versión	Problema Objetivo	Estrategia Principal	Gap Final	Exactitud	Épocas	Estado
V1	Línea base	División 70/10/20, LR: 3e-05	N/A	94.7 %	6	Baseline
V2	Anti-sobreajuste inicial	División 60/20/20, LR ultra-bajo	0.02	94.3 %	8	Excelente
V3	Mejora inicial	División 60/20/20, LR reducido	0.03	94.8 %	11	Convergente
V4	Control sobreajuste	Anti-sobreajuste mejorado	0.04	95.8 %	7	Convergente
V5	Configuración híbrida	70/10/20 + anti-sobreajuste	0.04	95.8 %	11	Óptimo
V6	Regularización fuerte	L2 aumentado, dropout agresivo	0.10	94.8 %	8	Convergente
V7	Configuración final	Regularización máxima corregida	0.05	95.2 %	21	Final

Tabla 5.16: Resumen de versiones experimentales de DistilBERT con evolución de estrategias y resultados reales del desarrollo.




Figura 5.13: Evolución de exactitud a través de las versiones experimentales.

La versión V2 representó la superación de limitaciones previas con anti-sobreajuste,




Tabla 5.17: Visualización comparativa de convergencia y métricas para las versiones experimentales más significativas con DistilBERT.

Parámetro	V1	V2	V3	V4	V5	V6	V7
Tasa de Aprendizaje	3e-05	2e-06	2e-06	1e-05	1e-05	1e-05	2e-06
Dropout Rate	0.4	0.4	0.4	0.3	0.4	0.5	0.7
L2 Regularization	0.001	0.01	0.01	0.01	0.1	0.5	0.05
Tamaño de Lote	8	4	4	8	8	8	4
División Datos	70/10/20	60/20/20	60/20/20	60/20/20	70/10/20	60/20/20	70/10/20

Tabla 5.18: Evolución de configuraciones y resultados entre versiones experimentales.

siendo la primera implementación exitosa de regularización agresiva con gap excepcional de 0.018, estableciendo los fundamentos para versiones posteriores mediante tasa de aprendizaje ultra-bajo ($2e-06$) y tamaño de lote 4. Las versiones V4-V5 marcaron el pico de rendimiento alcanzando máxima exactitud (95.8 %) con gap controlado de 0.037, representando configuración óptima entre regularización y capacidad de aprendizaje. La versión V7 como configuración final implementó inyección de ruido y regularización máxima coordinada, alcanzando exactitud final de 95.2 % con gap de 0.050, representando el mejor balance convergencia-generalización.

Los factores críticos del éxito incluyen tasas de aprendizaje ultra-bajas ($2e-06$) esenciales para convergencia estable, regularización múltiple coordinada mediante L2 + dropout + weight decay + inyección de ruido, división de datos optimizada con 70/10/20 superior a 60/20/20, y detención temprana inteligente con detección precisa del punto óptimo.

5.3.6. Pseudocódigo del algoritmo de entrenamiento DistilBERT

Esta subsección presenta el pseudocódigo simplificado del algoritmo de entrenamiento DistilBERT final. La Tabla 5.19 expone el procedimiento completo. El algoritmo demuestra que la regularización coordinada múltiple es efectiva para controlar el sobreajuste en modelos Transformer para detección de noticias falsas en español. El código completo del entrenamiento está disponible en el repositorio de GitHub del proyecto. Dado que este modelo resultó ser el de mejor rendimiento en la evaluación comparativa, es el que se utilizará en el módulo web de la aplicación final para proporcionar detección de noticias falsas en tiempo real.

5.3.7. Resultados finales y comparación

La Tabla 5.21 presenta el desglose detallado de las métricas de rendimiento por clase para el modelo DistilBERT optimizado. Los resultados demuestran un **equilibrio excepcional** entre ambas clases, un aspecto crítico que valida la capacidad de generalización del modelo.

Para la clase **FALSO (0)** (noticias falsas), el modelo alcanza una precisión del 94.96 %, lo que significa que cuando predice que una noticia es falsa, acierta en el 94.96 % de los casos, minimizando así los falsos positivos que podrían censurar contenido legítimo. El recall del 95.44 % indica que el modelo identifica correctamente el 95.44 % de todas las noticias realmente falsas, demostrando una excelente capacidad para detectar desinformación sin dejar pasar casos peligrosos. El F1-Score resultante del 95.20 % confirma el balance óptimo entre precisión y exhaustividad para esta clase crítica.

Para la clase **REAL (1)** (noticias legítimas), el modelo muestra métricas simétricas con precisión del 95.44 % y recall del 94.96 %, alcanzando igualmente un F1-Score del 95.20 %. Esta simetría entre clases es particularmente relevante porque demuestra

Algoritmo DistilBERT final - Regularización Anti-Sobreaajuste	
Entrada:	Corpus español, hiperparámetros de regularización
Salida:	Modelo DistilBERT con $\text{gap} \leq 0.05$
1. Preparación de datos:	
Cargar corpus_unificado_es_deforma_completo.csv	
Dividir: 70 % entrenamiento, 10 % validación, 20 % pruebas	
Tokenizar con MAX_LENGTH=128	
Crear batches de tamaño 4	
2. Optimización de hiperparámetros:	
learning_rate $\leftarrow$ [2e-6, 1e-6, 8e-7] # Ultra-bajos	
dropout_rate $\leftarrow$ [0.5, 0.6, 0.7] # Agresivo	
l2_reg $\leftarrow$ [0.05, 0.1, 0.2] # Fuerte	
Ejecutar búsqueda con Keras Tuner	
3. Construcción del modelo:	
modelo $\leftarrow$ DistilBERT-multilingual-cased	
Aplicar dropout_rate a todas las capas	
Aplicar regularización L2 a pesos	
optimizer $\leftarrow$ Adam(lr=learning_rate_óptimo)	
4. Entrenamiento con regularización:	
Para época = 1 hasta 30:	
Entrenar en conjunto de entrenamiento	
Validar en conjunto de validación	
gap $\leftarrow$ val_loss - train_loss	
Si gap < 0.02: “EXCELENTE”	
Si 0.02 $\leq$ gap < 0.04: “BUENO”	
Si gap $\geq$ 0.04: “ALERTA”	
Si early_stopping activado: break	
5. Evaluación final:	
Restaurar mejores pesos	
Evaluar en conjunto de pruebas	
Calcular exactitud, precisión, recall, f1-score	
Guardar modelo final	

Tabla 5.19: Pseudocódigo simplificado del algoritmo DistilBERT final (V7).

Métrica	Valor	Calificación
Exactitud	95.2 %	Excelente
F1-Score	95.2 %	Excelente
Especificidad	94.96 %	Excelente
Sensibilidad	95.44 %	Excelente

Tabla 5.20: Métricas finales del modelo DistilBERT optimizado.

Clase	Precisión	Recall	F1-Score	Soporte
FALSO (0)	94.96 %	95.44 %	95.20 %	6,168
REAL (1)	95.44 %	94.96 %	95.20 %	6,168
Promedio Macro	95.20 %	95.20 %	95.20 %	12,336
Promedio Ponderado	95.20 %	95.20 %	95.20 %	12,336

Tabla 5.21: Desglose detallado de métricas por clase para el modelo DistilBERT optimizado, demostrando rendimiento equilibrado en ambas categorías.

que el modelo no está sesgado hacia ninguna categoría, evitando tanto la propagación de desinformación (falsos negativos) como la censura inadecuada de contenido legítimo (falsos positivos).

La **identidad entre los promedios macro y ponderados** (ambos 95.20 %) confirma que el corpus de prueba está perfectamente balanceado con 6,168 muestras en cada clase, y que el modelo no favorece la clase mayoritaria. Este equilibrio perfecto valida las decisiones metodológicas tomadas durante la construcción del corpus unificado, particularmente el proceso de balanceo mediante extracción web de 9,000 noticias falsas que garantizó la distribución equitativa 49.8 % / 50.2 % en el conjunto completo.

5.3.8. Análisis de sesgos inherentes en el modelo DistilBERT ajustado

A pesar del rendimiento excepcional alcanzado por el modelo DistilBERT ajustado (95.2 % de exactitud), es importante reconocer y documentar los sesgos inherentes que pueden afectar su comportamiento en escenarios de producción. El análisis de sesgos constituye un requisito de transparencia científica y responsabilidad ética en el desarrollo de sistemas de IA para detección de desinformación.

Los sesgos en modelos de lenguaje para detección de noticias falsas pueden clasificarse en tres categorías principales según su origen: sesgos de datos (derivados del corpus de entrenamiento), sesgos algorítmicos (inherentes a la arquitectura del modelo), y sesgos de despliegue (emergentes en contextos de uso real). La Tabla 5.22 presenta una clasificación sistemática de los sesgos identificados en el modelo desarrollado.

Categoría	Tipo de Sesgo	Manifestación	Impacto Potencial
Sesgos de Datos	Sesgo temático político	92.8 % del corpus proviene del dataset político de Blanco-Fernández	Mayor precisión en contenido político vs. otros dominios (deportes, ciencia, cultura)
Sesgos de Datos	Sesgo geográfico peninsular	Predominio de español de España (~70 % del corpus)	Posible menor sensibilidad a modismos latinoamericanos o variantes regionales
Sesgos de Datos	Sesgo temporal de actualidad	Datos concentrados en 2020-2025 (eventos COVID-19, crisis política)	Asociación implícita de ciertos temas/vocabulario con falsedad basada en contexto histórico
Sesgos de Datos	Sesgo de fuentes verificadas	Corpus construido desde sitios conocidos (medios tradicionales vs. sitios de desinformación)	Posible asociación de estilo/formato con veracidad en lugar de contenido factual
Sesgos Algorítmicos	Sesgo de pre-entrenamiento multilingüe	DistilBERT entrenado sobre Wikipedia (conocimiento enciclopédico)	Mayor confianza en contenido con estilo enciclopédico vs. periodístico coloquial
Sesgos Algorítmicos	Sesgo de longitud de secuencia	Truncamiento a 128 tokens (~100 palabras en español)	Pérdida de contexto en artículos largos; decisiones basadas solo en inicio del texto
Sesgos Algorítmicos	Sesgo de representación tokenizada	Tokenizador WordPiece optimizado para idiomas con más datos (inglés)	Fragmentación subóptima de términos específicos del español (neologismos, tecnicismos)
Sesgos de Despliegue	Sesgo de selección de contenido analizado	Sistema analiza solo texto presentado (no contexto externo)	Incapacidad de verificar afirmaciones factuales contra bases de datos externas
Sesgos de Despliegue	Sesgo de umbral de decisión	Umbral fijo en 0.5 para clasificación binaria	No considera costo asimétrico de falsos positivos (censura) vs. falsos negativos (desinformación)

Tabla 5.22: Taxonomía de sesgos identificados en el modelo DistilBERT ajustado para detección de noticias falsas en español.

Sesgos de datos y su impacto en el rendimiento del modelo. El sesgo más significativo del modelo proviene de la composición del corpus de entrenamiento, donde el 92.8 % de los datos corresponden al *Spanish Political Fake News Dataset* [13]. Este desbalance temático, aunque justificado por la relevancia social de la desinformación política, introduce una especialización implícita que puede manifestarse en diferencias de rendimiento entre dominios. Para cuantificar este efecto, se realizó un experimento de validación cruzada por dominio mediante muestreo aleatorio de 500 noticias del conjunto de prueba y clasificación manual en categorías temáticas. Los resultados preliminares, presentados en la Tabla 5.23, sugieren que el modelo mantiene un rendimiento robusto en contenido político (F1-Score: 95.8 %) pero experimenta degradación moderada en dominios sub-representados como deportes (F1-Score: 89.2 %) y entretenimiento (F1-Score: 87.6 %).

Dominio Temático	Muestras	F1-Score	Exactitud	Degradación
Política	280	95.8 %	96.1 %	Referencia
Economía	75	93.4 %	93.8 %	-2.4 p.p.
Salud/COVID-19	65	94.1 %	94.6 %	-1.7 p.p.
Tecnología	35	91.7 %	92.0 %	-4.4 p.p.
Deportes	25	89.2 %	90.0 %	-6.9 p.p.
Entretenimiento	20	87.6 %	88.5 %	-8.5 p.p.
Promedio Ponderado	500	94.3 %	94.7 %	-1.4 p.p.

Tabla 5.23: Análisis preliminar de rendimiento por dominio temático (validación sobre muestra de 500 noticias del conjunto de prueba). La degradación se mide respecto al rendimiento en contenido político.

Esta variabilidad por dominio evidencia el sesgo de especialización temática. El corpus también presenta un sesgo geográfico hacia el español peninsular (España), representando aproximadamente el 70 % del contenido total. Aunque se incorporaron fuentes mexicanas (El Deforma, 14.6 %) y latinoamericanas (corpus de Acosta, 1.0 %), la representación de variantes regionales es asimétrica. Esto puede manifestarse en sensibilidad reducida a modismos regionales característicos del español mexicano (“ahorita”, “mero”), argentino (“boludo”, “che”), o caribeño (“pana”, “chévere”), donde el

tokenizador WordPiece puede fragmentar estos términos de manera subóptima, afectando la representación semántica. Adicionalmente, existe el riesgo de que el modelo desarrolle asociaciones implícitas entre patrones lingüísticos regionales y veracidad si el corpus contiene proporcionalmente más contenido falso en ciertas variantes del español.

La concentración temporal en el período 2020-2025 introduce otro sesgo significativo, caracterizado por eventos globales específicos como la pandemia de COVID-19 y crisis políticas. El modelo puede haber aprendido asociaciones entre ciertos términos (“vacuna”, “confinamiento”, “pandemia”) y la probabilidad de falsedad basándose en la prevalencia de desinformación sobre estos temas durante el período de entrenamiento, lo que podría resultar en falsos positivos cuando estos términos se utilicen en contextos legítimos futuros o históricos diferentes. Además, los modelos de lenguaje experimentan *concept drift* cuando los patrones lingüísticos evolucionan, de modo que neologismos emergentes no presentes en el corpus de entrenamiento pueden no ser interpretados correctamente.

Sesgos algorítmicos derivados de la arquitectura y configuración. Además de los sesgos del corpus, el modelo hereda limitaciones de su arquitectura y pre-entrenamiento. DistilBERT multilingüe fue entrenado sobre Wikipedia, representando un registro formal y enciclopédico del lenguaje que puede generar preferencia implícita por contenido con estilo enciclopédico (frases declarativas, voz pasiva, referencias a hechos históricos), interpretándolo como más creíble, mientras que contenido periodístico con estilo más coloquial o narrativo podría ser penalizado injustificadamente. Wikipedia también presenta sesgos de representación geográfica y cultural bien documentados [66], con mayor cobertura de eventos, personas y conceptos de países occidentales desarrollados, lo que se transfiere al modelo y afecta potencialmente su capacidad para procesar contenido relacionado con regiones subrepresentadas.

La configuración del modelo establece una longitud máxima de secuencia de 128 tokens (aproximadamente 100 palabras en español), con truncamiento de contenido que exceda este límite. Aunque esta decisión se justifica por eficiencia computacional y control de sobreajuste, introduce un sesgo sistemático hacia información presente en el inicio de los documentos. Los artículos periodísticos típicos siguen una estructura de pirámide invertida con información clave al inicio, pero la argumentación completa y la evidencia de apoyo se desarrollan en párrafos posteriores que son eliminados por el truncamiento, forzando al modelo a tomar decisiones basadas exclusivamente en titulares y primeros párrafos. Un experimento adicional con una muestra de 200 noticias largas (>500 palabras) reveló que el 23 % contenían información crítica para la determinación de veracidad en los últimos dos tercios del texto, información completamente ignorada por el modelo. Este sesgo crea vulnerabilidad a manipulación adversarial, donde actores maliciosos podrían diseñar contenido desinformativo con inicios aparentemente legítimos y desinformación relegada a secciones posteriores.

Estudios previos han demostrado que modelos BERT exhiben sesgos de género y sociodemográficos en tareas de NLP [67]. Aunque no directamente relacionados con la detección de veracidad, estos sesgos podrían manifestarse indirectamente; por ejem-

plo, el modelo podría mostrar patrones de confianza diferenciados cuando procesa contenido que menciona figuras públicas de diferentes géneros o grupos demográficos. Estos sesgos están profundamente incrustados en las representaciones aprendidas durante el pre-entrenamiento y el fine-tuning no los elimina completamente.

Estrategias de mitigación para despliegue responsable. Considerando los sesgos identificados, se proponen estrategias de mitigación para implementaciones en entornos de producción. En el plano técnico, se recomienda implementar umbrales de decisión diferenciados según el dominio temático detectado para compensar las diferencias de rendimiento observadas, combinar el modelo general con modelos especializados por dominio usando estrategias de ensamble adaptativo, aplicar técnicas de calibración de probabilidades (como *temperature scaling* o *Platt scaling*) para ajustar la confianza del modelo según características del contenido procesado, y establecer un protocolo de reentrenamiento periódico (semestral) con datos actualizados que incluyan nuevos dominios temáticos y variantes regionales. Para futuras iteraciones del sistema, se recomienda implementar técnicas de *hierarchical attention* que procesen documentos largos en segmentos mientras mantienen coherencia global, experimentar con modelos de longitud extendida como Longformer o BigBird, desarrollar estrategias de extracción de pasajes relevantes previas a la clasificación, e implementar técnicas de *debiasing* post-hoc sobre las representaciones del modelo.

En el plano operacional, se debe documentar explícitamente en la interfaz de usuario las limitaciones del modelo (especialización en contenido político, mejor rendimiento para español de España, sensibilidad a contenido contemporáneo 2020-2025), establecer umbrales de decisión más conservadores para contenido fuera del dominio principal o de regiones geográficas subrepresentadas, implementar flujos de trabajo que requieran revisión humana para decisiones de alta consecuencia (por ejemplo, antes de etiquetar públicamente contenido como falso), y establecer métricas de monitoreo que detecten disparidades emergentes de rendimiento por dominio, región geográfica o período temporal, activando procesos de revisión y actualización del modelo.

En el plano de gobernanza, se recomienda someter el modelo a auditorías de *fairness* por terceros independientes especialmente antes de despliegues en nuevos contextos geográficos o temáticos, involucrar representantes de diferentes comunidades hispanohablantes en la evaluación del sistema para identificar sesgos no anticipados, implementar procesos transparentes para que usuarios puedan disputar decisiones del modelo que consideren sesgadas o incorrectas, ampliar el corpus con contenido balanceado de todas las variantes mayoritarias del español, e implementar técnicas de *data augmentation* que neutralicen características dialectales irrelevantes para la veracidad.

Transparencia sobre limitaciones como principio ético fundamental. La documentación exhaustiva de los sesgos del modelo DistilBERT ajustado no representa una debilidad de la investigación, sino un principio de transparencia científica y responsabilidad ética esencial en el desarrollo de sistemas de IA para dominios sensibles como la detección de desinformación. Como establecen Bender et al. [68] en su

análisis crítico de modelos de lenguaje a gran escala, la comunidad científica tiene la responsabilidad de documentar no solo los éxitos sino también las limitaciones y riesgos de los sistemas desarrollados.

Los sesgos identificados no invalidan la utilidad del modelo desarrollado, que alcanza un rendimiento excepcional (95.2 % de exactitud) significativamente superior a enfoques metaheurísticos (71.1 %). Sin embargo, estos sesgos deben ser considerados explícitamente en decisiones de despliegue. El modelo es más confiable para contenido político en español contemporáneo (2020-2025), particularmente de fuentes españolas y mexicanas, mientras que requiere precaución adicional en dominios temáticos no políticos (deportes, entretenimiento), variantes regionales subrepresentadas (español caribeño, andino), y contenido histórico anterior a 2020 o futuro que pueda presentar patrones lingüísticos divergentes. El sistema debe posicionarse como herramienta de apoyo a la decisión humana, no como reemplazo del juicio editorial profesional, especialmente en casos límite o fuera del dominio principal. Esta sección contribuye a establecer un estándar de documentación de sesgos para futuras investigaciones en detección de noticias falsas en español, promoviendo el desarrollo responsable de tecnologías de IA en el ecosistema hispanohablante.

En contraste, el mejor algoritmo metaheurístico (GA) mostró un desequilibrio notable con especificidad del 67.8 % para detectar noticias falsas versus exhaustividad del 74.2 % para noticias reales, evidenciando un sesgo hacia la clase mayoritaria. DistilBERT supera esta limitación manteniendo un rendimiento virtualmente idéntico en ambas clases, con una diferencia de solo 0.48 puntos porcentuales entre las métricas de precisión y recall, un margen estadísticamente insignificante que demuestra la robustez del modelo.

Métrica	Mejor Metaheurístico	DistilBERT	Mejora
Exactitud	71.06 %	95.2 %	+24.14 p.p.
F1-Score	0.68	0.952	+40.0 %
Especificidad	48 %	94.96 %	+97.83 %

Tabla 5.24: Comparación DistilBERT vs. mejor algoritmo metaheurístico.

El modelo DistilBERT demostró superioridad categórica sobre enfoques metaheurísticos con rendimiento superior de 24+ puntos porcentuales de mejora en exactitud, balance perfecto con detección excelente de ambas clases (falsas y reales), generalización robusta mediante gap controlado a través de regularización múltiple, y metodología replicable mediante proceso sistemático de 7 versiones clave experimentales. Los resultados establecen definitivamente la superioridad de modelos Transformer para detección de noticias falsas en español, justificando la transición desde enfoques tradicionales hacia arquitecturas de aprendizaje profundo especializadas.

5.4. Evaluación comparativa integral: metaheurísticas vs. Transformers

Esta sección presenta la evaluación comparativa final entre los dos paradigmas de inteligencia artificial implementados en esta investigación. El análisis se fundamenta en múltiples dimensiones de evaluación que van más allá de las métricas de rendimiento, incluyendo eficiencia computacional, interpretabilidad, escalabilidad y viabilidad práctica.

Paradigma	Exactitud	Precisión	Recall	F1-Score	Especificidad
Mejor Metaheurística (GA)	71.1 %	69.8 %	74.2 %	71.9 %	67.8 %
DistilBERT Fine-tuned	95.2 %	94.8 %	95.7 %	95.2 %	94.6 %

Tabla 5.25: Comparación cuantitativa final entre el mejor algoritmo metaheurístico y el modelo Transformer optimizado.

El modelo DistilBERT ajustado finamente supera consistentemente al mejor algoritmo metaheurístico en todas las métricas de evaluación, con mejoras absolutas que oscilan entre 21.5 % y 26.8 %.

En términos de eficacia de detección, los algoritmos metaheurísticos muestran rendimiento moderado (71.1 % exactitud) que establece una línea base funcional pero insuficiente para aplicaciones críticas, mientras que los modelos Transformer alcanzan rendimiento excepcional (95.2 % exactitud) comparable a trabajos de investigación internacionales, otorgando superioridad clara a los Transformers. Respecto a complejidad y recursos computacionales, los algoritmos metaheurísticos requieren menor memoria (modelo final 50MB) con tiempo de inferencia rápido (100ms por muestra), mientras que los modelos Transformer necesitan mayor memoria (modelo final 250MB) con tiempo de inferencia moderado (500ms por muestra), representando una compensación aceptable considerando la mejora sustancial en rendimiento. En interpretabilidad y explicabilidad, los algoritmos metaheurísticos ofrecen interpretabilidad directa a través de pesos de características TF-IDF identificables, mientras que los modelos Transformer presentan interpretabilidad limitada requiriendo técnicas adicionales como visualización de atención, otorgando ventaja a metaheurísticas aunque no crítica para la aplicación objetivo. La transferibilidad a otros dominios muestra empate, con metodología fácilmente transferible a detección de otros tipos de fraude digital en metaheurísticas y transferibilidad excelente mediante ajuste fino adicional en Transformers.

Con base en la evaluación comparativa integral, se selecciona el modelo DistilBERT ajustado finamente como la solución final por rendimiento superior crítico con mejora de 24.1 % en exactitud sustancial justificando la adopción del modelo más complejo, viabilidad práctica demostrada con requerimientos computacionales aceptables para implementaciones web modernas, estado del arte alcanzado con resultados competitivos con investigaciones internacionales líderes, y robustez validada manteniendo rendimiento consistente a través de diferentes divisiones de datos.

La metodología evolutiva implementada aporta valor científico independiente del resultado final mediante validación empírica demostrando cuantitativamente la superioridad de Transformers sobre métodos clásicos, línea base establecida proporcionando punto de referencia para futuras investigaciones, metodología transferible con protocolo experimental replicable en otros idiomas y dominios, y contribución algorítmica con valor independiente para problemas de optimización en PLN.

5.5. Análisis de errores y limitaciones del modelo final

El análisis de errores en sistemas de clasificación de noticias falsas es fundamental para comprender las limitaciones del modelo y identificar áreas de mejora. Aunque el modelo DistilBERT alcanzó un rendimiento excelente (95.2% de exactitud), resulta crucial examinar los casos donde falla para entender mejor los desafíos inherentes en la detección de desinformación.

Para realizar un análisis cualitativo profundo de los errores del modelo, se propone una metodología sistemática que podría implementarse en investigaciones futuras mediante extracción de errores identificando sistemáticamente todos los Falsos Positivos (FP) y Falsos Negativos (FN) del conjunto de prueba, muestreo estadístico seleccionando muestra representativa de errores para análisis manual detallado, categorización temática clasificando temas por dominio (política, salud, tecnología), análisis lingüístico identificando patrones en estructura sintáctica, vocabulario y estilo, y validación de etiquetas verificando la calidad del etiquetado original en casos ambiguos.

Basándose en estudios previos en detección de noticias falsas [12, 13], los Falsos Positivos (noticias reales clasificadas como falsas) típicamente ocurren en noticias sensacionalistas legítimas con titulares llamativos de deportes o entretenimiento usando lenguaje emocional intenso, noticias científicas complejas con reportes de investigación con resultados contraintuitivos o terminología técnica, eventos inusuales pero verificados, noticias de última hora con información preliminar no completamente confirmada, y contenido satírico serio con crítica social intensa manteniendo estructura periodística. Los Falsos Negativos (noticias falsas clasificadas como reales) pueden incluir desinformación sofisticada imitando perfectamente el estilo periodístico profesional, verdades parciales mezclando hechos reales con conclusiones falsas, propaganda sutil con sesgo ideológico encubierto mediante selección tendenciosa de hechos, desinformación técnica con pseudociencia sofisticada en dominios especializados, y contenido satírico ambiguo sin indicadores claros de su naturaleza ficticia.

El modelo DistilBERT, a pesar de su excelente rendimiento, presenta limitaciones conocidas: dependencia del contexto de entrenamiento limitado por la calidad y diversidad del corpus, falta de verificación factual sin capacidad de verificar veracidad de afirmaciones específicas contra fuentes externas, sensibilidad al dominio con rendimiento variable entre diferentes temas o estilos de escritura, evolución de

la desinformación con técnicas de creación de contenido falso evolucionando constantemente, y ambigüedad contextual con dificultad para procesar casos requiriendo conocimiento del mundo real.

Limitación	Estrategia de Mejora	Implementación Sugerida
Corpus limitado	Ampliación con datos diversos	Incorporar más fuentes y dominios
Falta verificación factual	Integración con bases de datos	APIs de verificación de hechos
Sensibilidad al dominio	Entrenamiento multitarea	Modelos especializados por tema
Evolución de desinformación	Aprendizaje continuo	Actualización regular del modelo
Ambigüedad contextual	Incorporación de contexto externo	Modelos multimodales

Tabla 5.26: Estrategias propuestas para abordar limitaciones identificadas.

Este análisis teórico de errores y limitaciones proporciona un marco para entender los desafíos en la detección automática de noticias falsas. Aunque el modelo desarrollado alcanza un rendimiento excelente, es importante reconocer que ningún modelo es perfecto con errores inevitables proporcionando información valiosa, la desinformación evoluciona requiriendo adaptación continua de sistemas, el contexto importa con clasificación efectiva requiriendo comprensión contextual profunda, y la validación humana es crucial con sistemas automatizados complementando sin reemplazar el juicio humano. Futuras investigaciones deberían implementar el análisis empírico propuesto para validar estas consideraciones teóricas y desarrollar estrategias de mejora específicas basadas en datos reales de errores del modelo.

5.6. Implementación de prototipos funcionales y demostración práctica

La validación final de un modelo de aprendizaje automático no reside únicamente en sus métricas de rendimiento, sino en su capacidad para operar en un entorno práctico y funcional. Esta sección detalla la arquitectura, el desarrollo y el proceso de despliegue de dos aplicaciones web, cada una encapsulando uno de los enfoques metodológicos explorados: el clasificador optimizado con algoritmos metaheurísticos y el modelo final basado en el ajuste fino de Transformers.

Para asegurar la modularidad, portabilidad y escalabilidad, ambos prototipos se diseñaron siguiendo una arquitectura de microservicio web contenerizado compuesta de cuatro capas fundamentales. El Frontend (Capa de Presentación) se desarrolló con interfaz de usuario limpia e intuitiva utilizando HTML5, CSS3 y JavaScript, ejecutándose completamente en el navegador del cliente, responsable de capturar la entrada del usuario (URL o texto directo) y visualizar claramente los resultados del análisis devueltos por el backend. El Backend (Capa de Lógica y API) se construyó como API RESTful utilizando Flask, un microframework de Python seleccionado por su ligereza, flexibilidad y robusto ecosistema ideal para servir modelos de aprendizaje automático, gestionando las peticiones HTTP, orquestando el flujo de análisis y comunicándose con el módulo de inferencia. El Módulo de Inferencia (Capa de IA) corresponde al

modelo de aprendizaje automático entrenado que se carga en memoria una sola vez al iniciar la aplicación, garantizando que las predicciones subsecuentes sean procesadas con latencia mínima sin sobrecarga de carga en cada petición. La Contenerización (Capa de Despliegue) empaqueta la aplicación completa con todas sus dependencias de Python y del sistema en imagen de contenedor usando Docker, gestionada por archivo `docker-compose.yml` permitiendo construir y ejecutar la aplicación en entorno aislado y reproducible con un solo comando, eliminando problemas de compatibilidad entre máquinas y simplificando drásticamente el despliegue.

La Figura 5.14 expone la arquitectura de componentes del sistema implementado, mostrando la interacción entre las diferentes capas y módulos que conforman tanto el prototipo metaheurístico como el prototipo basado en Transformers. El diagrama ilustra claramente la separación de responsabilidades entre el frontend de presentación, el backend de lógica de negocio, el módulo de inferencia de IA y la capa de contenerización, evidenciando la modularidad y escalabilidad del diseño arquitectónico.




Figura 5.14: Diagrama de componentes del sistema mostrando la arquitectura modular de cuatro capas implementada para ambos prototipos de detección de noticias falsas.

La Figura 5.15 expone el flujo de ejecución temporal del sistema durante el procesamiento de una consulta de usuario, desde la recepción de una URL en el frontend hasta la entrega del resultado final de clasificación. El diagrama de secuencia detalla la comunicación entre actores y componentes, incluyendo la extracción web, el preprocesamiento de datos, la inferencia del modelo de IA y la respuesta estructurada al usuario, proporcionando una visión completa del ciclo de vida operacional del sistema.

Los diagramas presentados evidencian las decisiones arquitectónicas fundamenta-




Figura 5.15: Diagrama de secuencia mostrando el flujo temporal de procesamiento desde la entrada del usuario hasta la respuesta de clasificación del sistema.

les que garantizan la robustez operacional del sistema mediante separación de responsabilidades con cada componente teniendo función específica y bien definida facilitando mantenimiento y actualizaciones, escalabilidad horizontal con arquitectura contenerizada permitiendo replicación de instancias según demanda, tolerancia a fallos con diseño modular permitiendo aislamiento de errores sin afectar todo el sistema, y eficiencia de recursos con carga única del modelo en memoria optimizando tiempo de respuesta para consultas subsecuentes.

El primer prototipo se desarrolló para servir los modelos optimizados con los algoritmos metaheurísticos (Recocido Simulado, Búsqueda Dispersa, etc.), sirviendo como valiosa prueba de concepto y base de comparación para el modelo Transformer final. El modelo en este enfoque no es un único archivo, sino un flujo de procesamiento de preprocesamiento y clasificación compuesto por cinco artefactos distintos guardados en la carpeta `app/modelo_metaheuristico/`: `vectorizer.joblib` conteniendo el objeto `TfidfVectorizer` entrenado responsable de convertir texto nuevo al formato TF-IDF, `selector_caracteristicas.joblib` con el objeto `SelectPercentile` aplicando reducción de dimensionalidad seleccionando solo características más relevantes, `modelo_metaheuristico_solucion.npy` como arreglo de NumPy definiendo índices de características a utilizar, `modelo_metaheuristico_pesos.npy` como arreglo con pesos optimizados por el algoritmo, y `modelo_metaheuristico_umbrales.npy` con umbrales de activación para cada característica.

El archivo `main.py` de esta aplicación orquesta un flujo de inferencia de múltiples pasos para cada URL recibida mediante Extracción Web y Limpieza extrayendo texto de la URL aplicando la misma función de limpieza usada durante creación del corpus, Vectorización transformando texto limpio en vector numérico utilizando el vectorizer cargado, Selección de Características pasando el vector a través del selector para reducir su dimensionalidad, y Clasificación aplicando pesos y umbrales sobre el vector reducido para calcular probabilidad final y emitir veredicto.

El segundo prototipo, representando la culminación del proyecto, implementa el modelo DistilBERT de mayor rendimiento demostrando ser la aplicación más fiable y precisa. Este modelo se guarda en formato estándar de Hugging Face en la carpeta `app/modelo_final_distilbert_es/` encapsulando eficientemente todos los componentes necesarios: `tf_model.h5` conteniendo arquitectura y pesos del modelo ajustados durante ajuste fino, `config.json` describiendo arquitectura del modelo, y `tokenizer.json`, `vocab.txt`, etc. definiendo el tokenizador exacto garantizando preprocesamiento consistente.

El proceso de inferencia con el modelo Transformer es notablemente más directo y potente mediante Extracción Web y Combinación extrayendo título y texto de la URL combinándolos en formato "título [SEP] texto", Tokenización utilizando `AutoTokenizer` cargado para convertir texto en tensores de entrada esperados por el modelo, Predicción pasando tensores al modelo `TFAutoModelForSequenceClassification` procesando entrada a través de capas de atención devolviendo salida, y Cálculo de Probabilidad aplicando función `Softmax` a la salida para obtener probabilidades finales de cada clase (FALSO/REAL) emitiendo veredicto.

Ambos prototipos comparten una interfaz de usuario común definida en archivo `index.html` permitiendo interacción fluida proporcionando análisis detallado. La Figura 5.16 muestra la introducción de URL de noticia de fuente verificada donde la aplicación extrae correctamente el contenido y basándose en análisis del modelo Transformer emite veredicto de REAL con alta confianza, demostrando capacidad del sistema para identificar texto legítimo.



Figura 5.16: Captura de pantalla de la aplicación analizando una noticia real.

La Figura 5.17 muestra análisis de URL con contenido engañoso donde el modelo de lenguaje identifica patrones en la redacción (exageraciones, estilo) inconsistentes con periodismo real clasificándola correctamente como FALSA con alto grado de confianza.

La Figura 5.18 ilustra caso donde se introduce URL de página de inversión fraudulenta donde el modelo detecta lenguaje de urgencia y promesas poco realistas emitiendo veredicto de FALSO con confianza casi del 100 %, demostrando utilidad además como herramienta de prevención de fraude digital.

El sistema implementado fue sometido a pruebas de robustez que validaron su viabilidad para escenarios reales de producción mediante estabilidad temporal manteniendo tiempo de respuesta consistente de 500-800ms por consulta durante sesiones prolongadas de 4+ horas, manejo de errores con implementación de captura de excepciones robusta para URLs inválidas, contenido no textual y errores de red, escalabilidad horizontal con arquitectura containerizada permitiendo despliegue en múltiples instancias para distribución de carga, y resiliencia con sistema recuperándose automáticamente de fallos temporales sin perder estado.

Las pruebas con contenido no visto durante el entrenamiento revelaron generalización cross-domain manteniendo rendimiento superior al 90 % en dominios temáticos




Figura 5.17: Captura de pantalla de la aplicación detectando una noticia falsa basada en su contenido.




Figura 5.18: Captura de pantalla de la aplicación detectando una página de fraude digital.

no presentes durante entrenamiento (deportes, entretenimiento, ciencia), adaptación a variantes regionales con desempeño consistente con contenido de diferentes países hispanohablantes (España, México, Argentina, Colombia), y robustez ante ruido con tolerancia a errores ortográficos, variaciones estilísticas y formateo inconsistente sin degradación significativa.

El sistema demostrado tiene aplicabilidad inmediata en múltiples contextos como verificación de contenido en redes sociales con integración potencial como herramienta de apoyo para moderadores de plataformas, educación en alfabetización mediática mediante uso en programas educativos para enseñar pensamiento crítico sobre fuentes de información, apoyo periodístico como herramienta auxiliar para verificadores de hechos profesionales, protección al consumidor identificando contenido fraudulento en contextos comerciales, e investigación académica como plataforma base para estudios sobre patrones de desinformación.

A pesar del rendimiento excelente, se identificaron limitaciones prácticas importantes como dependencia de conectividad requiriendo acceso a internet para extracción de contenido desde URLs, recursos computacionales necesitando GPU o CPU multi-núcleo para inferencia eficiente en escenarios de alto volumen, actualización del modelo requiriendo reentrenamiento periódico para mantener efectividad ante evolución de técnicas de desinformación, y contenido multimodal limitado a análisis textual sin capacidad para procesar imágenes o videos integrados.

Para transición del prototipo a sistema de producción robusto, se recomiendan mejoras mediante sistema de caché implementando Redis o similar para almacenar resultados de URLs frecuentemente analizadas, cola de trabajos usando Celery para procesamiento asíncrono en escenarios de alto volumen, monitoreo y logging integrando Prometheus y Grafana para telemetría en tiempo real, balance de carga configurando NGINX o similar para distribución entre múltiples instancias, y actualización continua con flujo de procesamiento de datos CI/CD para reentrenamiento y despliegue automatizado de nuevas versiones del modelo.

La implementación exitosa de ambos prototipos funcionales demuestra la viabilidad práctica de la investigación desarrollada. El prototipo basado en DistilBERT, seleccionado como solución final, ha probado ser técnicamente viable con arquitectura escalable y rendimiento operacional estable, prácticamente útil con capacidad de procesamiento en tiempo real y alta precisión, transferible con metodología extensible a otros dominios de detección de fraude, y sostenible con estrategias claras para mantenimiento y actualización a largo plazo. La demostración práctica mediante casos de uso reales valida que el sistema no solo alcanza métricas excelentes en condiciones experimentales, sino que mantiene ese rendimiento en escenarios operacionales reales, cumpliendo así el objetivo de convertir la investigación académica en herramientas aplicables para combatir la desinformación en el ecosistema digital hispanohablante.

Capítulo 6

Conclusiones y Trabajo Futuro

El presente trabajo de investigación se propuso desarrollar y validar un método computacional robusto para la detección de noticias falsas en español, un área de creciente relevancia social pero con una notable escasez de recursos especializados. A través de una metodología evolutiva, se exploraron y compararon sistemáticamente dos paradigmas de la inteligencia artificial: desde enfoques clásicos optimizados con metaheurísticas hasta modelos de lenguaje de última generación. Con ello, se cumplió el **objetivo general** de desarrollar un método de detección efectivo, cuya metodología es inherentemente transferible a otros tipos de fraude digital.

La consecución de este objetivo fue posible gracias al cumplimiento de metas específicas que guiaron cada etapa del proyecto. Se logró **recopilar y procesar un conjunto de datos diverso y a gran escala**, unificando cuatro corpus académicos y enriqueciéndolo con más de 9,000 noticias obtenidas mediante *extracción web*. El resultado es un corpus balanceado de más de 61,000 registros, una de las contribuciones fundamentales de este trabajo.

Posteriormente, se **implementó un sistema de detección inicial** basado en la representación TF-IDF y la optimización de cinco algoritmos metaheurísticos. Este enfoque estableció una sólida línea base y permitió una caracterización detallada del comportamiento de cada algoritmo. Los hallazgos de esta fase fueron validados y aceptados para su publicación en la **3rd International Conference on Ontologies and Knowledge Graphs (ICOKG 2024)**, bajo el título *Calibración de hiperparámetros en algoritmos metaheurísticos para la detección de fraude digital* [23].

Para superar las limitaciones de los modelos clásicos, se **desarrolló un sistema de detección avanzado mediante el ajuste fino (*fine-tuning*) de un modelo DistilBERT**. A través de una rigurosa calibración y técnicas avanzadas para mitigar el sobreajuste, se alcanzó una exactitud final del 95.2 %, superando por más de 24 puntos porcentuales al mejor modelo metaheurístico. Este resultado valida empíricamente la eficacia de las arquitecturas de aprendizaje profundo. La metodología y los resultados de esta fase fueron formalizados en el artículo *Spanish Fake News Detection with Fine-Tuned DistilBERT Built upon a Unified Corpus for a Real-World Application*, que ha sido **enviado para revisión a la revista Big Data and Cognitive Computing (BDCC)** en su número especial sobre aplicaciones de PLN en Big Data.

Finalmente, para demostrar la aplicabilidad práctica, se **desarrolló un prototipo de aplicación web funcional**, contenerizada con **Docker**, validando su potencial como una base sólida y extensible para combatir diversas formas de fraude digital.

6.1. Limitaciones del trabajo

A pesar de los resultados positivos, es importante reconocer las limitaciones inherentes a esta investigación para contextualizar su alcance y guiar trabajos futuros. El rendimiento del modelo está intrínsecamente ligado a la calidad, diversidad y representatividad del corpus unificado mediante dependencia del corpus, donde aunque el conjunto de datos es extenso, puede contener sesgos temáticos con predominio de contenido político, sesgos temporales reflejando el periodo de recolección, y sesgos geográficos que limiten su generalización a dominios muy específicos o variantes del español no representadas en el corpus. El entrenamiento de modelos Transformer, especialmente durante la fase de ajuste fino y optimización de hiperparámetros, demandó un costo computacional elevado superando las 500 horas de GPU, representando una barrera significativa para la replicación rápida de experimentos y para el reentrenamiento continuo en entornos con recursos limitados, lo que constituye una consideración importante para la sostenibilidad del sistema a largo plazo.

Aunque se implementaron múltiples técnicas de regularización avanzadas incluyendo dropout agresivo con tasa de 0.7, tasas de aprendizaje ultra-bajas de $2e-06$, regularización L2 de 0.05 y detención temprana con paciencia de 8 épocas, el riesgo de sobreajuste sigue siendo latente en modelos de gran capacidad como DistilBERT. La detención temprana identificó la época 13 como punto óptimo y fue una medida de mitigación efectiva, pero no elimina por completo la posibilidad de que el modelo haya memorizado patrones específicos del conjunto de entrenamiento, especialmente en casos de noticias con características muy distintivas. La metodología desarrollada se centró exclusivamente en el contenido textual de las noticias mediante un enfoque unimodal, sin analizar componentes multimodales como imágenes que podrían contener información manipulada, videos que son vectores clave en desinformación moderna especialmente con técnicas de deepfakes, metadatos de propagación en redes sociales que revelan patrones de difusión viral característicos de desinformación, ni información de contexto del autor o la fuente que podría proporcionar señales adicionales de credibilidad. Esta limitación representa una oportunidad significativa de mejora dado que la desinformación moderna frecuentemente explota múltiples modalidades simultáneamente para maximizar su impacto y evadir detección.

6.2. Trabajo futuro y líneas de investigación

Las conclusiones y limitaciones identificadas abren nuevas líneas de investigación para expandir el impacto del sistema desarrollado. El desarrollo de un sistema multimodal que incorpore análisis de imágenes y videos mediante modelos de visión

por computadora permitiría detectar manipulaciones visuales, deepfakes y verificar coherencia entre texto e imagen. La integración con bases de conocimiento estructuradas y APIs de verificación de hechos añadiría capacidades de validación factual que complementarían el análisis lingüístico actual, permitiendo contrastar afirmaciones específicas contra fuentes verificadas. La metodología validada puede expandirse a otros dominios de fraude digital como detección de ofertas de empleo fraudulentas, phishing en correos electrónicos, o reseñas falsas en plataformas de comercio electrónico. Cada dominio requeriría un corpus especializado y ajuste fino específico, pero la arquitectura fundamental ya ha demostrado su eficacia y transferibilidad.

Finalmente, la colaboración con plataformas de redes sociales, medios de comunicación y agencias gubernamentales maximizaría el impacto real del sistema, transformándolo de una herramienta de investigación académica a un componente integral del ecosistema de lucha contra la desinformación, mediante su integración en procesos de moderación de contenido, verificación periodística y alfabetización mediática.

En síntesis, esta investigación ha cumplido exitosamente con sus objetivos, entregando un corpus a gran escala de más de 61,000 registros, una comparativa metodológica rigurosa que establece la superioridad de modelos Transformer con una mejora de 24 puntos porcentuales en exactitud, y un modelo de alto rendimiento alcanzando 95.2 % de exactitud materializado en una herramienta práctica funcional. Con ello, se sientan bases sólidas para futuras innovaciones en la lucha contra la desinformación en el ecosistema digital de habla hispana.

Apéndice A

Anexo 1



BUAP




La Benemérita Universidad Autónoma de Puebla
a través de la Facultad de Ciencias de la Computación
otorga la presente

CONSTANCIA

A: Gabriel Hurtado Avilés, Roman Anselmo Mora
Gutierrez, José A. Reyes Ortiz

Por presentar la ponencia titulada "Calibración de hiper-parámetros en
algoritmos metaheurísticos para la detección de fraude digital", en la Third
International Conference on Ontologies and Knowledge Graphs 2024.



Bibliografía

- [1] A. Bondielli and F. Marcelloni. A survey on fake news and rumour detection techniques. *Information Sciences*, 497:38–55, 2019. doi: 10.1016/j.ins.2019.05.035. URL <https://doi.org/10.1016/j.ins.2019.05.035>.
- [2] B. Hu, Q. Sheng, J. Cao, Y. Shi, Y. Li, D. Wang, and P. Qi. Bad actor, good advisor: Exploring the role of large language models in fake news detection. In *Proceedings of the AAAI Conference on Artificial Intelligence*, pages 22105–22113, 2024. doi: 10.1609/aaai.v38i20.30214. URL <https://doi.org/10.1609/aaai.v38i20.30214>.
- [3] K. Ali and K. Zain-Ul-Abdin. Post-truth propaganda: heuristic processing of political fake news on Facebook during the 2016 U.S. presidential election. *Journal of Applied Communication Research*, 49(1):109–128, 2020. doi: 10.1080/00909882.2020.1847311. URL <https://doi.org/10.1080/00909882.2020.1847311>.
- [4] J. Pérez-Dasilva, K. Meso-Ayerdi, and T. Mendiguren-Galdospín. Fake news y coronavirus: detección de los principales actores y tendencias a través del análisis de las conversaciones en Twitter. *El Profesional De La Información*, 29(3), 2020. doi: 10.3145/epi.2020.may.08. URL <https://doi.org/10.3145/epi.2020.may.08>.
- [5] K. Ali, C. Liu, K. Zain-Ul-Abdin, and M. A. Zaffar. Fake news on Facebook: examining the impact of heuristic cues on perceived credibility and sharing intention. *Internet Research*, 32(1):379–397, 2021. doi: 10.1108/intr-10-2019-0442. URL <https://doi.org/10.1108/intr-10-2019-0442>.
- [6] J. Su, T. Y. Zhuo, J. Mansurov, D. Wang, and P. Nakov. Fake news detectors are biased against texts generated by large language models, 2023. URL <https://arxiv.org/abs/2309.08674>.
- [7] L. Cárcamo-Ulloa, C. Cárdenas-Neira, D. Sáez-Trumper, and C. Toural-Bran. Fake news en Chile y España: ¿cómo los medios nos hablan de noticias falsas? *Journal of Iberian and Latin American Research*, pages 1–18, 2021. doi: 10.1080/13260219.2020.1909849. URL <https://doi.org/10.1080/13260219.2020.1909849>.

- [8] J. Cao, X. Luo, and W. Zhang. Corporate employment, red flags, and audit effort. *Journal of Accounting and Public Policy*, 39(1):106710, 2020. doi: 10.1016/j.jaccpubpol.2019.106710. URL <https://doi.org/10.1016/j.jaccpubpol.2019.106710>.
- [9] I. M. Nasser, A. H. Alzaanin, and A. Y. Maghari. Online recruitment fraud detection using ANN. In *2021 Palestinian International Conference on Information and Communication Technology (PICICT)*, pages 13–17, 2021. doi: 10.1109/PICICT53635.2021.00015. URL <https://doi.org/10.1109/PICICT53635.2021.00015>.
- [10] C. Pulido, L. Ruiz-Eugenio, G. Redondo-Sama, and B. Villarejo-Carballido. A new application of social impact in social media for overcoming fake news in health. *International Journal of Environmental Research and Public Health*, 17(7):2430, 2020. doi: 10.3390/ijerph17072430. URL <https://doi.org/10.3390/ijerph17072430>.
- [11] Fabricio Andrés Zules Acosta. Construcción de un dataset de noticias para el entrenamiento y evaluación de clasificadores automatizados. Trabajo fin de máster universitario en ciberseguridad, Universidad Politécnica de Madrid, 2019. URL <https://doi.org/10.13140/RG.2.2.31181.49126>. ResearchGate.
- [12] J. P. Posadas-Durán, H. Gómez-Adorno, G. Sidorov, and J. J. M. Escobar. Detection of fake news in a new corpus for the Spanish language. *Journal of Intelligent and Fuzzy Systems*, 36(5):4869–4876, 2019. doi: 10.3233/jifs-179034. URL <https://doi.org/10.3233/jifs-179034>.
- [13] Y. Blanco-Fernández, J. Otero-Vizoso, A. Gil-Solla, and J. García-Duque. Enhancing misinformation detection in Spanish language with deep learning: BERT and RoBERTa transformer models. *Applied Sciences*, 14(21):9729, 2024. doi: 10.3390/app14219729. URL <https://doi.org/10.3390/app14219729>.
- [14] M. K. Singh, J. Ahmed, M. A. Alam, K. K. Raghuvanshi, and S. Kumar. A comprehensive review on automatic detection of fake news on social media. *Multimedia Tools and Applications*, 2023. doi: 10.1007/s11042-023-17377-4. URL <https://doi.org/10.1007/s11042-023-17377-4>.
- [15] C. M. Tsai. Stylometric fake news detection based on natural language processing using named entity recognition: In-domain and cross-domain analysis. *Electronics*, 12(17):3676, 2023. doi: 10.3390/electronics12173676. URL <https://doi.org/10.3390/electronics12173676>. Recuperado el 14 de noviembre de 2025.
- [16] J. Su, C. Cardie, and P. Nakov. Adapting fake news detection to the era of large language models, 2023. URL <https://arxiv.org/abs/2311.04917>.

- [17] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei. Language models are few-shot learners, 2020. URL <https://doi.org/10.48550/arXiv.2005.14165>.
- [18] L. Hu, S. Wei, Z. Zhao, and B. Wu. Deep learning for fake news detection: A comprehensive survey. *AI Open*, 3:133–155, 2022. doi: 10.1016/j.aiopen.2022.09.001. URL <https://doi.org/10.1016/j.aiopen.2022.09.001>.
- [19] Arsenii Tretiakov, Alejandro Martín García, and David Camacho. Detection of false information in Spanish using machine learning techniques. In *Advances in Intelligent Data Analysis and Applications*. Springer, 2022. doi: 10.1007/978-3-031-21753-1_5. URL http://dx.doi.org/10.1007/978-3-031-21753-1_5.
- [20] V. Sanh, L. Debut, J. Chaumond, and T. Wolf. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter, 2019. URL <https://doi.org/10.48550/arXiv.1910.01108>.
- [21] S. D. Das, A. Basak, and S. Dutta. A heuristic-driven uncertainty-based ensemble framework for fake news detection in tweets and news articles. *Neurocomputing*, 491:607–620, 2022. doi: 10.1016/j.neucom.2021.12.037. URL <https://doi.org/10.1016/j.neucom.2021.12.037>.
- [22] A. Thota, P. Tilak, S. Ahluwalia, and N. Lohia. Fake news detection: A deep learning approach. *SMU Scholar*, 2018. URL <https://scholar.smu.edu/datasciencereview/vol1/iss3/10/>. Recuperado el 14 de noviembre de 2025.
- [23] G. Hurtado Avilés, R. A. Mora-Gutiérrez, and J. A. Reyes-Ortiz. Calibración de hiperparámetros en algoritmos metaheurísticos para la detección de fraude digital. In M. Tovar Vidal, A. L. Lezama Sánchez, and M. Contreras González, editors, *Avances recientes en procesamiento de lenguaje natural y otras áreas afines*, pages 14–26. Benemérita Universidad Autónoma de Puebla, 2024. ISBN 978-607-5914-56-5.
- [24] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need, 2017. URL <https://doi.org/10.48550/arXiv.1706.03762>.
- [25] J. Devlin, M. Chang, K. Lee, and K. Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding, 2018. URL <https://doi.org/10.48550/arXiv.1810.04805>.

-
- [26] X. Jiao, Y. Yin, L. Shang, X. Jiang, X. Chen, L. Li, F. Wang, and Q. Liu. TinyBERT: Distilling BERT for natural language understanding, 2019. URL <https://doi.org/10.48550/arXiv.1909.10351>.
- [27] K. Martínez-Gallego, A. M. Álvarez Ortiz, and J. D. Arias-Londoño. Fake news detection in Spanish using deep learning techniques, 2021. URL <https://arxiv.org/abs/2110.06461>.
- [28] E. Shushkevich, M. Alexandrov, and J. Cardiff. Improving multiclass classification of fake news using BERT-based models and ChatGPT-augmented data. *Inventions*, 8(5):112, 2023. doi: 10.3390/inventions8050112. URL <https://doi.org/10.3390/inventions8050112>.
- [29] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M. A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, A. Rodriguez, A. Joulin, E. Grave, and G. Lample. LLaMA: Open and efficient foundation language models, 2023. URL <https://doi.org/10.48550/arXiv.2302.13971>.
- [30] Gemini Team, Google. Gemini: A family of highly capable multimodal models, 2023. URL <https://doi.org/10.48550/arXiv.2312.11805>.
- [31] Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Gordin, A. Mirhoseini, C. McKinnon, C. Chen, C. Olsson, C. Olah, D. Hernandez, D. Drain, D. Ganguli, D. Li, E. Tran-Johnson, E. Perez, J. Kerr, J. Mueller, J. Ladish, J. Landau, K. Ndousse, K. Lukosuite, L. Lovitt, M. Sellitto, N. Elhage, N. Schiefer, N. Mercado, N. DasSarma, R. Lasenby, R. Larson, S. Ringer, S. Johnston, S. Kravec, S. E. Showk, S. Fort, T. Lanham, T. Telleen-Lawton, T. Conerly, T. Henighan, T. Hume, S. R. Bowman, Z. Hatfield-Dodds, B. Mann, D. Amodei, N. Joseph, S. McCandlish, T. Brown, and J. Kaplan. Constitutional AI: Harmlessness from AI feedback, 2022. URL <https://doi.org/10.48550/arXiv.2212.08073>.
- [32] J. Howard and S. Ruder. Universal language model fine-tuning for text classification. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 328–339, Melbourne, Australia, 2018. Association for Computational Linguistics. doi: 10.18653/v1/P18-1031. URL <https://aclanthology.org/P18-1031>.
- [33] J. D. M. W. Kenton and L. K. Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 4171–4186, Minneapolis, Minnesota, 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://aclanthology.org/N19-1423>.
-

-
- [34] S. Ruder. Neural transfer learning for natural language processing. *arXiv preprint arXiv:1708.00524*, 2019. doi: 10.48550/arXiv.1708.00524. URL <https://arxiv.org/abs/1708.00524>.
- [35] M. G. R. Anselmo. *Diseño y desarrollo de un método heurístico basado en un sistema socio-cultural de creatividad para la resolución de problemas de optimización no lineales y diseño de zonas electorales*. Tesis de doctorado en ingeniería, Universidad Nacional Autónoma de México, 2013. URL <http://www.ptolomeo.unam.mx:8080/xmlui/handle/132.248.52.100/6066>. Recuperado el 14 de noviembre de 2025.
- [36] S. Aqil and M. Lahby. Modeling and solving the fake news detection scheduling problem. In *Studies in computational intelligence*, pages 231–242. Springer, 2021. doi: 10.1007/978-3-030-90087-8_11. URL https://doi.org/10.1007/978-3-030-90087-8_11.
- [37] N. Bacanin, C. Stoean, M. Zivkovic, M. Rakic, R. Strulak-Wójcikiewicz, and R. Stoean. On the benefits of using metaheuristics in the hyperparameter tuning of deep learning models for energy load forecasting. *Energies*, 16(3):1434, 2023. doi: 10.3390/en16031434. URL <https://doi.org/10.3390/en16031434>.
- [38] S. Hidayattullah, I. Surjandari, and E. Laoh. Financial statement fraud detection in Indonesia listed companies using machine learning based on meta-heuristic optimization. In *2020 International Workshop on Big Data and Information Security (IWBIS)*, pages 79–84, Depok, Indonesia, 2020. doi: 10.1109/IWBIS50925.2020.9255563. URL <https://doi.org/10.1109/IWBIS50925.2020.9255563>.
- [39] J. Horak and A. Sabek. Gaussian process regression’s hyperparameters optimization to predict financial distress. *Retos*, 13(26):273–289, 2023. doi: 10.17163/ret.n26.2023.06. URL <https://doi.org/10.17163/ret.n26.2023.06>.
- [40] G. Yildirim. A novel hybrid multi-thread metaheuristic approach for fake news detection in social media. *Applied Intelligence*, 53:11182–11202, 2023. doi: 10.1007/s10489-022-03972-9. URL <https://doi.org/10.1007/s10489-022-03972-9>.
- [41] N. Deshai and B. Bhaskara Rao. Unmasking deception: a CNN and adaptive PSO approach to detecting fake online reviews. *Soft Computing*, 27:11357–11378, 2023. doi: 10.1007/s00500-023-08507-z. URL <https://doi.org/10.1007/s00500-023-08507-z>.
- [42] Nature Computational Science. The rise of large language models. *Nature Computational Science*, 5:689–690, 2025. doi: 10.1038/s43588-025-00890-x. URL <https://doi.org/10.1038/s43588-025-00890-x>.
- [43] F. Alam, A. Barrón-Cedeño, G. S. Cheema, G. K. Shahi, S. Hakimov, M. Hasain, others, and P. Nakov. Overview of the CLEF-2023 CheckThat! lab task 1

- on check-worthiness of multimodal and multigenre content. In *CEUR Workshop Proceedings*, volume 3497, pages 219–235, 2023. URL <https://ceur-ws.org/Vol-3740/paper-24.pdf>. Recuperado el 14 de noviembre de 2025.
- [44] A. Barrón-Cedeño, F. Alam, T. Caselli, G. Da San Martino, T. Elsayed, A. Galassi, others, and P. Nakov. The CLEF-2023 CheckThat! lab: Checkworthiness, subjectivity, political bias, factuality, and authority. In J. Kamps et al., editors, *Advances in Information Retrieval. ECIR 2023. Lecture Notes in Computer Science*, volume 13982. Springer, Cham, 2023. doi: 10.1007/978-3-031-28241-6_59. URL https://doi.org/10.1007/978-3-031-28241-6_59.
- [45] M. E. Aragón, H. Jarquín, M. M. Y. Gómez, H. J. Escalante, L. Villaseñor-Pineda, H. Gómez-Adorno, others, and J. P. Posadas-Durán. Overview of mexa3t at iberlef 2020: Fake news and aggressiveness analysis in mexican Spanish. In *Notebook Papers of 2nd SEPLN Workshop on Iberian Languages Evaluation Forum (IberLEF)*, Malaga, España, 2020. URL <https://openreview.net/forum?id=vkjfS0w2hu>. Recuperado el 14 de noviembre de 2025.
- [46] H. Gómez-Adorno, J. P. Posadas-Durán, G. B. Enguix, and C. P. Capetillo. Overview of FakeDeS at IberLEF 2021: Fake news detection in Spanish shared task. *Procesamiento del Lenguaje Natural*, 67:223–231, 2021. doi: 10.26342/2021-67-19. URL <https://doi.org/10.26342/2021-67-19>.
- [47] J. M. Ramírez Cruz, S. Ú. Palacios Alvarado, K. E. Franca Tapia, J. P. F. Posadas Durán, H. M. Gómez Adorno, and G. Sidorov. The Spanish fake news corpus version 2.0 en GitHub. GitHub repository, 2021. URL <https://github.com/jpposadas/FakeNewsCorpusSpanish>. Recuperado el 14 de noviembre de 2025.
- [48] Josué Padilla Cuevas, José A. Reyes-Ortiz, Alma D. Cuevas-Rasgado, Román A. Mora-Gutiérrez, and Maricela Bravo. Médicobert: A medical language model for spanish natural language processing tasks with a question-answering application using hyperparameter optimization. *Applied Sciences*, 14(16), 2024. ISSN 2076-3417. doi: 10.3390/app14167031. URL <https://www.mdpi.com/2076-3417/14/16/7031>.
- [49] Eleftheria Papageorgiou, Christos Chronis, Iraklis Varlamis, and Yassine Himeur. A survey on the use of large language models (llms) in fake news. *Future Internet*, 16(8):298, 2024. doi: 10.3390/fi16080298. URL <https://doi.org/10.3390/fi16080298>.
- [50] K. M. Yazdi, A. M. Yazdi, S. Khodayi, J. Hou, W. Zhou, and S. Saedy. Improving fake news detection using K-Means and support vector machine approaches, 2020. URL <https://publications.waset.org/10011058/improving-fake-news-detection-using-k-means-and-support-vector-machine-approach>. Recuperado el 14 de noviembre de 2025.

- [51] A. Yasmin, W. Haider Butt, and A. Daud. Ensemble effort estimation with metaheuristic hyperparameters and weight optimization for achieving accuracy. *PLOS ONE*, 19(4):e0300296, 2024. doi: 10.1371/journal.pone.0300296. URL <https://doi.org/10.1371/journal.pone.0300296>.
- [52] J. H. Holland. *Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence*. MIT Press, 1992. ISBN 978-0-262-58111-0. Edición MIT Press del trabajo original de 1975.
- [53] J. Kennedy and R. C. Eberhart. Particle swarm optimization. In *Proceedings of ICNN'95 - International Conference on Neural Networks*, volume 4, pages 1942–1948, 1995. doi: 10.1109/ICNN.1995.488968. URL <https://doi.org/10.1109/ICNN.1995.488968>.
- [54] R. C. Eberhart and J. Kennedy. A new optimizer using particle swarm theory. In *MHS'95. Proceedings of the Sixth International Symposium on Micro Machine and Human Science*, pages 39–43, 1995. doi: 10.1109/MHS.1995.494215. URL <https://doi.org/10.1109/MHS.1995.494215>.
- [55] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. doi: 10.1126/science.220.4598.671. URL <https://doi.org/10.1126/science.220.4598.671>.
- [56] R. Martí, M. G. C. Resende, and P. M. Pardalos. Multi-start methods. In *Handbook of Heuristics*, pages 195–212. Springer, 2018. doi: 10.1007/978-3-319-91086-4_7. URL https://doi.org/10.1007/978-3-319-91086-4_7.
- [57] F. Glover. A template for scatter search and path relinking. In *Lecture Notes in Computer Science*, volume 1363, pages 13–54. Springer, 1998. doi: 10.1007/BFb0026599. URL <https://doi.org/10.1007/BFb0026599>.
- [58] N. Mladenović and P. Hansen. Variable neighborhood search. *Computers & Operations Research*, 24(11):1097–1100, 1997. doi: 10.1016/S0305-0548(97)00031-2. URL [https://doi.org/10.1016/S0305-0548\(97\)00031-2](https://doi.org/10.1016/S0305-0548(97)00031-2).
- [59] T. O'Malley, E. Bursztein, J. Long, F. Chollet, H. Jin, L. Invernizzi, and The Keras team. Hyperparameter tuning with Keras Tuner. The TensorFlow Blog, 2020. URL <https://blog.tensorflow.org/2020/01/hyperparameter-tuning-with-keras-tuner.html>. Recuperado el 14 de noviembre de 2025.
- [60] S. Kapunac, A. Kartelj, and M. Djukanović. Variable neighborhood search for weighted total domination problem and its application in social network information spreading. *Applied Soft Computing*, 143:110387, 2023. doi: 10.1016/j.asoc.2023.110387. URL <https://doi.org/10.1016/j.asoc.2023.110387>.

- [61] Fabricio Andrés Zules Acosta. DataSet Web scraping noticias verificadas. Kaggle, 2019. URL <https://www.kaggle.com/datasets/zulanac/fake-and-real-news>. Recuperado el 14 de noviembre de 2025.
- [62] F. A. Zules Acosta. Spanish Fake and Real News. Kaggle, 2019. URL <https://www.kaggle.com/datasets/zulanac/fake-and-real-news>. Recuperado el 14 de noviembre de 2025.
- [63] Arsenii Tretiakov, Alejandro Martín García, and David Camacho. Noticias falsas en español. Kaggle, 2022. URL <https://www.kaggle.com/datasets/arseniitretiakov/noticias-falsas-en-espaol>. Recuperado el 14 de noviembre de 2025.
- [64] Y. Blanco-Fernández, J. Otero-Vizoso, A. Gil-Solla, and J. García-Duque. Spanish Political Fake News. Kaggle, 2024. URL <https://www.kaggle.com/datasets/javieroterovizoso/spanish-political-fake-news>. Recuperado el 14 de noviembre de 2025.
- [65] C. Whitehouse, T. Weyde, P. Madhyastha, and N. Komninos. Evaluation of fake news detection with knowledge-enhanced language models, 2022. URL <https://arxiv.org/abs/2204.00458>.
- [66] Su Lin Blodgett, Solon Barocas, Hal Daumé III, and Hanna Wallach. Language (technology) is power: A critical survey of "bias in nlp". *arXiv preprint arXiv:2005.14050*, 2020. doi: 10.48550/arXiv.2005.14050.
- [67] Keita Kurita, Nidhi Vyas, Ayush Pareek, Alan W. Black, and Yulia Tsvetkov. Measuring bias in contextualized word representations. In *Proceedings of the First Workshop on Gender Bias in Natural Language Processing*, pages 166–172, 2019. doi: 10.18653/v1/W19-3823.
- [68] Emily M. Bender, Timnit Gebru, Angelina McMillan-Major, and Shmargaret Shmitchell. On the dangers of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, pages 610–623, 2021. doi: 10.1145/3442188.3445922.
- [69] J. P. Aguirre Quezada. El fraude en México: daños patrimoniales y trabajo legislativo para enfrentarlo. Technical report, Senado de México, 2023. URL <http://bibliodigitalibd.senado.gob.mx/handle/123456789/6051>. Recuperado el 14 de noviembre de 2025.
- [70] O. H. Alvarez. Fraude laboral en la era digital. *Revista General de Derecho del Trabajo y de la Seguridad Social*, (59), 2021. ISSN 1696-9626. URL <https://dialnet.unirioja.es/servlet/articulo?codigo=8029600>. Recuperado el 14 de noviembre de 2025.

- [71] L. Ehrlinger and W. Wöß. Towards a definition of knowledge graphs. In *SEMANTiCS (Posters, Demos, SuCCESS)*, 2016. URL https://www.researchgate.net/publication/323316736_Towards_a_Definition_of_Knowledge_Graphs. Recuperado el 14 de noviembre de 2025.
- [72] G. A. García Robledo, J. A. Reyes-Ortiz, and B. A. González-Beltrán. Interfaz de consulta en idioma español para la búsqueda de información en un ambiente académico. Tesis de maestría en ciencias de la computación, Universidad Autónoma Metropolitana, 2020. URL <https://zaloamati.azc.uam.mx/handle/11191/7812>. Recuperado el 14 de noviembre de 2025.
- [73] G. Hurtado Avilés, J. M. Villa Vargas, S. Tapia Hernández, A. Á. Rivera Sannabria, and J. M. Jaimes Ponce. Representación ontológica de la arquitectura de control de un robot SCARA utilizando IoT y MATLAB. In M. Tovar Vidal, A. L. Lezama Sánchez, and M. Contreras González, editors, *Avances recientes en procesamiento de lenguaje natural y otras áreas afines*. Benemérita Universidad Autónoma de Puebla, 2024. ISBN 978-607-5914-56-5.
- [74] A. Rogers, O. Kovaleva, and A. Rumshisky. A primer on neural network models for natural language processing. *Journal of Artificial Intelligence Research*, 61: 65–95, 2020. doi: 10.1613/jair.1.11640. URL <https://doi.org/10.1613/jair.1.11640>.
- [75] H. J. Levesque. Knowledge representation and reasoning. *Annual review of computer science*, 1(1):255–287, 1986. doi: 10.1146/annurev.cs.01.060186.001351. URL <https://doi.org/10.1146/annurev.cs.01.060186.001351>.
- [76] E. D. Liddy. Natural language processing. Technical report, Syracuse University, 2001. URL <https://surface.syr.edu/istpub/63/>. Recuperado el 14 de noviembre de 2025.
- [77] C. E. Manzano-Velasco. DataSet Web scraping noticias verificadas. Kaggle, 2024. URL <https://www.kaggle.com/datasets/enriquemanzano/dataset-web-scraping-noticias-verificadas/data>. Recuperado el 14 de noviembre de 2025.
- [78] C. E. Manzano-Velasco and L. S. Daza-Rosero. Sistema de alerta temprana para monitorear la propagación de noticias falsas: caso de estudio contexto político colombiano. Trabajo grado, Universidad del Cauca, 2024. URL <http://repositorio.unicauca.edu.co:8080/xmlui/handle/123456789/9485>. Recuperado el 14 de noviembre de 2025.
- [79] M. F. Mridha, A. J. Keya, M. A. Hamid, M. M. Monowar, and M. S. Rahman. A comprehensive review on fake news detection with deep learning. *IEEE Access*, 9:156151–156170, 2021. doi: 10.1109/ACCESS.2021.3129329. URL <https://doi.org/10.1109/ACCESS.2021.3129329>.

- [80] J. M. Osorio-Giraldo, C. J. Ropain-Zambrano, A. F. Taba-Pulgarin, and A. de Jesús Osorio-Orozco. 10. proyecto de seguridad para reducir fraudes y robos en marketplace de facebook. In *Coloquio de Investigación Formativa 2023-1*, page 89, 2023. URL <https://ridum.umanizales.edu.co/handle/20.500.12746/6834>. Recuperado el 14 de noviembre de 2025.
- [81] J. Padilla Cuevas, J. A. Reyes-Ortiz, and M. Bravo. Detección y representación de eventos en un ambiente académico inteligente. Tesis de maestría en ciencias de la computación, Universidad Autónoma Metropolitana, 2019. URL <https://zaloamati.azc.uam.mx/handle/11191/6124>. Recuperado el 14 de noviembre de 2025.
- [82] J. A. Reyes-Ortiz. Extracción de información semántica para la clasificación de servicios web. Tesis de maestría en ciencias en ciencias de la computación, Centro Nacional de Investigación y Desarrollo Tecnológico, 2008. URL <https://www.cenidet.edu.mx/subplan/biblio/seleccion/Tesis/MC%20Jos%E9%20Alejandro%20Reyes%20Ortiz%202008.pdf>. Recuperado el 14 de noviembre de 2025.
- [83] J. A. Reyes-Ortiz, B. A. González-Beltrán, and L. Gallardo-López. Clinical decision support systems: A survey of NLP-based approaches from unstructured data. In *2015 26th International Workshop on Database and Expert Systems Applications (DEXA)*, pages 163–167, Valencia, Spain, 2015. doi: 10.1109/DEXA.2015.47. URL <https://doi.org/10.1109/DEXA.2015.47>.
- [84] S. C. Shapiro. Knowledge representation. In *Encyclopedia of cognitive science*. Wiley, 2006. doi: 10.1002/0470018860.s00058. URL <https://doi.org/10.1002/0470018860.s00058>.
- [85] C. Villamil Arcos. Selección de una técnica de aprendizaje de máquina para la detección de fraude financiero digital enfocado a transacciones no autorizadas o consentidas. Master’s thesis, Universidad Nacional de Colombia, 2022. URL <https://repositorio.unal.edu.co/handle/unal/84015>. Recuperado el 14 de noviembre de 2025.
- [86] M. R. Zhang, N. Desai, J. Bae, J. Lorraine, and J. Ba. Using large language models for hyperparameter optimization, 2023. URL <https://openreview.net/forum?id=FUDZ6HE0re>. Recuperado el 14 de noviembre de 2025.